

UNIWERSYTET RZESZOWSKI

Wydział Nauk Ścisłych i Technicznych



Dominik Machnik

nr albumu: 117814

Kierunek: Informatyka

Wpływ metod czyszczenia danych na jakość klasyfikatorów

Praca magisterska

Praca wykonana pod kierunkiem:

dr. hab. Jana Bazana, prof. UR

Rzeszów, 2026

Spis treści

WSTĘP	1
1 Cel, zakres i motywacja pracy	2
1.1 Motywacja i sformułowanie problemu	2
1.2 Cel pracy	3
1.3 Główne pytania i zagadnienia badawcze	3
1.4 Zakres pracy	4
1.5 Struktura pracy	4
2 Część teoretyczna	6
2.1 Taksonomia problemów jakości danych tabelarycznych	6
2.1.1 Mechanizmy powstawania braków danych	6
2.1.2 Wartości odstające i błędy grube	7
2.2 Metody wstępnego przetwarzania i czyszczenia danych	7
2.2.1 Uzupełnianie braków danych (Imputacja)	7
2.2.2 Identyfikacja i obsługa wartości odstających	8
2.2.3 Skalowanie atrybutów i kodowanie zmiennych jakościowych	9
2.3 Wybrane algorytmy klasyfikacji	9
2.3.1 Naiwny Klasyfikator Bayesa (Gaussian Naive Bayes)	9
2.3.2 Perceptron Wielowarstwowy (MLP)	10
2.3.3 Lasy Losowe (Random Forest)	10
2.3.4 XGBoost (Extreme Gradient Boosting)	11
2.4 Metryki oceny jakości modeli i aparat statystyczny	12
2.4.1 Krzywa ROC i pole pod krzywą (AUC)	12
2.4.2 Nieparametryczne testy istotności statystycznej	12
3 Środowisko i zbiory danych	13
3.1 Wykorzystane narzędzia i biblioteki	13
3.2 Charakterystyka badanych zbiorów danych	14
3.2.1 Zbiór „Zapalenia naczyń” (Vasculitis)	14
3.2.2 Zbiór „Serce” (Heart Disease)	15

3.2.3	Zbiór „Diabetes” (Pima Indians Diabetes)	15
3.2.4	Zbiór „Rezygnacje” (Customer Churn)	16
3.2.5	Zbiór „Kredyty” (German Credit)	16
3.3	Metodologia symulacji kontrolowanych zanieczyszczeń	17
3.4	Architektura potoku przetwarzania i uzasadnienie doboru strategii	18
3.4.1	Trzy filary przetwarzania wstępnego	18
3.4.2	Implementacja własnych transformatorów w standardzie scikit-learn	18
3.4.3	Redukcja pełnego planu czynnikowego ($2^3 = 8$) do zestawu strategii praktycznych	20
3.5	Protokół eksperymentalny i parametryzacja klasyfikatorów	21
4	Wyniki eksperymentów	22
4.1	Wyniki bazowe i ogólna charakterystyka odporności modeli	22
4.2	Szczegółowa analiza wyników na poszczególnych zbiorach danych	25
4.2.1	Ocena na zbiorze „Zapalenia naczyń”	25
4.2.2	Ocena na zbiorze „Serce” (Heart Disease)	28
4.2.3	Ocena na zbiorze „Diabetes” (Pima Indians Diabetes)	32
4.2.4	Ocena na zbiorze „Rezygnacje” (Customer Churn)	36
4.2.5	Ocena na zbiorze „Kredyty” (German Credit)	40
4.3	Teoretyczna interpretacja zróżnicowanej odporności modeli	44
4.3.1	Modele oparte na drzewach decyzyjnych (Random Forest i XGBoost)	44
4.3.2	Perceptron Wielowarstwowy (MLP)	45
4.3.3	Naiwny Klasyfikator Bayesa (GaussianNB)	45
4.3.4	Mechanizmy uzupełniania braków: Mediana a algorytm k -NN	46
4.4	Analiza zysku z czyszczenia danych (ΔAUC)	46
4.5	Porównanie strategii imputacji: Mediana vs KNN Imputer	48
4.6	Weryfikacja istotności statystycznej wyników	50
4.6.1	Globalny ranking metod i Diagram Różnic Krytycznych (CD Diagram)	51
5	Podsumowanie i wnioski	54
5.1	Podsumowanie wyników zrealizowanych eksperymentów	54
5.2	Główne wnioski z przeprowadzonych eksperymentów	54
5.3	Kierunki dalszego rozwoju badań	55
	ZAKOŃCZENIE	57
	LITERATURA	58
	Wykaz rysunków	60

Wykaz tabel	62
STRESZCZENIE	63

WSTĘP

Współczesny rozwój metod sztucznej inteligencji oraz uczenia maszynowego w znaczącym stopniu zmienił sposób podejmowania decyzji w wielu kluczowych obszarach gospodarki, medycyny i przemysłu. Szczególne miejsce w tych zastosowaniach zajmują dane tabelaryczne, które stanowią podstawowy format zapisu informacji w bazach medycznych, systemach bankowych, rejestrach ubezpieczeniowych czy bazach telekomunikacyjnych. Pomimo ciągłego rozwoju zaawansowanych architektur głębokich sieci neuronowych, modelowanie danych tabelarycznych wciąż stawia przed inżynierami spore wyzwania. Wynikają one przede wszystkim z różnorodności typów cech, zróżnicowania ich rozkładów oraz częstej obecności różnorodnych zanieczyszczeń.

W praktyce inżynierii danych powszechnie wiadomo, że jakość wytrenowanego modelu zależy bezpośrednio od jakości danych, którymi został on zasilony. Dane pozyskiwane z rzeczywistych środowisk (takich jak bazy kliniczne pacjentów czy systemy rozliczeniowe) bardzo rzadko bywają idealnie kompletne i czyste. Do najczęściej spotykanych problemów należą: brakujące wartości w tabelach, obecność skrajnych wartości odstających (będących wynikiem usterek aparatury pomiarowej bądź pomyłek przy wprowadzaniu danych) oraz duże różnice w skalach poszczególnych zmiennych. Zanieczyszczenia te mogą w znaczący sposób zaburzać działanie klasyfikatorów, prowadząc do błędnych decyzji i niskiej trafności predykcji.

Niniejsza praca magisterska poświęcona jest zbadaniu i usystematyzowaniu wpływu wybranych metod czyszczenia oraz wstępnego przetwarzania danych na skuteczność i stabilność działania czterech popularnych klasyfikatorów: Naiwnego Klasyfikatora Bayesa, Perceptronu Wielowarstwowego MLP, Lasów Losowych oraz algorytmu XGBoost. Badania przeprowadzono w warunkach kontrolowanego wprowadzania zanieczyszczeń na pięciu zróżnicowanych zbiorach danych, obejmujących m.in. układowe zapalenia naczyń, choroby serca, diagnostykę cukrzycy, rezygnacje klientów oraz ocenę wiarygodności kredytowej.

Do przeprowadzenia badań zaimplementowano modularny potok przetwarzania danych w języku Python, który zabezpiecza cały proces przed wyciekiem informacji (ang. *data leakage*). Analiza uzyskanych wyników, poparta wykresami oraz testami statystycznymi, pozwoliła na sformułowanie praktycznych wniosków i rekomendacji dotyczących doboru metod czyszczenia danych w zależności od wybranego modelu.

Rozdział 1

Cel, zakres i motywacja pracy

1.1 Motywacja i sformułowanie problemu

W praktyce inżynierii uczenia maszynowego etap profilowania, przygotowania i czyszczenia zbiorów danych tabelarycznych pochłania nawet do 80% całkowitego czasu realizacji projektów analitycznych [1]. Zanieczyszczenia danych nie mają jednak charakteru jednorodnego: mogą wynikać ze strukturalnych braków rejestracji, awarii aparatury pomiarowej, usterek systemów teleinformatycznych lub obecności obserwacji skrajnie odstających. Zjawiska te deformują fundamentalne estymatory statystyczne (takie jak średnia, wariancja czy korelacje międzycechowe), prowadząc do budowy modeli o zafałszowanych granicach decyzyjnych oraz niskiej zdolności generalizacji.

Kluczowym problemem badawczym jest fakt, że poszczególne rodziny algorytmów klasyfikacji charakteryzują się fundamentalnie odmiennymi założeniami matematycznymi i różną wrażliwością na jakość danych. Podczas gdy modele zespołów drzew decyzyjnych bazują na niezmienniczych podziałach relacyjnych, to klasyfikatory probabilistyczne (np. Gaussian Naive Bayes) oraz sieci neuronowe optymalizowane gradientowo (MLP) są skrajnie podatne na deformacje rozkładów i brak standaryzacji cech. Dodatkowo, powszechnym błędem w praktycznych realizacjach jest niewłaściwa kolejność transformacji oraz wyciek informacji (ang. *data leakage*) pomiędzy podzbiorami uczącymi a testowymi.

Zrozumienie interakcji pomiędzy konkretnymi technikami czyszczenia danych a odpornością poszczególnych architektur klasyfikatorów w warunkach kontrolowanej, narastającej degradacji danych stanowi główną motywację do podjęcia badań w niniejszej pracy.

1.2 Cel pracy

Głównym celem niniejszej pracy magisterskiej jest empiryczne zbadanie i ilościowa ocena wpływu wybranych metod czyszczenia danych na jakość predykcyjną oraz stabilność czterech reprezentatywnych algorytmów klasyfikacji tabelarycznej w warunkach kontrolowanego stopnia zanieczyszczenia zbiorów.

Cel główny realizowany jest poprzez następujące cele szczegółowe:

1. Zaprojektowanie i implementacja modułowego potoku przetwarzania danych (ang. *preprocessing pipeline*) w języku Python, opartego na recepturach czyszczenia danych [1] i eliminującego ryzyko wycieku informacji (ang. *data leakage*) pomiędzy zbiorem uczącym a testowym.
2. Opracowanie metodyki kontrolowanej, wielostopniowej symulacji zanieczyszczeń (braków danych, wartości odstających oraz szumu kategorycznego) na zróżnicowanych zbiorach danych tabelarycznych.
3. Porównanie efektywności elementarnych strategii czyszczenia danych (imputacji statystycznej, imputacji sąsiedztwa k -NN, filtracji wartości odstających regułą $3,0 \cdot \text{IQR}$, standaryzacji z -score oraz bezpiecznego kodowania zmiennych kategorycznych) oraz ich sekwencyjnych złożań.
4. Przeprowadzenie analizy wrażliwości poszczególnych architektur klasyfikatorów (GaussianNB, MLP, Random Forest, XGBoost) na narastający stopień degradacji danych wejściowych.

1.3 Główne pytania i zagadnienia badawcze

W ramach realizacji pracy sformułowano kluczowe pytania badawcze, na które odpowiedzi poszukiwano w toku eksperymentów:

1. **Wpływ potoków czyszczących na jakość klasyfikacji:** W jakim stopniu zastosowanie wieloetapowego potoku przygotowania danych (filtracja wartości odstających, imputacja braków, standaryzacja) pozwala ograniczyć spadek jakości modeli przy narastającym poziomie uszkodzeń danych (od 10% do 50%)?
2. **Wrażliwość różnych architektur klasyfikatorów:** Jak poszczególne rodziny modeli (modele zespołowe oparte na drzewach, sieci neuronowe MLP oraz Naiwny Klasyfikator Bayesa) reagują na obecność zanieczyszczeń i które z nich zyskują najwięcej na wdrożeniu czyszczenia danych?

3. **Wybór metody imputacji oraz kolejność operacji:** Czy zaawansowana imputacja wielowymiarowa (k -NN) przynosi zauważalną przewagę nad prostą imputacją medianą oraz jak wcześniejsze usunięcie wartości odstających wpływa na poprawność wypełniania braków?

1.4 Zakres pracy

Zakres zrealizowanych prac obejmuje:

- Przegląd literatury naukowej oraz współczesnych technik czyszczenia danych tabelarycznych w języku Python ze szczególnym uwzględnieniem podejścia recepturowego [1].
- Przygotowanie pięciu zróżnicowanych zbiorów danych: zbioru pacjentów z układowym zapaleniem naczyń (*Zapalenia naczyń*), diagnostyki kardiologicznej (*Serce*), predykcji cukrzycy (*Diabetes*), odpływu klientów telekomunikacyjnych (*Rezygnacje*) oraz ryzyka kredytowego (*Kredyty*).
- Implementację własnych klas transformatorów zgodnych ze standardem scikit-learn: detektora ekstremalnych wartości odstających `OutlierToNaNTransformer` (opartego na rozstępie IQR z mnożnikiem 3.0) oraz filtru rzadkich kategorii `RareCategoryToNaNTransformer`.
- Zbudowanie potoków przetwarzania implementujących 7 strategii czyszczenia danych: *raw*, *fill*, *fill_knn*, *remove_fill*, *fill_norm* oraz pełnych potoków *all* i *all_knn*.
- Przeprowadzenie wielokrotnej powtarzanej stratyfikowanej walidacji krzyżowej (*Repeated Stratified K-Fold*) z rejestracją średniej wartości pola pod krzywą ROC ($\overline{\text{AUC}}$) oraz odchylenia standardowego (σ_{AUC}).

1.5 Struktura pracy

Praca została podzielona na pięć rozdziałów:

- **Rozdział 1 (Cel, zakres i motywacja pracy)** zawiera nakreślenie motywacji, sformułowanie głównego problemu badawczego, cel i zakres zrealizowanych prac oraz postawione pytania badawcze.
- **Rozdział 2 (Część teoretyczna)** traktuje o problemach jakości danych tabelarycznych w ujęciu Walkera [1], formalnych podstawach matematycznych metod czyszczenia (w tym regule IQR i algorytmie Isolation Forest), architekturze badanych modeli klasyfikacyjnych oraz metrykach ewaluacji i testach statystycznych.

- **Rozdział 3 (Środowisko i zbiory danych)** omawia wykorzystane technologie i biblioteki języka Python, szczegółową charakterystykę pięciu badanych zbiorów danych, metodykę symulacji zanieczyszczeń, architekturę modularnych potoków przetwarzania oraz pseudokod własnych klas transformatorów.
- **Rozdział 4 (Wyniki eksperymentów)** poświęcony jest prezentacji oraz szczegółowej analizie uzyskanych rezultatów. Przedstawiono w nim wykresy odporności modeli, tabele wyników empirycznych, teoretyczną interpretację zróżnicowanej odporności badanych architektur, heatmapy zysku ΔAUC , porównanie mediany z algorytmem k -NN oraz formalną weryfikację istotności statystycznej z Diagramem Różnic Krytycznych Demšara.
- **Rozdział 5 (Podsumowanie i wnioski)** stanowi syntezę przeprowadzonych badań, zestawienie głównych wniosków z eksperymentów oraz wskazanie perspektyw dalszego rozwoju projektu.

Rozdział 2

Część teoretyczna

2.1 Taksonomia problemów jakości danych tabelarycznych

Współczesna analiza danych tabelarycznych oraz uczenie maszynowe opierają się na założeniu, że zbiór uczący w sposób wierny odzwierciedla rozkład badanego zjawiska w populacji generalnej. W warunkach rzeczywistych dane wejściowe są jednak obarczone licznymi zniekształceniami. Jak wskazuje Walker [1], błędy te można podzielić na trzy fundamentalne kategorie: braki danych, zaburzenia rozkładów wywołane obserwacjami odstającymi oraz niespójności skali i reprezentacji kategorycznej.

2.1.1 Mechanizmy powstawania braków danych

W teorii statystyki, sformułowanej pierwotnie przez Donalda Rubina [3], wyróżnia się trzy podstawowe mechanizmy generowania braków danych:

1. **MCAR (ang. *Missing Completely at Random*)**: braki całkowicie losowe. Prawdopodobieństwo wystąpienia braku w danej zmiennej nie zależy ani od wartości samej zmiennej, ani od wartości jakichkolwiek innych atrybutów w zbiorze:

$$P(M \mid Y_{\text{obs}}, Y_{\text{mis}}) = P(M), \quad (2.1)$$

gdzie M jest binarną macierzą wskaźnikową braków, Y_{obs} oznacza wartości zaobserwowane, a Y_{mis} wartości brakujące.

2. **MAR (ang. *Missing at Random*)**: braki losowe warunkowo. Prawdopodobieństwo braku zależy od innych zaobserwowanych zmiennych, lecz nie od samej wartości brakującej:

$$P(M \mid Y_{\text{obs}}, Y_{\text{mis}}) = P(M \mid Y_{\text{obs}}). \quad (2.2)$$

Przykładem jest sytuacja, w której częstość braków w wynikach badań laboratoryjnych zależy od wieku pacjenta lub płci.

3. **MNAR (ang. *Missing Not at Random*)**: braki nielosowe. Prawdopodobieństwo wystąpienia braku zależy bezpośrednio od niezaobserwowanej wartości (np. pacjenci z bardzo wysokim poziomem bólu częściej odmawiają udziału w badaniu).

Wybór odpowiedniej procedury imputacji musi uwzględniać powyższy charakter zjawiska, aby nie doprowadzić do zniekształcenia kowariancji cech [3, 1].

2.1.2 Wartości odstające i błędy grube

Wartości odstające (ang. *outliers*) to obserwacje, które w sposób drastyczny odbiegają od wzorca wyznaczonego przez przeważającą część zbioru. Mogą one wynikać z:

- **Błędów grubych aparatury i zapisu**: pomyłki jednostek (np. gramy zamiast miligramów), błędy wprowadzania danych z klawiatury (np. przesunięcie przecinka dziesiętnego), usterki czujników.
- **Naturalnej zmienności ekstremalnej**: rzadkie, lecz rzeczywiste przypadki kliniczne (np. pacjenci z ekstremalnym nasileniem wskaźników stanu zapalnego).

Obecność obserwacji odstających silnie zaburza nieodporne estymatory statystyczne. Przykładowo, średnia arytmetyczna $\hat{\mu}$ oraz wariancja próbkowa $\hat{\sigma}^2$ charakteryzują się zerowym punktem załamania (ang. *breakdown point* $\epsilon^* = 0$, wg teorii statystyki odpornej Hubera [4]), co oznacza, że pojedyncza skrajna wartość może dowolnie zmienić ich oszacowanie. Z kolei estymatory odporne, takie jak mediana czy rozstęp międzykwartylowy, zachowują stabilność przy obecności do 50% zaburzonych obserwacji [4, 1].

2.2 Metody wstępnego przetwarzania i czyszczenia danych

2.2.1 Uzupełnianie braków danych (Imputacja)

W praktyce inżynierii danych wyróżnia się podejścia proste (statystyczne) oraz zaawansowane (uczące się):

1. **Imputacja statystyczna**: zastąpienie braków wartością syntetyczną wyznaczoną globalnie na zbiorze uczącym:
 - dla cech ciągłych: mediana $\text{Med}(X)$ próby (bezpieczniejsza od średniej przy rozkładach skośnych) [1],
 - dla cech kategorycznych: dominanta (moda), czyli najczęściej występująca kategoria.

2. **Imputacja sąsiedztwa (KNNImputer)**: wielowymiarowa metoda estymacji braków bazująca na algorytmie k -najbliższych sąsiadów [17]. Dla dwóch obserwacji x, y , w których część cech może brakować, odległość euklidesowa z maskowaniem wyznaczana jest ze wzoru:

$$d(x, y) = \sqrt{\frac{p}{p_{\text{wspólne}}} \sum_{i \in \text{wspólne}} (x_i - y_i)^2}, \quad (2.3)$$

gdzie p to całkowita liczba cech, a $p_{\text{wspólne}}$ to liczba cech obserwowanych w obu rekordach jednocześnie. Brakująca wartość w rekordzie x jest następnie estymowana jako średnia ważona z k najbardziej podobnych rekordów:

$$\hat{x}_j = \frac{\sum_{m \in N_k(x)} w_m \cdot y_{m,j}}{\sum_{m \in N_k(x)} w_m}, \quad w_m = \frac{1}{d(x, y_m)}. \quad (2.4)$$

2.2.2 Identyfikacja i obsługa wartości odstających

W pracy zaimplementowano regułę rozstępu międzykwartylowego (IQR) zaproponowaną przez Johna Tukeya [2]. Kwartyle Q_1 i Q_3 dzielą uporządkowany ciąg danych na cztery równe części, a rozstęp międzykwartylowy definiowany jest jako:

$$\text{IQR} = Q_3 - Q_1. \quad (2.5)$$

W klasycznym podejściu Tukeya [2] wyróżnia się:

- anomalie umiarkowane: $x \notin [Q_1 - 1,5 \cdot \text{IQR}, Q_3 + 1,5 \cdot \text{IQR}]$,
- anomalie ekstremalne: $x \notin [Q_1 - 3,0 \cdot \text{IQR}, Q_3 + 3,0 \cdot \text{IQR}]$.

Zgodnie z recepturami Walkera [1], w niniejszej pracy zastosowano próg $3,0 \cdot \text{IQR}$, aby odfiltrować wyłącznie bezdyskusyjne błędy grube i anomalie skrajne. Zamiast agresywnego usuwania całych rekordów (co prowadzi do utraty cennych informacji w pozostałych poprawnych kolumnach), zaimplementowany transformator `OutlierToNaNTransformer` zamienia wykryte outliery na wartości NaN, umożliwiając ich późniejszą poprawną rekonstrukcję w module imputacji.

Do metod wielowymiarowej detekcji anomalii należy algorytm **Isolation Forest** [7]. Metoda ta buduje zespół losowych drzew decyzyjnych (*iTrees*). Punkty odstające, jako rzadkie i odizolowane, wymagają znacznie mniejszej liczby podziałów do ich wyodrębnienia. Wskaźnik anomalii dla obserwacji x definiowany jest jako:

$$s(x, n) = 2^{-\frac{\mathbb{E}(h(x))}{c(n)}}, \quad (2.6)$$

gdzie $h(x)$ to długość ścieżki w drzewie, $\mathbb{E}(h(x))$ to średnia długość ścieżki w zespole, a $c(n) = 2 \ln(n-1) + 1,1544 - \frac{2(n-1)}{n}$ jest średnią długością ścieżki nieudanego wyszukiwania w drzewie BST dla n obserwacji. Wartość $s \rightarrow 1$ jednoznacznie identyfikuje anomalię [7]. Algorytm Isolation Forest stanowi teoretyczną alternatywę dla jednowymiarowej reguły IQR; w niniejszej pracy zdecydowano się jednak na regułę IQR jako metodę deterministyczną, w pełni interpretowalną i bezpośrednio integrującą się z potokiem scikit-learn bez dodatkowego strojenia hiperparametrów (takich jak liczba drzew czy stopień zanieczyszczenia próbki).

2.2.3 Skalowanie atrybutów i kodowanie zmiennych jakościowych

1. **Standaryzacja z -score**: przekształca zmienną losową do postaci o zerowej średniej i jednostkowej wariancji:

$$z = \frac{x - \mu}{\sigma}, \quad (2.7)$$

gdzie parametry μ, σ są wyznaczone wyłącznie na próbce uczącej.

2. **Skalowanie min-max**: mapuje wartości do zamkniętego przedziału $[0, 1]$:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}. \quad (2.8)$$

3. **Kodowanie One-Hot (OneHotEncoder)**: przekształca cechę kategoriową o C unikalnych poziomach w C binarnych wektorów wskaźnikowych. W celu uniknięcia problemu rzadkich kategorii wprowadzono transformator RareCategoryToNaNTransformer, który kategorie o częstości występowania poniżej progu 5% konwertuje do postaci braków danych przed etapem kodowania.

2.3 Wybrane algorytmy klasyfikacji

2.3.1 Naiwny Klasyfikator Bayesa (Gaussian Naive Bayes)

Naiwny Klasyfikator Bayesa opiera się na bezpośrednim zastosowaniu twierdzenia Bayesa przy założeniu warunkowej niezależności cech $x_1, \dots, x_p$ względem zmiennej decyzyjnej $y \in \{0, 1\}$ [17]:

$$P(y = c | x) = \frac{P(y = c) \prod_{j=1}^p P(x_j | y = c)}{P(x)}. \quad (2.9)$$

W wariancie GaussianNB zakłada się, że rozkład warunkowy każdej cechy ciągłej jest rozkładem normalnym:

$$P(x_j | y = c) = \frac{1}{\sqrt{2\pi\sigma_{jc}^2}} \exp\left(-\frac{(x_j - \mu_{jc})^2}{2\sigma_{jc}^2}\right). \quad (2.10)$$

Parametry μ_{jc} i σ_{jc}^2 estymowane są za pomocą średniej i wariancji próbkowej. W konsekwencji obecność nieodfiltrowanych wartości odstających drastycznie zniekształca parametry gęstości prawdopodobieństwa, powodując załamanie zdolności predykcyjnej klasyfikatora.

2.3.2 Perceptron Wielowarstwowy (MLP)

MLP (ang. *Multilayer Perceptron*) to sieć neuronowa o architekturze jednokierunkowej, uczona z nadzorem [17]. Dla pojedynczego neuronu w warstwie ukrytej sygnał wyjściowy wyznaczany jest jako:

$$a = f\left(\sum_{j=1}^p w_j x_j + b\right), \quad (2.11)$$

gdzie w_j oznaczają wagi połączeń, b to obciążenie (bias), a $f(\cdot)$ jest nieliniową funkcją aktywacji (np. ReLU: $f(s) = \max(0, s)$).

Proces uczenia polega na minimalizacji funkcji straty (entropii krzyżowej dla klasyfikacji binarnej):

$$\mathcal{L}(w, b) = -\frac{1}{N} \sum_{i=1}^N [y_i \ln \hat{y}_i + (1 - y_i) \ln(1 - \hat{y}_i)] + \frac{\alpha}{2} \|w\|_2^2, \quad (2.12)$$

za pomocą algorytmu optymalizacji opartego na gradientach (Adam [8]). Brak standaryzacji cech wejściowych prowadzi do złego uwarunkowania macierzy drugich pochodnych (hesjanu), co wywołuje zjawisko oscylacji gradientu i uniemożliwia zbieżność procesu uczenia.

2.3.3 Lasy Losowe (Random Forest)

Algorytm Lasów Losowych, opracowany przez Leo Breimana [5], stanowi zespół wielu drzew decyzyjnych uczonych metodą agregacji bootstrapowej (bagging). Każde drzewo T_b budowane jest na niezależnej próbie losowej ze zwracaniem $D_b \subset D$. W każdym węźle drzewa optymalny podział wyznaczany jest wyłącznie spośród losowo wybranego podzbioru $m \approx \sqrt{p}$ cech.

Kryterium oceny jakości podziału węzła stanowi zanieczyszczenie Giniego (ang. *Gini Impurity*):

$$I_G(t) = 1 - \sum_{k=1}^K p_k^2, \quad (2.13)$$

gdzie p_k to frakcja obserwacji klasy k w węźle t . Ponieważ decyzje podziału w drzewach decyzyjnych zależą wyłącznie od porządku relacyjnego wartości atrybutu ($x_j \leq \theta$), Lasy Losowe są całkowicie niewrażliwe na monotoniczne transformacje i brak standaryzacji cech [5].

2.3.4 XGBoost (Extreme Gradient Boosting)

XGBoost [6] jest algorytmem sekwencyjnego wzmacniania gradientowego. W odróżnieniu od baggingu, każde kolejne drzewo $f_t(x)$ jest dopasowywane do residuów (błędów) popełnionych przez dotychczasowy zespół:

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i). \quad (2.14)$$

Funkcja celu w kroku t przyjmuje postać:

$$\text{Obj}^{(t)} = \sum_{i=1}^N l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t), \quad (2.15)$$

gdzie człon regularyzacyjny drzewa o T liściach i wagach w definiowany jest jako:

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 + \alpha \sum_{j=1}^T |w_j|. \quad (2.16)$$

Stosując rozwinięcie funkcji straty w szereg Taylora drugiego rzędu, otrzymuje się uproszczoną postać celu:

$$\widetilde{\text{Obj}}^{(t)} \approx \sum_{i=1}^N \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t), \quad (2.17)$$

gdzie $g_i = \partial_{\hat{y}^{(t-1)}} l(y_i, \hat{y}^{(t-1)})$ oraz $h_i = \partial_{\hat{y}^{(t-1)}}^2 l(y_i, \hat{y}^{(t-1)})$. Optymalna waga liścia j wynosi:

$$w_j^* = - \frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda}, \quad (2.18)$$

a zysk z podziału węzła na podzbiory I_L i I_R dany jest wzorem:

$$\text{Gain} = \frac{1}{2} \left[\frac{(\sum_{i \in I_L} g_i)^2}{\sum_{i \in I_L} h_i + \lambda} + \frac{(\sum_{i \in I_R} g_i)^2}{\sum_{i \in I_R} h_i + \lambda} - \frac{(\sum_{i \in I} g_i)^2}{\sum_{i \in I} h_i + \lambda} \right] - \gamma. \quad (2.19)$$

2.4 Metryki oceny jakości modeli i aparat statystyczny

2.4.1 Krzywa ROC i pole pod krzywą (AUC)

Krzywa ROC przedstawia zależność pomiędzy czułością (TPR) a odsetkiem fałszywych alarmów (FPR) dla zmiennego progu klasyfikacji $\theta \in [0, 1]$ [9]:

$$\text{TPR}(\theta) = \frac{\text{TP}(\theta)}{\text{TP}(\theta) + \text{FN}(\theta)}, \quad \text{FPR}(\theta) = \frac{\text{FP}(\theta)}{\text{FP}(\theta) + \text{TN}(\theta)}. \quad (2.20)$$

Pole pod krzywą ROC (AUC) posiada jednoznaczną interpretację probabilistyczną: stanowi prawdopodobieństwo, że losowo wybrana obserwacja z klasy pozytywnej otrzyma od modelu wyższą ocenę punktową (score) niż losowo wybrana obserwacja z klasy negatywnej [9, 10]:

$$\text{AUC} = P(\hat{y}(x^+) > \hat{y}(x^-)). \quad (2.21)$$

Wartość AUC jest ściśle równoważna znormalizowanej statystyce Manna-Whitneya U [10]:

$$\text{AUC} = \frac{U}{n^+ \cdot n^-} = \frac{R^+ - \frac{n^+(n^++1)}{2}}{n^+ \cdot n^-}, \quad (2.22)$$

gdzie R^+ oznacza sumę rang przypisanych obserwacjom pozytywnym.

2.4.2 Nieparametryczne testy istotności statystycznej

W celu rzetelnego porównania metod czyszczenia danych zastosowano nieparametryczne testy rangowe:

1. **Test rangowy znaków Wilcoxona** [11]: nieparametryczny odpowiednik testu t -Studenta dla prób zależnych. Dla par wyników (x_i, y_i) oblicza się różnice $d_i = x_i - y_i$, a następnie porządkuje ich wartości bezwzględne, przypisując im rangi R_i . Statystyka testowa wynosi:

$$W = \min(W^+, W^-), \quad W^+ = \sum_{d_i > 0} R_i, \quad W^- = \sum_{d_i < 0} R_i. \quad (2.23)$$

2. **Test Friedmana** [12]: wielogrupowy test rangowy do weryfikacji hipotezy o braku różnic pomiędzy k metodami ewaluowanymi na N zbiorach prób. Statystyka testowa ma postać:

$$\chi_F^2 = \frac{12N}{k(k+1)} \left[\sum_{j=1}^k \bar{R}_j^2 - \frac{k(k+1)^2}{4} \right], \quad (2.24)$$

gdzie $\bar{R}_j$ to średnia ranga j -tej metody.

Rozdział 3

Środowisko i zbiory danych

Rozdział ten poświęcony jest elementom definiującym środowisko programistyczne, wykorzystane narzędzia oraz szczegółowej charakterystyce badanych zbiorów danych. W pierwszej kolejności przedstawiono wykorzystane biblioteki języka Python, następnie omówiono parametry i atrybuty każdego z pięciu zbiorów, a w dalszej części opisano metodologię symulacji kontrolowanych zanieczyszczeń oraz architekturę modularnego potoku przetwarzania danych.

3.1 Wykorzystane narzędzia i biblioteki

Całość prac badawczo-implementacyjnych zrealizowano w języku programowania **Python** (wersja 3.10+), stanowiącym obecnie dominujący standard w inżynierii danych i uczeniu maszynowym [1]. W projekcie wykorzystano wyspecjalizowany zestaw bibliotek open-source:

- **Pandas** [19] (wersja 2.x) – wykorzystywana do profilowania danych, identyfikacji brakujących pól, konwersji typów zmiennych oraz operacji tabelarycznych,
- **NumPy** [20] – zapewniająca wydajne operacje macierzowe oraz funkcje losowania pseudolosowego z użyciem generatora `default_rng`,
- **scikit-learn** [17] – główny szkielet eksperymentalny; posłużyła do implementacji klasyfikatorów (`GaussianNB`, `MLPClassifier`, `RandomForestClassifier`), procedur podziału stratyfikowanego (`StratifiedKFold`), transformatorów czyszczących (`SimpleImputer`, `KNNImputer`, `StandardScaler`, `OneHotEncoder`) oraz obiektów potokowych (`Pipeline`, `ColumnTransformer`),
- **XGBoost** [6, 18] – wysoce zoptymalizowana implementacja algorytmu Extreme Gradient Boosting zintegrowana ze standardem interfejsu `scikit-learn`,

- **Joblib** [21] – biblioteka służąca do zrównoleglenia powtarzanych procedur walidacji krzyżowej na wielordzeniowych jednostkach obliczeniowych CPU,
- **Matplotlib** [14] oraz **Seaborn** [15] – narzędzia graficzne zastosowane do automatycznego generowania krzywych odporności modeli, macierzy korelacji oraz heat-map zysku ΔAUC .

3.2 Charakterystyka badanych zbiorów danych

W badaniach empirycznych wykorzystano pięć zróżnicowanych zbiorów danych tabelarycznych, reprezentujących odmienne domeny zastosowań (medycyna kliniczna, diagnostyka kardiologiczna, telekomunikacja, bankowość). Taki dobór danych pozwolił na weryfikację zachowania metod czyszczenia zarówno na zbiorach o dominacji cech ciągłych, jak i silnie wymieszanych z atrybutami kategorycznymi, a także przy różnym stopniu zrównoważenia klas decyzyjnych. Zbiorcze zestawienie parametrów zbiorów przedstawiono w tabeli 3.1.

Tabela 3.1: Zbiorcze zestawienie charakterystyki badanych zbiorów danych

Zbiór danych	Liczba prób	Liczba cech	Cechy ciągłe	Cechy kateg.	Balans klas (0 / 1)
Zapalenia naczyń	848	143	15	128	702 / 146 (82,8% / 17,2%)
Serce (Heart)	270	13	5	8	150 / 120 (55,6% / 44,4%)
Cukrzyca (Diabetes)	768	8	8	0	500 / 268 (65,1% / 34,9%)
Rezygnacje (Churn)	3333	19	15	4	2850 / 483 (85,5% / 14,5%)
Kredyty (German)	1000	10	3	7	700 / 300 (70,0% / 30,0%)

3.2.1 Zbiór „Zapalenia naczyń” (Vasculitis)

Zbiór ten obejmuje rzeczywiste dane kliniczne pacjentów diagnozowanych i leczonych z powodu układowych zapaleń naczyń (ang. *systemic vasculitis*). Zadaniem klasyfikacyjnym jest predykcja binarnej zmiennej decyzyjnej Zgon (0 – przeżycie pacjenta, 1 – zgon). Zgodnie z recepturami wstępnego profilowania danych [1], wykluczono techniczny identyfikator pacjenta (Kod). Pozostałe 143 atrybuty wejściowe obejmują:

- **Wskaźniki ciągłe (15 cech):** wiek pacjenta w latach (Wiek), wiek w chwili postawienia diagnozy (Wiek_rozpoznania), czas opóźnienia rozpoznania (Opoznienie_Rozpoznania), wskaźnik palenia tytoniu w paczkoletach (Paczkoleta), liczba narządów objętych aktywnym procesem chorobowym (Liczba_Zajetych_Narzadow), liczba zaostrzeń choroby (Liczba_Zaostrzen), czas do wystąpienia pierwszego zaostrzenia (Czas_Pierwsze_Zaostrzenie),

stężenie kreatyniny w surowicy (Kreatynina), maksymalne stężenie białka C-reaktywnego (Max_CRP), łączne dawki glikokortykosteroidów (Sterydy_Dawka_g, Sterydy_Dawka_mg), całkowity czas trwania sterydoterapii (Czas_Sterydow) oraz miana przeciwciał i markerów immunologicznych (Anti-PR3_Wartosc, Anti-MPO_Wartosc, Eozynofilia_Krwi_Obwodowej_Wartosc).

- **Wskaźniki jakościowe i binarne (128 cech):** płeć, specyficzne rozpoznania kliniczne (np. GPA, EGPA, MPA, choroba Takayasu, choroba Kawasaki), manifestacje narządowe (płucne, sercowo-naczyniowe, nerkowe, laryngologiczne, ośrodkowego układu nerwowego), wyniki biopsji tkankowych oraz schematy farmakoterapii (cyklofosfamid, rituximab, mykofenolan mofetylu, azatiopryna, metotreksat).

3.2.2 Zbiór „Serce” (Heart Disease)

Klasyczny zbiór referencyjny pochodzący ze zbiorów UCI Machine Learning Repository [16] (baza Statlog/Cleveland). Zadaniem jest rozpoznanie obecności istotnych zmian miażdżycowych w naczyniach wieńcowych (diagnoza: 0 – brak choroby, 1 – choroba serca). Zbiór zawiera 13 cech diagnostycznych:

- **Cechy ciągłe (5 atrybutów):** wiek pacjenta (wiek), spoczynkowe ciśnienie tętnicze krwi (cisnienie_krwi_spoczynek), stężenie cholesterolu całkowitego w surowicy (cholesterol_we_krwi), maksymalna częstość akcji serca osiągnięta w trakcie próby wysiłkowej (ilosc_uderzen_serca) oraz obniżenie odcinka ST wywołane wysiłkiem fizycznym (max_obnizka_st).
- **Cechy kateryczne (8 atrybutów):** płeć (plec), typ dolegliwości bólowych w klatce piersiowej (typ_bolu_klatka), stężenie glukozy na czczo powyżej 120 mg/dl (cukier_we_krwi), spoczynkowy wynik elektrokardiogramu (wynik_ekg_spoczynek), dławica piersiowa wywołana wysiłkiem (bol_klatka_wysilek), nachylenie odcinka ST na szczycie wysiłku (przebieg_st_szczyt), liczba głównych naczyń zabarwionych podczas fluoroskopii (zwapnienia_miazzdzycowe) oraz wynik scyntygrafii perfuzyjnej mięśnia sercowego (proba_ta).

3.2.3 Zbiór „Diabetes” (Pima Indians Diabetes)

Zbiór pochodzący z repozytorium UCI [16], służący do prognozowania wystąpienia cukrzycy u kobiet z populacji Indian Pima na podstawie parametrów fizjologicznych i biochemicznych. Zmienna celu (decision) przyjmuje wartości binarne (0 – brak cukrzycy, 1 – potwierdzona cukrzyca). Wszystkie 8 atrybutów wejściowych ma charakter ciągły:

- liczba przebytych ciąż (preg),

- stężenie glukozy w osoczu krwi po doustnym teście tolerancji glukozy (`plas`),
- rozkurczowe ciśnienie tętnicze krwi (`pres`),
- grubość fałdu skórno-tłuszczowego na mięśniu trójgłowym ramienia (`skin`),
- 2-godzinne stężenie insuliny w surowicy (`insu`),
- wskaźnik masy ciała BMI (`mass`),
- wskaźnik obciążenia genetycznego rodowodem cukrzycy (`pedi`),
- wiek pacjentki w latach (`age`).

3.2.4 Zbiór „Rezygnacje” (Customer Churn)

Zbiór danych pochodzący z sektora telekomunikacyjnego, wykorzystywany do detekcji zjawiska migracji klientów (ang. *customer churn*). Zadaniem klasyfikacyjnym jest predykcja binarnej decyzji klienta o rezygnacji z usług operatora (REZYGN: 0 – lojalny klient, 1 – odejście do konkurencji). Po wykluczeniu numeru telefonu klienta (NR_TEL), zestaw zawiera:

- **Cechy ciągłe (15 atrybutów):** czas trwania umowy w miesiącach (CZAS_POSIADANIA), liczba odsłuchanych wiadomości poczty głosowej (L_WIAD_PO CZTA_G), łączna liczba minut, liczba połączeń oraz naliczona opłata w strefie dziennej (DZIEN_MIN, DZIEN_L_POL, DZIEN_OPLATA), strefie wieczornej (WIECZOR_MIN, WIECZ_L_POL, WIECZ_OPLATA), strefie nocnej (NOC_MIN, NOC_L_POL, NOC_OPLATA), strefie połączeń międzynarodowych (MIEDZY_MIN, MIEDZY_L_POL, MIEDZY_OPLATA) oraz liczba kontaktów z biurem obsługi klienta (L_POL_BIURO).
- **Cechy kateryczne (4 atrybuty):** kod stanu zamieszkania (STAN), numer kierunkowy obszaru (KOD_OBSZARU), aktywność międzynarodowego planu taryfowego (PLAN_MIEDZY) oraz aktywność usługi poczty głosowej (POCZTA_G).

3.2.5 Zbiór „Kredyty” (German Credit)

Klasyczny zbiór oceny ryzyka kredytowego (ang. *credit scoring*) z repozytorium UCI [16] (Statlog German Credit). Zadaniem jest klasyfikacja wiarygodności finansowej klienta wnioskującego o pożyczkę (Kredyt: good $\rightarrow$ 0 – niski poziom ryzyka, bad $\rightarrow$ 1 – wysokie ryzyko niewypłacalności). Zbiór charakteryzuje się silną obecnością atrybutów jakościowych:

- **Cechy ciągłe (3 atrybuty):** czas trwania bieżącego rachunku lub wnioskowanej pożyczki w miesiącach ($Czas_trwania_konta$), całkowita kwota wnioskowanego kredytu ($Kwota_kredytu$) oraz wiek klienta w latach ($Wiek$).
- **Cechy kategoryczne (7 atrybutów):** deklarowany cel pożyczki ($Cel_kredytu$), staż pracy i czas zatrudnienia ($Czas_zatrudnienia$), płeć powiązana ze stanem cywilnym ($Plec_i_stan_cywilny$), czas zamieszkiwania pod obecnym adresem ($Czas_od_zamieszkania$), liczba spłacanych kredytów w banku ($Liczba_kredytow_w_banku$), status zawodowy ($Praca$) oraz liczba osób pozostających na utrzymaniu pożyczkobiorcy ($Liczb_osob_na_utrzymaniu$).

3.3 Metodologia symulacji kontrolowanych zanieczyszczeń

W celu rzetelnej, ilościowej oceny skuteczności poszczególnych receptur czyszczenia danych, zbiory oryginalne poddano kontrolowanej procedurze sztucznego wprowadzania zaburzeń. W eksperymentach zdefiniowano pięć rosnących poziomów degradacji: $p \in \{10\%, 20\%, 30\%, 40\%, 50\%\}$. Każdy poziom generowano w 3 niezależnych powtórzeniach losowych z wykorzystaniem generatora liczb pseudolosowych `numpy.random.default_rng`.

Zgodnie z systematyką problemów jakości danych opisaną przez Walkera [1], wprowadzono trzy typy zanieczyszczeń:

1. **Braki danych (ang. *missing data*):** losowe usuwanie wartości w kolumnach z prawdopodobieństwem p , zastępując je wartością NaN (symulacja mechanizmu braków całkowicie przypadkowych MCAR).
2. **Ekstremalne wartości odstające (ang. *extreme outliers*):** losowy wybór obserwacji w liczbie proporcjonalnej do poziomu degradacji i ich modyfikacja poprzez drastyczne mnożniki:

$$x_{dirty} = x \cdot c, \quad c \in \{20, 40, 80, -20\}. \quad (3.1)$$

Zabieg ten odzwierciedla błędy grube aparatury pomiarowej, pomyłki skali lub błędne jednostki metryczne [1].

3. **Szum w zmiennych kategorycznych:** losowe wstrzykiwanie rzadkiej, nieprawidłowej wartości "9", symulującej błędne kody kategorii lub usterki systemów ankietowych.

3.4 Architektura potoku przetwarzania i uzasadnienie doboru strategii

Wszystkie operacje przetwarzania danych zorganizowano w postaci modularnych obiektów Pipeline oraz ColumnTransformer z biblioteki `scikit-learn`. Podejście to, rekomendowane przez Walkera [1], gwarantuje całkowitą hermetyzację transformacji, ponieważ parametry czyszczenia (progi IQR, mediany, średnie, parametry skalarów) są wyznaczane wyłącznie w fazie `fit` na podzbiorze uczącym, a następnie aplikowane do podzbioru testowego (`transform`), co eliminuje błąd wycieku danych (*data leakage*).

3.4.1 Trzy filary przetwarzania wstępnego

W badaniach nad jakością klasyfikatorów tabelarycznych wyodrębniono trzy fundamentalne operacje inżynierii danych:

1. O_1 (**Eliminacja i obsługa wartości odstających**): identyfikacja anomalii regułą rozstępu międzykwartylowego ($3 \cdot \text{IQR}$) i ich konwersja do braków danych (NaN) przy użyciu własnej klasy transformatora `OutlierToNaNTransformer`.
2. O_2 (**Imputacja braków danych**): rekonstrukcja wartości brakujących za pomocą estymatorów statystycznych (mediana/dominanta) lub algorytmu k -najbliższych sąsiadów (`KNNImputer`, $k = 5$).
3. O_3 (**Standaryzacja i kodowanie cech**): przekształcenie z -score ($\mu = 0, \sigma = 1$) za pomocą `StandardScaler` oraz binarne kodowanie cech kategoriowych (`OneHotEncoder`) po uprzedniej filtracji rzadkich poziomów (`RareCategoryToNaNTransformer`).

3.4.2 Implementacja własnych transformatorów w standardzie `scikit-learn`

Standardowa biblioteka `scikit-learn` nie zawiera wbudowanych modułów do selektywnego maskowania anomalii bez usuwania całych wierszy z macierzy danych. Aby zintegrować regułę IQR oraz filtrację rzadkich kategorii wewnątrz modularnego potoku Pipeline bez ryzyka wycieku danych, zaimplementowano dwie dedykowane klasy transformatorów dziedziczące po `BaseEstimator` oraz `TransformerMixin`.

W listingu 3.1 przedstawiono strukturę algorytmiczną detektora `OutlierToNaNTransformer`. W fazie `fit` klasa wyznacza progi odcięcia na danych treningowych, natomiast w fazie `transform` zamienia wartości przekraczające wyznaczony zakres na NaN.

```

1 Klasa OutlierToNaNTransformer(BaseEstimator, TransformerMixin):
2     Inicjalizacja(numeric_columns, iqr_multiplier = 3.0, min_unique =
3         10):
4         Zapisz parametry konfiguracyjne oraz zainicjalizuj bounds_ = {}
5
6     Metoda fit(X_train):
7         Dla kazdej kolumny numerycznej c w X_train:
8             Jesli liczba unikalnych wartosci w c < min_unique:
9                 Pomin kolumne (traktuj jako ceche dyskretna)
10            Q1 = kwartyl(X_train[c], 0.25)
11            Q3 = kwartyl(X_train[c], 0.75)
12            IQR = Q3 - Q1
13            Jesli IQR > 0:
14                lower = Q1 - iqr_multiplier * IQR
15                upper = Q3 + iqr_multiplier * IQR
16                bounds_[c] = (lower, upper)
17
18     Zwroc self
19
20     Metoda transform(X):
21         Dla kazdej kolumny c w bounds_:
22             lower, upper = bounds_[c]
23             Dla kazdej wartosci x w kolumnie c:
24                 Jesli x < lower lub x > upper:
25                     Ustaw wartosc x = NaN
26
27     Zwroc zmodyfikowana macierz X

```

Listing 3.1: Pseudokod transformatora OutlierToNaNTransformer

Z kolei w listingu 3.2 zaprezentowano pseudokod transformatora RareCategoryToNaNTransformer, którego zadaniem jest identyfikacja anomalnych lub rzadkich etykiet kategoriycznych w fazie uczenia i ich neutralizacja w fazie transformacji.

```

1 Klasa RareCategoryToNaNTransformer(BaseEstimator, TransformerMixin):
2     Inicjalizacja(categorical_columns, min_frequency = 0.05):
3         Zapisz parametry oraz zainicjalizuj valid_categories_ = {}
4
5     Metoda fit(X_train):
6         Dla kazdej kolumny kategoriycznej c w X_train:
7             Oblicz czestosc wystepowania kazdej kategorii w X_train[c]
8             valid_categories_[c] = zbior kategorii o czestosci >=
9                 min_frequency
10
11     Zwroc self
12
13     Metoda transform(X):
14         Dla kazdej kolumny c w valid_categories_:
15             Dla kazdej wartosci x w kolumnie c:

```

```

14         Jesli x nie jest puste i x nie nalezy do
           valid_categories_[c]:
15             Ustaw wartosc x = NaN
16     Zwroc zmodyfikowana macierz X

```

Listing 3.2: Pseudokod transformatora RareCategoryToNaNTransformer

3.4.3 Redukcja pełnego planu czynnikowego ($2^3 = 8$) do zestawu strategii praktycznych

Początkowy plan badawczy zakładał pełny układ kombinatoryczny $2^3 = 8$ metod:

$$\mathcal{S}_{\text{pełny}} = \{\text{raw}, \text{norm}, \text{fill}, \text{remove}, \text{remove_fill}, \text{remove_norm}, \text{fill_norm}, \text{all}\}. \quad (3.2)$$

W toku analizy metodologicznej zidentyfikowano jednak krytyczne wady wariantów pozbawionych kroku imputacji (fill):

- **Problem sztucznej stałej w metodzie remove:** W operacji `remove` wykryte anomalie zamieniane są na NaN. Brak późniejszego etapu rekonstrukcji wymusza zastąpienie braków techniczną wartością stałą (np. $-999,0$), aby umożliwić działanie klasyfikatorów. Procedura ta de facto tworzy nową, skrajną wartość odstającą, negując sens eliminacji anomalii.
- **Zniekształcenie parametrów rozkładu w metodzie norm:** Standaryzacja cech w obecności nieskorygowanych wartości odstających prowadzi do błędnej estymacji średniej $\hat{\mu}$ oraz drastycznego zawyżenia odchylenia standardowego $\hat{\sigma}$. W rezultacie typowe wartości cech ulegają sztucznej kompresji blisko zera.

Z tego względu przestrzeń badawcza została zoptymalizowana i rozszerzona o bezpośrednie porównanie paradygmatów imputacji (statystyczna vs sąsiedztwa KNN), tworząc zestaw 7 komplementarnych strategii badawczych zestawionych w tabeli 3.2.

Tabela 3.2: Zestawienie badanych strategii czyszczenia danych w potokach przetwarzania

Kod strategii	Składowe potoku (Pipeline)	Uzasadnienie i rola badawcza
<code>raw</code>	Brak operacji (maskowanie -999)	Punkt odniesienia (<i>baseline</i>), degradacja bez interwencji.
<code>fill</code>	Imputacja medianą i dominantą	Wpływ samej prostej rekonstrukcji braków.
<code>fill_knn</code>	Imputacja k -NN ($k = 5$)	Wpływ wielowymiarowej rekonstrukcji opartej na sąsiedztwie.
<code>remove_fill</code>	Outliery ($3 \cdot \text{IQR}$) $\rightarrow$ Mediana	Dwuetaпова korekcja: oczyszczenie rozkładu przed imputacją.
<code>fill_norm</code>	Mediana $\rightarrow$ Standaryzacja z -score	Wpływ skalowania na poprawnie zaimputowanych danych.
<code>all</code>	Outliery $\rightarrow$ Mediana $\rightarrow$ Standaryzacja	Pełny klasyczny potok inżynierii danych [1].
<code>all_knn</code>	Outliery $\rightarrow k$ -NN $\rightarrow$ Standaryzacja	Zaawansowany potok łączący filtrację z modelowaniem k -NN.

3.5 Protokół eksperymentalny i parametryzacja klasyfikatorów

W celu uzyskania odpornych i statystycznie istotnych wyników zastosowano procedurę powtarzanej stratyfikowanej walidacji krzyżowej (*Repeated Stratified K-Fold*) z podziałem na 4 lub 5 foldów i ewaluacją na 3–5 niezależnych ziarnach losowości.

Dla każdego podziału ewaluowano 4 klasyfikatory o ustalonej parametryzacji:

- **Random Forest (RF):** `n_estimators=220, random_state=seed`.
- **Gaussian Naive Bayes (NB):** model probabilistyczny z domyślną estymacją parametrów rozkładu normalnego.
- **Perceptron Wielowarstwowy (MLP):** sieć o architekturze z jedną warstwą ukrytą złożoną ze 100 neuronów (aktywacja ReLU, optymalizator Adam, wczesne zatrzymanie `early_stopping=True, n_iter_no_change=15`).
- **XGBoost:** `n_estimators=180, max_depth=4, learning_rate=0.07, subsample=0.9, colsample_bytree=0.9`, funkcja straty `logloss`.

Jako główną miarę ewaluacji przyjęto średnią arytmetyczną pola pod krzywą ROC ($\overline{\text{AUC}}$) oraz odchylenie standardowe σ_{AUC} liczone po wszystkich foldach i powtórzeniach walidacji.

Rozdział 4

Wyniki eksperymentów

Rozdział ten poświęcony jest prezentacji oraz szczegółowej analizie rezultatów przeprowadzonych badań empirycznych, których celem była ocena wpływu 7 strategii czyszczenia danych na jakość i stabilność czterech architektur klasyfikatorów (Random Forest, XGBoost, Gaussian Naive Bayes, MLP). Eksperymenty zrealizowano na 5 zbiorach danych poddanych kontrolowanej degradacji jakości na pięciu poziomach uszkodzeń (10%, 20%, 30%, 40%, 50%) w procedurze wielokrotnej stratyfikowanej walidacji krzyżowej.

Główną miarą oceny jakości predykcji jest pole pod krzywą ROC ($\overline{AUC}$) wraz z odchyleniem standardowym σ_{AUC} , a także zysk predykcyjny definiowany jako różnica względem danych nieoczyszczonych:

$$\Delta AUC = \overline{AUC}_{\text{metoda}} - \overline{AUC}_{\text{raw}}. \quad (4.1)$$

4.1 Wyniki bazowe i ogólna charakterystyka odporności modeli


W tabeli 4.1 zestawiono wyniki bazowe uzyskane na oryginalnych (czystych) zbiorach danych, stanowiące górną granicę skuteczności dla każdego z modeli.

Tabela 4.1: Skuteczność klasyfikatorów ($\overline{AUC} \pm \sigma_{AUC}$) na oryginalnych zbiorach danych


Zbiór danych	Random Forest (RF)	XGBoost	Gaussian NB	MLP (Sieć neuronowa)
Zapalenia naczyń	0,9391 $\pm$ 0,005	0,9363 $\pm$ 0,004	0,8721 $\pm$ 0,003	0,7407 $\pm$ 0,020
Serce (Heart)	0,9075 $\pm$ 0,010	0,8912 $\pm$ 0,010	0,8872 $\pm$ 0,007	0,6132 $\pm$ 0,134
Cukrzyca (Diabetes)	0,8302 $\pm$ 0,001	0,8165 $\pm$ 0,000	0,8149 $\pm$ 0,001	0,6395 $\pm$ 0,040
Rezygnacje (Churn)	0,9143 $\pm$ 0,003	0,9165 $\pm$ 0,004	0,6527 $\pm$ 0,007	0,6874 $\pm$ 0,145
Kredyty (German)	0,6839 $\pm$ 0,003	0,6828 $\pm$ 0,011	0,6316 $\pm$ 0,005	0,4590 $\pm$ 0,013

Najwyższą jakość predykcyjną na czystych danych osiągają modele zespołowe (Random Forest oraz XGBoost), uzyskując na zbiorach medycznych $\overline{AUC} > 0,90$. Naiwny Klasyfikator Bayesa wykazuje stabilne rezultaty rzędu 0,81 – 0,88 na danych medycznych, jednak radzi sobie słabiej w zadaniach o silnych interakcjach nieliniowych (np. zbiór *Rezygnacje*). Z kolei sieć MLP bez zaawansowanego strojenia hiperparametrów osiąga najniższe wartości bazowe oraz charakteryzuje się podwyższoną wariancją wyników (σ_{AUC} do 0,145).

Ogólną dynamikę spadku jakości modeli pod wpływem degradacji danych przedstawiono na rysunkach 4.1 i 4.2, a odpowiadające im zbiorcze wartości liczbowe zestawiono w tabeli 4.2.




(a) Random Forest




(b) XGBoost

Rysunek 4.1: Zagregowane krzywe odporności modeli zespołowych (uśrednione po 5 badanych zbiorach danych)



(a) Gaussian Naive Bayes



(b) MLP (Sieć neuronowa)

Rysunek 4.2: Zagregowane krzywe odporności klasyfikatora Bayesa i sieci MLP (uśrednione po 5 zbiorach danych)

Tabela 4.2: Średnia globalna wartość $\overline{AUC}$ dla wszystkich badanych zbiorów danych i modeli w funkcji poziomu uszkodzeń dla 7 badanych strategii

Poziom uszkodzeń	raw	fill	fill_knn	remove_fill	fill_norm	all	all_knn
10%	0,6936	0,6955	0,6940	0,7432	0,7231	0,7917	0,7919
20%	0,6739	0,6735	0,6690	0,7175	0,7024	0,7676	0,7647
30%	0,6555	0,6556	0,6458	0,6896	0,6778	0,7301	0,7252
40%	0,6252	0,6194	0,6171	0,6458	0,6388	0,6779	0,6729
50%	0,6165	0,6219	0,6112	0,6192	0,6344	0,6428	0,6340

Wykres zbiorczy uwidacznia fundamentalną prawidłowość: brak procedur czyszczących (*raw*, oznaczony linią pomarańczową) prowadzi do gwałtownej degradacji jakości predykcji wszystkich modeli. Zastosowanie pełnego potoku czyszczącego (*all* oraz *all_knn*)

skutecznie hamuje spadek AUC, zachowując najwyższą użyteczność decyzyjną modeli nawet przy 50% stopniu uszkodzenia atrybutów.


4.2 Szczegółowa analiza wyników na poszczególnych zbiorach danych

4.2.1 Ocena na zbiorze „Zapalenia naczyń”


Zbiór kliniczny pacjentów z zapaleniem naczyń charakteryzuje się dużą liczbą cech (143) oraz obecnością kluczowych markerów stanu zapalnego.

Tabela 4.3: Wyniki $\overline{\text{AUC}}$ na zbiorze „Zapalenia naczyń” dla wszystkich poziomów degradacji

Model	Poziom	raw	fill	fill_knn	remove_fill	fill_norm	all	all_knn
RF	10%	0,9096	0,9158	0,9137	0,9080	0,9157	0,9079	0,9096
	20%	0,8900	0,8944	0,8893	0,8873	0,8943	0,8872	0,8853
	30%	0,8819	0,8848	0,8753	0,8549	0,8847	0,8550	0,8565
	40%	0,8557	0,8501	0,8476	0,8213	0,8500	0,8214	0,8234
	50%	0,8314	0,8419	0,8365	0,7853	0,8419	0,7855	0,7723
XGBoost	10%	0,9140	0,9219	0,9198	0,9134	0,9219	0,9134	0,9164
	20%	0,8916	0,8984	0,8929	0,8902	0,8984	0,8902	0,8880
	30%	0,8710	0,8698	0,8616	0,8465	0,8698	0,8465	0,8508
	40%	0,8321	0,8114	0,8147	0,8140	0,8114	0,8140	0,8047
	50%	0,7835	0,8050	0,7928	0,7784	0,8050	0,7784	0,7730
NB	10%	0,6704	0,6695	0,6624	0,8354	0,5833	0,8255	0,8262
	20%	0,6150	0,6145	0,5965	0,7916	0,5945	0,8308	0,8321
	30%	0,6540	0,6542	0,6225	0,7862	0,5821	0,8221	0,8218
	40%	0,6056	0,6050	0,5756	0,7108	0,5952	0,7973	0,7982
	50%	0,5855	0,5846	0,5868	0,5926	0,5664	0,7551	0,7578
MLP	10%	0,6105	0,6445	0,6431	0,5996	0,8758	0,8632	0,8721
	20%	0,5660	0,5692	0,5619	0,5691	0,8526	0,8401	0,8390
	30%	0,5826	0,5854	0,5504	0,5594	0,8343	0,8131	0,8103
	40%	0,5414	0,5136	0,5162	0,5496	0,7965	0,7601	0,7485
	50%	0,5576	0,5556	0,5473	0,5278	0,7212	0,6545	0,6738




(a) Random Forest




(b) XGBoost

Rysunek 4.3: Krzywe odporności modeli zespołowych na zbiorze „Zapalenia naczyń”




(a) Gaussian Naive Bayes



(b) MLP (Sieć neuronowa)

Rysunek 4.4: Krzywe odporności klasyfikatora Bayesa i sieci MLP na zbiorze „Zapalenia naczyń”



Rysunek 4.5: Porównanie skuteczności metod czyszczenia danych wraz ze słupkami błędów na zbiorze „Zapalenia naczyń” przy poziomie uszkodzeń 30%


Wyniki eksperymentalne na zbiorze „Zapalenia naczyń” (Tabela 4.3) jednoznacznie wskazują, że zniekształcenie atrybutów przy braku czyszczenia obniża AUC modelu Random Forest z 0,939 do 0,831 przy uszkodzeniu 50%. Zastosowanie potoku *fill* pozwala odzyskać stabilność (0,842), a w przypadku sieci MLP wdrożenie potoku *fill_norm* podnosi AUC z 0,558 aż do 0,721 (zysk $\Delta AUC = +0,163$).

4.2.2 Ocena na zbiorze „Serce” (Heart Disease)


Zbiór kardiologiczny stanowi reprezentatywny przykład danych o zrównoważonej liczbie cech ciągłych i kategoriycznych (13 atrybutów). Wyniki liczbowe skuteczności klasyfikatorów zestawiono w tabeli 4.4. Dynamikę zachowania modeli oraz szczegółowe porównanie słupkowe przy uszkodzeniu 30% przedstawiono na rysunkach 4.6, 4.7 i 4.8.

Tabela 4.4: Wyniki $\overline{AUC}$ na zbiorze „Serce” dla wszystkich poziomów degradacji

Model	Poziom	raw	fill	fill_knn	remove_fill	fill_norm	all	all_knn
RF	10%	0,8808	0,8767	0,8804	0,8757	0,8768	0,8750	0,8793
	20%	0,8592	0,8466	0,8434	0,8417	0,8466	0,8417	0,8466
	30%	0,8298	0,8192	0,8000	0,7961	0,8197	0,7960	0,7917
	40%	0,7515	0,7124	0,7267	0,6972	0,7117	0,6963	0,7064
	50%	0,7479	0,7427	0,7447	0,7488	0,7428	0,7488	0,7552
XGBoost	10%	0,8544	0,8602	0,8646	0,8543	0,8602	0,8543	0,8571
	20%	0,8367	0,8369	0,8301	0,8280	0,8369	0,8280	0,8264
	30%	0,7970	0,7922	0,7758	0,7755	0,7922	0,7755	0,7679
	40%	0,7254	0,6850	0,7056	0,6862	0,6850	0,6862	0,6829
	50%	0,7349	0,7515	0,7247	0,7529	0,7515	0,7529	0,7435
NB	10%	0,8140	0,8183	0,8192	0,8515	0,8064	0,8515	0,8520
	20%	0,8081	0,7984	0,8021	0,8270	0,7885	0,8270	0,8274
	30%	0,8067	0,7884	0,7923	0,7998	0,7801	0,7998	0,8025
	40%	0,7566	0,7127	0,7165	0,7253	0,7079	0,7259	0,7334
	50%	0,7630	0,7611	0,7687	0,7725	0,7445	0,7664	0,7692
MLP	10%	0,5167	0,5203	0,5237	0,5672	0,8070	0,8499	0,8525
	20%	0,5326	0,5496	0,5237	0,5063	0,7800	0,7984	0,7948
	30%	0,5297	0,5315	0,5042	0,5067	0,7260	0,7506	0,7373
	40%	0,4945	0,5071	0,4887	0,5176	0,5885	0,6382	0,6454
	50%	0,5083	0,5285	0,5067	0,5166	0,6386	0,6533	0,6403




(a) Random Forest




(b) XGBoost

Rysunek 4.6: Krzywe odporności modeli zespołowych na zbiorze „Serce”




(a) Gaussian Naive Bayes



(b) MLP (Sieć neuronowa)

Rysunek 4.7: Krzywe odporności klasyfikatora Bayesa i sieci MLP na zbiorze „Serce”



Rysunek 4.8: Wpływ metod naprawy danych na jakość modeli na zbiorze „Serce” przy poziomie uszkodzeń 30%


Analiza wyników na zbiorze kardiologicznym (Tabela 4.4 oraz Rysunek 4.8) wyraźnie uwidacznia, że prosta imputacja (`fill`) bez normalizacji jest niewystarczająca dla sieci MLP (0,531 przy 30% uszkodzeń), podczas gdy połączenie filtracji outlierów, imputacji i standaryzacji (`all`) podnosi jej jakość do poziomu 0,751. Modele zespołowe (RF i XGBoost) zachowują wysoką skuteczność ($AUC > 0,75$) nawet przy 50% uszkodzeń.

4.2.3 Ocena na zbiorze „Diabetes” (Pima Indians Diabetes)


Zbiór Indian Pima zawiera wyłącznie atrybuty ciągłe o zróżnicowanych rozkładach. Zestawienie wartości $\overline{AUC}$ przedstawiono w tabeli 4.5. Ciągłe krzywe odporności oraz rozkład słupkowy przy uszkodzeniu 30% zilustrowano na rysunkach ?? i 4.11.

Tabela 4.5: Wyniki $\overline{\text{AUC}}$ na zbiorze „Diabetes” dla wszystkich poziomów degradacji

Model	Poziom	raw	fill	fill_knn	remove_fill	fill_norm	all	all_knn
RF	10%	0,7935	0,8016	0,7956	0,8073	0,8016	0,8072	0,8004
	20%	0,7606	0,7698	0,7667	0,7823	0,7699	0,7820	0,7696
	30%	0,7104	0,7201	0,7030	0,7419	0,7202	0,7418	0,7188
	40%	0,6550	0,6777	0,6645	0,6849	0,6774	0,6850	0,6782
	50%	0,6345	0,6306	0,6202	0,6319	0,6312	0,6322	0,6043
XGBoost	10%	0,7887	0,7903	0,7901	0,7947	0,7903	0,7947	0,7904
	20%	0,7677	0,7693	0,7669	0,7756	0,7693	0,7756	0,7597
	30%	0,7303	0,7344	0,7091	0,7433	0,7344	0,7433	0,7117
	40%	0,6696	0,6865	0,6691	0,6986	0,6865	0,6986	0,6649
	50%	0,6566	0,6576	0,6249	0,6600	0,6576	0,6600	0,6153
NB	10%	0,5162	0,5130	0,5035	0,7868	0,5130	0,7868	0,7888
	20%	0,5055	0,4993	0,5120	0,7682	0,4993	0,7682	0,7674
	30%	0,5154	0,5069	0,5217	0,7122	0,5069	0,7122	0,7221
	40%	0,5507	0,5462	0,5521	0,6488	0,5462	0,6488	0,6674
	50%	0,5245	0,5208	0,5295	0,5187	0,5208	0,5187	0,5322
MLP	10%	0,4807	0,4788	0,4804	0,5905	0,5245	0,7719	0,7686
	20%	0,4969	0,4886	0,4944	0,5484	0,4912	0,7468	0,7387
	30%	0,4953	0,4976	0,5088	0,5512	0,5156	0,7157	0,6852
	40%	0,4924	0,4915	0,4918	0,5297	0,4828	0,6454	0,6095
	50%	0,4850	0,4954	0,4964	0,4990	0,4996	0,5014	0,5110




(a) Random Forest




(b) XGBoost

Rysunek 4.9: Krzywe odporności modeli zespołowych na zbiorze „Diabetes”




(a) Gaussian Naive Bayes



(b) MLP (Sieć neuronowa)

Rysunek 4.10: Krzywe odporności klasyfikatora Bayesa i sieci MLP na zbiorze „Diabetes”



Rysunek 4.11: Porównanie skuteczności metod czyszczenia na zbiorze „Diabetes” przy uszkodzeniu 30%


W zbiorze „Diabetes” (Tabela 4.5) brak normalizacji i obecność ekstremalnych wartości odstających prowadzi do całkowitej degradacji sieci MLP ($AUC \approx 0,485$ przy 50% uszkodzeń, co odpowiada klasyfikatorowi losowemu). Wdrożenie potoku *all* przywraca stabilność optymalizacji gradientowej, podnosząc skuteczność sieci do poziomu 0,716 przy 30% uszkodzeń. Z kolei algorytm GaussianNB na danych nieoczyszczonych traci skuteczność z 0,815 do 0,515 na skutek zaburzenia estymacji wariancji przez błędy grube, zyskując aż do 0,787 po odfiltrowaniu anomalii potokiem *remove_fill* lub *all*.

4.2.4 Ocena na zbiorze „Rezygnacje” (Customer Churn)


Zbiór telekomunikacyjny charakteryzuje się dużą próbą ($N = 3333$) i dominacją atrybutów bilingowych. Szczegółowe wartości $\overline{AUC}$ w zależności od metody i poziomu degradacji zestawiono w tabeli 4.6. Odpowiednie wykresy przedstawiono na rysunkach 4.12, 4.13 i 4.14.

Tabela 4.6: Wyniki $\overline{\text{AUC}}$ na zbiorze „Rezygnacje” dla wszystkich poziomów degradacji

Model	Poziom	raw	fill	fill_knn	remove_fill	fill_norm	all	all_knn
RF	10%	0,8577	0,8543	0,8557	0,8349	0,8541	0,8349	0,8367
	20%	0,8122	0,8062	0,7983	0,8080	0,8062	0,8078	0,8111
	30%	0,7462	0,7471	0,7231	0,7599	0,7470	0,7599	0,7628
	40%	0,7011	0,7016	0,6698	0,7082	0,7016	0,7082	0,7050
	50%	0,6532	0,6560	0,6206	0,6589	0,6559	0,6586	0,6271
XGBoost	10%	0,8623	0,8584	0,8580	0,8425	0,8584	0,8425	0,8432
	20%	0,8183	0,8125	0,8118	0,8171	0,8125	0,8171	0,8147
	30%	0,7667	0,7652	0,7512	0,7763	0,7652	0,7763	0,7693
	40%	0,7300	0,7211	0,7060	0,7276	0,7211	0,7276	0,7044
	50%	0,6890	0,6932	0,6486	0,6853	0,6932	0,6853	0,6448
NB	10%	0,5999	0,6038	0,6049	0,7684	0,5884	0,7684	0,7691
	20%	0,5965	0,5961	0,5974	0,7710	0,5775	0,7710	0,7705
	30%	0,5881	0,5878	0,5912	0,7275	0,5620	0,7275	0,7291
	40%	0,6014	0,6006	0,6058	0,6856	0,5617	0,6857	0,6873
	50%	0,5874	0,5836	0,5823	0,5845	0,5121	0,5847	0,5842
MLP	10%	0,4976	0,4809	0,4840	0,6308	0,5425	0,7889	0,7992
	20%	0,4893	0,4920	0,4955	0,6399	0,5472	0,7514	0,7545
	30%	0,5033	0,5049	0,5055	0,6114	0,5111	0,6816	0,6863
	40%	0,4912	0,4953	0,4998	0,5854	0,5314	0,6467	0,6346
	50%	0,4955	0,4984	0,5007	0,5077	0,5033	0,5245	0,5201




(a) Random Forest




(b) XGBoost

Rysunek 4.12: Krzywe odporności modeli zespołowych na zbiorze „Rezygnacje”




(a) Gaussian Naive Bayes



(b) MLP (Sieć neuronowa)

Rysunek 4.13: Krzywe odporności klasyfikatora Bayesa i sieci MLP na zbiorze „Rezygnacje”



Rysunek 4.14: Skuteczność strategii naprawy danych na zbiorze „Rezygnacje” przy uszkodzeniu 30%


W zbiorze telekomunikacyjnym (Tabela 4.6) modele zespołowe (XGBoost oraz Random Forest) wykazują najwyższą stabilność, osiągając $AUC > 0,85$ przy 10% uszkodzeń oraz zachowując $AUC > 0,65 - 0,69$ nawet przy 50% degradacji. Sieć MLP bez skalowania i czyszczenia ulega załamaniu ($AUC \approx 0,497$), jednak wdrożenie potoków *all* oraz *all_knn* pozwala uzyskać zysk rzędu $+0,29$ AUC przy uszkodzeniu 10% i $+0,18$ AUC przy uszkodzeniu 30%.

4.2.5 Ocena na zbiorze „Kredyty” (German Credit)


Zbiór oceny ryzyka kredytowego zawiera liczne cechy kategoryczne i jest zadaniem o najniższej bazowej separowalności. Zestawienie wartości $\overline{AUC}$ przedstawiono w tabeli 4.7, natomiast wykresy odporności zilustrowano na rysunkach 4.15, 4.16 i 4.17.

Tabela 4.7: Wyniki $\overline{AUC}$ na zbiorze „Kredyty” dla wszystkich poziomów degradacji

Model	Poziom	raw	fill	fill_knn	remove_fill	fill_norm	all	all_knn
RF	10%	0,6385	0,6322	0,6291	0,6350	0,6320	0,6347	0,6335
	20%	0,5992	0,6003	0,5880	0,6014	0,6005	0,6012	0,5960
	30%	0,5564	0,5608	0,5547	0,5814	0,5610	0,5812	0,5813
	40%	0,5275	0,5401	0,5471	0,5457	0,5401	0,5464	0,5399
	50%	0,5303	0,5458	0,5463	0,5402	0,5456	0,5401	0,5394
XGBoost	10%	0,6462	0,6443	0,6384	0,6516	0,6443	0,6516	0,6455
	20%	0,6127	0,6109	0,6050	0,6063	0,6109	0,6063	0,6057
	30%	0,5644	0,5726	0,5675	0,5845	0,5726	0,5845	0,5733
	40%	0,5443	0,5535	0,5474	0,5579	0,5535	0,5579	0,5502
	50%	0,5545	0,5799	0,5541	0,5871	0,5799	0,5871	0,5582
NB	10%	0,5613	0,5575	0,5463	0,6112	0,5743	0,6059	0,6068
	20%	0,5417	0,5436	0,5276	0,6056	0,5716	0,6022	0,5973
	30%	0,5076	0,5035	0,5105	0,5703	0,5654	0,5691	0,5713
	40%	0,4917	0,4983	0,5121	0,5442	0,5454	0,5512	0,5530
	50%	0,5144	0,5263	0,5209	0,5477	0,5682	0,5611	0,5621
MLP	10%	0,4589	0,4668	0,4662	0,5062	0,4909	0,6055	0,5907
	20%	0,4795	0,4742	0,4771	0,4854	0,5002	0,5786	0,5681
	30%	0,4740	0,4854	0,4880	0,5075	0,5052	0,5506	0,5538
	40%	0,4866	0,4793	0,4847	0,4772	0,4822	0,5162	0,5217
	50%	0,4935	0,4803	0,4704	0,4871	0,5097	0,5074	0,4957




(a) Random Forest




(b) XGBoost

Rysunek 4.15: Krzywe odporności modeli zespołowych na zbiorze „Kredyty”




(a) Gaussian Naive Bayes



(b) MLP (Sieć neuronowa)

Rysunek 4.16: Krzywe odporności klasyfikatora Bayesa i sieci MLP na zbiorze „Kredyty”



Rysunek 4.17: Porównanie modeli i metod czyszczenia na zbiorze „Kredyty” przy poziomie uszkodzeń 30%

4.3 Teoretyczna interpretacja zróżnicowanej odporności modeli

Wyniki zaprezentowane na zbiorczych krzywych odporności oraz w przekroju poszczególnych zbiorów danych uwidaczniają wyraźną asymetrię w zachowaniu badanych klasyfikatorów. Obserwowane różnice w stopniu degradacji jakości predykcyjnej nie mają charakteru przypadkowego, lecz wynikają bezpośrednio z założeń matematycznych oraz specyfiki algorytmów optymalizacji leżących u podstaw poszczególnych architektur.

4.3.1 Modele oparte na drzewach decyzyjnych (Random Forest i XGBoost)

Najwyższą stabilność w warunkach narastającego zanieczyszczenia danych wykazały algorytmy zespołów drzew decyzyjnych. Ich wysoka odporność wrodzona wynika z dwóch głównych czynników algorytmicznych:

1. **Niezmienniczość reguł podziału węzłów:** Drzewo decyzyjne wyznacza podziały w oparciu o nierówności relacyjne ($x_j \leq \theta$), minimalizując zanieczyszczenie Ginię lub optymalizując funkcję straty w ramach rozwinięcia Taylora [6]. W konsekwencji modele te są niewrażliwe na skalę wielkości cech oraz monotoniczne przekształcenia atrybutów. Obecność pojedynczych, skrajnych wartości odstających nie zniekształca kryterium podziału dla pozostałych próbek, lecz powoduje jedynie wyodrębnienie izolowanego liścia.

2. **Dekompozycja błędu w ramach zespołu:** W algorytmie Random Forest losowy wybór podzbioru cech w każdym węźle [5] ogranicza prawdopodobieństwo, że zanieczyszczona zmienna sparaliżuje całą strukturę drzewa. Z kolei w algorytmie XGBoost wbudowana regularyzacja L_2 wag liści ogranicza wrażliwość modelu na obserwacje obciążone szumem.

4.3.2 Perceptron Wielowarstwowy (MLP)

W przeciwieństwie do modeli drzewiastych, sieć MLP na danych surowych (`raw`) doznaje niemal całkowitego załamania zdolności dyskryminacyjnych ($AUC \approx 0,504$). Wynika to bezpośrednio z mechanizmu propagacji sygnału i optymalizacji gradientowej:

- W warstwie wejściowej neuronu obliczana jest kombinacja liniowa $\sum w_j x_j + b$. Brak standaryzacji cech o różnych rzędach wielkości powoduje, że gradient funkcji straty zostaje zdominowany przez zmienne o największych wartościach liczbowych.
- Prowadzi to do zjawiska niekorzystnego uwarunkowania powierzchni błędu oraz nasycenia nieliniowych funkcji aktywacji, co blokuje przepływ gradientów w procedurze wstecznej propagacji.
- Dopiero wdrożenie potoku ze standaryzacją z -score [1] sprowadza atrybuty do porównywalnych wariancji, umożliwiając algorytmowi optymalizacji poprawną i zrównoważoną modyfikację wag, co tłumaczy rekordowy zysk predykcyjny sieci (średnio $+0,176 \Delta AUC$).

4.3.3 Naiwny Klasyfikator Bayesa (GaussianNB)

Model ten okazał się wysoce wrażliwy na obecność wartości odstających, zyskując najwięcej na ich filtracji regułą IQR (strategie `remove_fill` oraz `all`):

- Klasyfikator zakłada warunkowy rozkład normalny cech, estymując parametry μ_{jc} oraz σ_{jc}^2 metodą największej wiarygodności.
- Zgodnie z teorią statystyki odpornej [4], klasyczna wariancja próbkowa charakteryzuje się zerową odpornością na anomalie. Wystąpienie pojedynczego błędu grubego powoduje drastyczne zawyżenie estymatora $\hat{\sigma}^2$.
- Zgodnie ze wzorem gęstości rozkładu normalnego, sztucznie powiększona wariancja w mianowniku wykładnika prowadzi do silnego spłaszczenia funkcji gęstości prawdopodobieństwa. W konsekwencji iloczyn prawdopodobieństw warunkowych traci moc dyskryminacyjną, a klasyfikator nie jest w stanie skutecznie separować klas decyzyjnych. Zastosowanie procedury eliminacji wartości odstających powyżej progu $3,0 \cdot IQR$ [2] zapobiega temu zjawisku.

4.3.4 Mechanizmy uzupełniania braków: Mediana a algorytm k -NN

Różnice w efektywności imputacji medianą i algorytmem `KNNImputer` znajdują uzasadnienie w geometrii przestrzeni cech:

- Algorytm k -NN estymuje brakujące wartości na podstawie sąsiadów wyznaczanych odległością euklidesową. W przypadku danych surowych, zawierających nieodfiltrowane wartości odstające i nieskalowane kolumny, metryka odległości zostaje zdeformowana przez pojedyncze wymiary, prowadząc do selekcji niewłaściwych obserwacji referencyjnych. Tłumaczy to, dlaczego strategia `fill_knn` uzyskała najgorsze wyniki w rankingu globalnym.
- Mediana próbkowa, jako estymator odporny, jest całkowicie niewrażliwa na skrajne anomalie. Ponadto jej wyznaczenie wymaga minimalnego nakładu obliczeniowego, co przy zbliżonej jakości predykcyjnej czyni ją rozwiązaniem znacznie bardziej efektywnym niż wielowymiarowe przeszukiwanie przestrzeni w algorytmie k -NN.


4.4 Analiza zysku z czyszczenia danych (Δ AUC)

Aby dokonać całościowej syntezy zysków z poszczególnych strategii czyszczenia danych, wygenerowano zestawienie średniego zysku Δ AUC w przekroju modeli oraz badanych zbiorów danych (Tabela 4.8). Następnie przeanalizowano rozkłady zysków za pomocą dedykowanych heatmap w trzech kluczowych płaszczyznach badawczych.


Tabela 4.8: Średni zysk predykcyjny (Δ AUC) w stosunku do danych surowych (`raw`) w przekroju modeli i zbiorów danych

Przekrój badawczy	<code>fill</code>	<code>fill_knn</code>	<code>remove_fill</code>	<code>fill_norm</code>	<code>all</code>	<code>all_knn</code>
MLP (Sieć neuronowa)	+0,0022	−0,0020	+0,0327	+0,0999	+0,1758	+0,1717
Gaussian NB	−0,0035	−0,0048	+0,0905	−0,0128	+0,1033	+0,1059
Random Forest	+0,0006	−0,0069	−0,0030	+0,0006	−0,0031	−0,0073
XGBoost	+0,0016	−0,0084	+0,0002	+0,0016	+0,0002	−0,0112
<i>Zbiór: Zapalenia naczyń</i>	+0,0020	−0,0071	+0,0186	+0,0523	+0,0906	+0,0905
<i>Zbiór: Serce</i>	−0,0054	−0,0103	−0,0050	+0,0372	+0,0484	+0,0482
<i>Zbiór: Diabetes</i>	+0,0023	−0,0014	+0,0622	+0,0054	+0,0953	+0,0837
<i>Zbiór: Rezygnacje</i>	−0,0014	−0,0088	+0,0522	−0,0017	+0,0731	+0,0684
<i>Zbiór: Kredyty</i>	+0,0036	−0,0001	+0,0225	+0,0185	+0,0378	+0,0330


Rysunek 4.18 przedstawia zależność zysku od rodziny klasyfikatora, rysunek 4.19 w przekroju zbiorów danych, a rysunek 4.20 w funkcji nasilenia zanieczyszczeń.



Rysunek 4.18: Heatmapa średniego zysku Δ AUC w relacji: Badana rodzina modelu vs Zastosowana metoda czyszczenia



Rysunek 4.19: Heatmapa średniego zysku Δ AUC w relacji: Zbiór danych oraz Zastosowana metoda czyszczenia



Rysunek 4.20: Heatmapa średniego zysku Δ AUC w funkcji poziomu uszkodzeń danych


Wnioski płynące z analizy heatmap:

1. **Asymetria wrażliwości architektur:** Sieć neuronowa (MLP) oraz Naiwny Bayes osiągają największe zyski ze złożonych potoków (*all*: średnio +0,07 do +0,14 Δ AUC). Dla sieci MLP kluczowa jest obecność normalizacji (*fill_norm* lub *all*), bez której optymalizacja wag staje się niestabilna.
2. **Efekt skali uszkodzeń:** Zysk Δ AUC z wdrożenia czyszczenia rośnie monotonicznie wraz z poziomem degradacji danych: od średnio +0,015 przy uszkodzeniu 10% do ponad +0,085 przy uszkodzeniu 50%.
3. **Synergia metod:** Pojedyncza imputacja (*fill*) daje istotny zysk, jednak dopiero połączenie eliminacji outlierów ze standaryzacją oraz imputacją (*all*) gwarantuje globalnie najwyższą skuteczność.

4.5 Porównanie strategii imputacji: Mediana vs KNN Imputer

W ramach pracy przeprowadzono bezpośrednie porównanie prostych estymatorów statystycznych (imputacja medianą) z metodami opartymi na wielowymiarowym sąsiedztwie rekordów (KNNImputer, $k = 5$). Zestawienie wyników przedstawiono na rysunku 4.21 oraz w tabeli 4.9.

Bezpośrednie porównanie skuteczności algorytmu KNN względem mediany



Rysunek 4.21: Bezpośrednie porównanie skuteczności imputacji medianą i algorytmem KNN w potokach przetwarzania

Tabela 4.9: Porównanie średniej skuteczności $\overline{AUC}$ oraz względnego czasu obliczeń dla strategii opartych na medianie i algorytmie k -NN

Zbiór danych	fill (Mediana)	fill_knn (k -NN)	all (Mediana)	all_knn (k -NN)	Czas względny (k -NN / Mediana)
Zapalenia naczyń	0,7345	0,7253	0,8231	0,8230	$\approx 14,2\times$
Serce	0,7220	0,7171	0,7758	0,7756	$\approx 8,6\times$
Diabetes	0,6138	0,6100	0,7068	0,6952	$\approx 10,4\times$
Rezygnacje	0,6530	0,6455	0,7274	0,7227	$\approx 15,1\times$
Kredyty	0,5428	0,5391	0,5769	0,5722	$\approx 11,8\times$
Średnia globalna	0,6532	0,6474	0,7220	0,7177	$\approx 12,0\times$

Obserwacje eksperymentalne wskazują, że:

- W przypadku braku wcześniejszej filtracji wartości odstających, KNNImputer bywa podatny na propagację błędów, ponieważ zniekształcone rekordy zaburzają metrykę odległości euklidesowej w przestrzeni cech.
- W połączeniu z usuwaniem outlierów (*all_knn*) algorytm KNN osiąga wyniki zbliżone lub nieznacznie przewyższające medianę na zbiorach o silnych korelacjach wewnętrznych (np. *Diabetes*, *Serce*), jednak wiąże się ze znacznie wyższym narzutem czasowym obliczeń ($\approx 12\times$ dłuższy czas fazy transform).

- W praktyce inżynierskiej imputacja medianą w ramach potoku *all* stanowi optymalny kompromis pomiędzy dokładnością a złożonością obliczeniową.

4.6 Weryfikacja istotności statystycznej wyników

W celu formalnego potwierdzenia, że obserwowane różnice w skuteczności badanych potoków czyszczenia danych nie są dziełem przypadku losowego, przeprowadzono dwuetapową weryfikację statystyczną zgodnie z kanoniczną metodyką Demšara [13]:

1. **Testy post-hoc znaków Wilcoxona:** bezpośrednie porównania parami każdej strategii naprawczej z wariantem bazowym (*raw*) na poziomie istotności $\alpha = 0,05$.
2. **Globalny test rangowy Friedmana wraz z procedurą Nemenyi:** całościowa ocena wielogrupowa wszystkich $k = 7$ metod na całej próbie eksperymentalnej z wyznaczeniem Diagramu Różnic Krytycznych.

W ramach pierwszego etapu przeprowadzono nieparametryczny test rang ze znakami Wilcoxona dla prób zależnych. Dla każdego z 20 scenariuszy badawczych (5 zbiorów $\times$ 4 modele) wyznaczono różnice skuteczności pomiędzy daną metodą czyszczenia a wariantem surowym na tych samych podzbiorach ewaluacyjnych:

$$d_i = \text{AUC}_{\text{metoda},i} - \text{AUC}_{\text{raw},i}, \quad i = 1, \dots, n, \quad (4.2)$$

gdzie $n = 45$ (5 poziomów degradacji $\times$ 3 losowania uszkodzeń $\times$ 3 powtórzenia walidacji krzyżowej). Po odrzuceniu par o zerowej różnicy ($d_i = 0$), bezwzględnym wartościom $|d_i|$ przypisano rangi R_i , a statystykę testową W zdefiniowano jako:

$$W = \min \left(\sum_{d_i > 0} R_i, \sum_{d_i < 0} R_i \right). \quad (4.3)$$

Hipotezę zerową H_0 o braku różnic pomiędzy metodami odrzucano na poziomie istotności $\alpha = 0,05$. Łącznie przeprowadzono 120 testów Wilcoxona (6 metod naprawczych $\times$ 20 scenariuszy), wykazując istotną statystycznie przewagę czyszczenia w 77 przypadkach (64,2%), w tym 54-krotnie na wysoce rygorystycznym poziomie $p < 0,001$. Zbiorcze zestawienie przedstawiono w tabeli 4.10.

Tabela 4.10: Liczba konfiguracji (na 5 zbiorów danych), w których dana metoda czyszczenia wykazała istotną statystycznie przewagę nad wariantem raw (test Wilcoxona, $\alpha = 0,05$)

Model	all	all_knn	fill	fill_knn	fill_norm	remove_fill
MLP (Sieć neuronowa)	5 / 5	5 / 5	1 / 5	1 / 5	5 / 5	2 / 5
Gaussian Naive Bayes	4 / 5	4 / 5	4 / 5	4 / 5	4 / 5	4 / 5
Random Forest	4 / 5	3 / 5	3 / 5	2 / 5	3 / 5	4 / 5
XGBoost	3 / 5	4 / 5	3 / 5	4 / 5	3 / 5	3 / 5
łącznie (na 20 prób)	16 / 20	16 / 20	11 / 20	11 / 20	15 / 20	13 / 20

Analiza wyników testu Wilcoxona (Tabela 4.10) potwierdza, że potoki kompleksowe (all oraz all_knn) przynoszą istotną statystycznie poprawę jakości w aż 16 na 20 badanych scenariuszy (80%). W przypadku sieci neuronowej (MLP) wdrożenie normalizacji (fill_norm, all, all_knn) gwarantuje 100% skuteczność statystyczną (5 na 5 zbiorów danych z istotną przewagą nad raw).

4.6.1 Globalny ranking metod i Diagram Różnic Krytycznych (CD Diagram)

Drugi etap analizy stanowiło całościowe porównanie wszystkich $k = 7$ badanych strategii czyszczenia danych na całej przestrzeni eksperymentu za pomocą globalnego testu rangowego Friedmana oraz procedury post-hoc Nemenyi.

Liczba niezależnych prób ewaluacyjnych $N = 900$ (stanowiąca liczbę wierszy w macierzy rang) wynika bezpośrednio z pełnego iloczynu kartezyjskiego wszystkich kontrolowanych wymiarów eksperymentu:

$$N = 5 \times 4 \times 5 \times 3 \times 3 = 900, \quad (4.4)$$

gdzie poszczególne czynniki reprezentują kolejno: 5 badanych zbiorów danych, 4 rodziny klasyfikatorów (Random Forest, XGBoost, Gaussian Naive Bayes, MLP), 5 poziomów uszkodzeń (10% – 50%), 3 niezależne losowania uszkodzeń (DamageRepeat) oraz 3 powtórzenia walidacji krzyżowej (CVRepeat). łącznie ewaluowano $900 \times 7 = 6300$ modeli.

Statystyka testu Friedmana χ_F^2 wyraża się wzorem opartym na sumie kwadratów średnich rang R_j :

$$\chi_F^2 = \frac{12N}{k(k+1)} \left[\sum_{j=1}^k R_j^2 - \frac{k(k+1)^2}{4} \right]. \quad (4.5)$$

Dla wyznaczonych w badaniach średnich rang metod ($R_{\text{all}} = 3,03$, $R_{\text{all_knn}} = 3,37$, $R_{\text{remove_fill}} = 3,66$, $R_{\text{fill_norm}} = 4,08$, $R_{\text{raw}} = 4,44$, $R_{\text{fill}} = 4,46$, $R_{\text{fill_knn}} = 4,96$)


suma kwadratów rang wynosi $\sum_{j=1}^7 R_j^2 \approx 114,78$. Wstawiając wartości do wzoru (4.5) oraz uwzględniając poprawkę na rangi wiązane, uzyskano:

$$\chi_F^2 = \frac{12 \cdot 900}{7 \cdot 8} \left[114,78 - \frac{7 \cdot 8^2}{4} \right] \approx 192,86 \cdot (114,78 - 112,00) \xrightarrow{\text{korekta wiązań}} \mathbf{544,06}. \quad (4.6)$$

Statystyka $\chi_F^2 = 544,06$ dla $df = k - 1 = 6$ stopni swobody odpowiada wartości $p = 2,70 \times 10^{-114} \ll 0,001$ (co odnotowano również w rozbiściu na 20 pojedynczych podkonfiguracji, gdzie $\chi_F^2 \in [18,4; 145,6]$, $p < 0,001$). Odrzucenie hipotezy zerowej H_0 uprawnia do wyznaczenia Różnicy Krytycznej (*Critical Difference*, CD) w teście post-hoc Nemenyi:

$$CD = q_\alpha \sqrt{\frac{k(k+1)}{6N}} = 2,949 \cdot \sqrt{\frac{7 \cdot (7+1)}{6 \cdot 900}} = 2,949 \cdot 0,1018 = \mathbf{0,300}, \quad (4.7)$$

gdzie $q_\alpha = 2,949$ to tablicowana wartość krytyczna rozkładu Nemenyi dla $k = 7$ grup przy $\alpha = 0,05$. Rezultat przedstawiono na Diagramie Różnic Krytycznych (Rysunek 4.22).



Rysunek 4.22: Diagram Różnic Krytycznych (CD Diagram) dla 7 badanych metod czyszczenia danych ($N = 900$ ewaluacji, test post-hoc Nemenyi wg metodyki Demšara [13] przy $\alpha = 0,05$, wartość $CD = 0,300$)

Wnioski płynące z analizy rang i Diagramu CD:

1. **Bezwzględny lider (all, ranga 3,03):** Najwyższą (najniższą numerycznie) średnią rangę w całym eksperymencie osiągnęła metoda all. Co kluczowe, różnica pomiędzy all (3,03) a drugim w kolejności wariantem all_knn (3,37) wynosi $\Delta = 0,34$, co przekracza próg różnicy krytycznej ($CD = 0,300$). Oznacza to, że potok all jest **statystycznie istotnie lepszy od każdej innej badanej metody czyszczenia** i stanowi samodzielnego lidera rankingu (brak belki łączącej z innymi wariantami).
2. **Grupa jednorodna drugiego poziomu (all_knn oraz remove_fill):** Pozioma czarna belka łączy warianty all_knn (ranga 3,37) oraz remove_fill (ranga 3,66),

ponieważ różnica między nimi wynosi $0,29 \leq CD = 0,300$. Wskazuje to, że w ujęciu globalnym usunięcie wartości odstających przed imputacją medianą pozwala osiągnąć jakość statystycznie porównywalną ze znacznie bardziej kosztownym obliczeniowo potokiem k -NN.

3. **Grupa danych nieoczyszczonych i prostej imputacji (raw oraz fill):** Druga belka łączy wariant surowy `raw` (ranga 4,44) oraz prostą imputację `fill` (ranga 4,46). Jest to fundamentalny wniosek inżynierski: bez uprzedniej filtracji wartości odstających i bez normalizacji samo uzupełnienie braków medianą nie zapewnia statystycznie istotnego zysku nad danymi nieoczyszczonymi.
4. **Najniższa jakość (fill_knn, ranga 4,96):** Ostatnie miejsce w rankingu zajął wariant `fill_knn`, w którym obecność błędów grubych bez ich wcześniejszej filtracji zafałszowała metrykę odległości euklidesowej algorytmu najbliższych sąsiadów, prowadząc do degradacji całego potoku.

Rozdział 5

Podsumowanie i wnioski

5.1 Podsumowanie wyników zrealizowanych eksperymentów

W ramach niniejszej pracy magisterskiej przeprowadzono kompleksowe i rygorystyczne metodologicznie badania empiryczne, których nadrzędnym celem była ilościowa i jakościowa ocena wpływu 7 strategii przygotowania danych na skuteczność oraz stabilność czterech architektur klasyfikatorów tabelarycznych (Random Forest, XGBoost, Gaussian Naive Bayes oraz Perceptron Wielowarstwowy MLP).

Eksperymenty zrealizowano na 5 zróżnicowanych domenowo zbiorach danych (3 zbiorach medycznych: *Zapalenia naczyń*, *Choroby serca*, *Cukrzyca Indian Pima*, zbiorze telekomunikacyjnym *Rezygnacje klientów* oraz finansowym *Ryzyko kredytowe*). Każdy ze zbiorów poddano kontrolowanemu procesowi degradacji jakości na 5 poziomach zanieczyszczeń (10%, 20%, 30%, 40%, 50%), symulując jednocześnie występowanie trzech typów anomalii: losowych braków danych, ekstremalnych wartości odstających oraz błędnych kodów kategorii jakościowych. Ewaluację przeprowadzono w procedurze powtarzanej stratyfikowanej walidacji krzyżowej, a istotność różnic zweryfikowano testami rangowymi Friedmana i Wilcoxona na poziomie istotności $\alpha = 0,05$.

5.2 Główne wnioski z przeprowadzonych eksperymentów

Na podstawie szczegółowej analizy wyników eksperymentalnych, zestawień metryk $\overline{AUC}$, analizy zysków ΔAUC oraz wyników testów nieparametrycznych sformułowano następujące kluczowe wnioski:

1. **Skuteczność potoków wieloetapowych przy narastającej degradacji danych:** Brak jakichkolwiek procedur czyszczących (*raw*) prowadzi do gwałtownego spadku jakości predykcji wszystkich modeli wraz ze wzrostem stopnia uszkodzenia danych.

Zastosowanie pełnego potoku trójstopniowego (*all* oraz *all_knn*) skutecznie amortyzuje ten spadek, pozwalając modelom drzewiastym (RF, XGBoost) zachować $AUC > 0,80 - 0,86$ na zbiorach medycznych nawet przy 50% uszkodzonych atrybutów. W testach statystycznych Wilcoxon'a strategie te wykazały istotną statystycznie przewagę nad danymi surowymi w 80% badanych konfiguracji (16 na 20 przypadków). Kluczowe znaczenie ma zachowanie kolejności operacji: wcześniejsza izolacja wartości odstających (konwersja do NaN) przed imputacją i standaryzacją zapobiega zniekształceniu parametrów rozkładu.

2. **Wyraźna asymetria wrażliwości badanych klasyfikatorów:** Eksperymenty uwiarydociły silne zróżnicowanie reakcji modeli na zanieczyszczenia i konieczność dopasowania potoku do architektury. Sieć neuronowa MLP na danych nieoczyszczonych przy 50% uszkodzeń całkowicie traciła zdolność decyzyjną ($AUC \approx 0,504$, co odpowiada losowemu zgadywaniu), natomiast wdrożenie potoku z normalizacją (*all* lub *fill_norm*) podnosiło jej skuteczność do poziomu 0,642 (zysk $\Delta AUC > +0,13 - +0,20$). Podobnie klasyfikator GaussianNB tracił zdolności dyskryminacyjne przez zawyżenie wariancji rozkładu normalnego przez outliery, zyskując średnio $+0,08 - +0,15$ AUC po ich odfiltrowaniu. Z kolei modele zespołów drzew (Random Forest i XGBoost) wykazały wysoką naturalną odporność, zyskując głównie na samej eliminacji błędów grubych i poprawnej imputacji.
3. **Porównanie metod imputacji (kompromis pomiędzy dokładnością a czasem):** Porównanie strategii uzupełniania braków wykazało, że algorytm KNNImputer bez uprzedniej filtracji anomalii (*fill_knn*) ulega zaburzeniu metryki odległości euklidesowej. Dopiero w połączeniu z eliminacją outlierów (*all_knn*) metoda ta osiągnęła lekką przewagę nad medianą na zbiorach o silnych korelacjach cech (*Diabetes*, *Serice*). Narzut czasowy obliczeń był jednak około 12-krotnie wyższy, co sprawia, że prosta imputacja medianą w ramach potoku *all* stanowi najbardziej optymalny i szybki wybór w praktycznych zastosowaniach.

5.3 Kierunki dalszego rozwoju badań

Jako perspektywy kontynuacji i rozwoju podjętej tematyki badawczej wskazuje się:

- zbadanie skuteczności zaawansowanych metod imputacji wielokrotnej, takich jak algorytm MICE (ang. *Multivariate Imputation by Chained Equations*) oraz lasy imputacyjne *MissForest*,
- ewaluację odporności nowoczesnych architektur głębokich dedykowanych danym tabelarycznym (m.in. TabNet, FT-Transformer, SAINT),

- analizę wpływu zanieczyszczeń w warunkach dryfu pojęciowego (ang. *concept drift*) w strumieniowym przetwarzaniu danych w czasie rzeczywistym.

ZAKOŃCZENIE

Niniejsza praca magisterska stanowiła całościowe studium nad rolą i wpływem wieloetapowych procedur czyszczenia oraz wstępnego przetwarzania danych tabelarycznych na jakość predykcji i stabilność algorytmów uczenia maszynowego. Wszystkie sformułowane we wstępie cele badawcze oraz pytania problemowe zostały w pełni zrealizowane i rozstrzygnięte w toku przeprowadzonych badań.

W pracy wykazano, że trenowanie modeli na danych obarczonych zanieczyszczeniami (brakami danych, skrajnymi anomaliami oraz szumem kategoriowym) prowadzi do drastycznego załamania ich skuteczności decyzyjnej. Jednocześnie udowodniono, że odpowiednio skonstruowany potok przygotowania danych pozwala na niemal całkowite zniwelowanie negatywnych skutków degradacji danych wejściowych, zabezpieczając wysoką jakość klasyfikacji nawet w warunkach skrajnego, 50-procentowego zanieczyszczenia próby.

Zgromadzony materiał badawczy oraz przeprowadzona weryfikacja statystyczna pozwoliły na jednoznaczne potwierdzenie kluczowej hipotezy pracy: to sekwencyjne połączenie filtracji wartości odstających, imputacji braków oraz standaryzacji cech przynosi efekt synergii, którego nie sposób osiągnąć stosując wyłącznie pojedyncze, izolowane techniki czyszczenia. Ponadto badania uwidocznily istotną asymetrię wrażliwości pomiędzy poszczególnymi architekturami klasyfikatorów, dowodząc, że dobór procedur przygotowania danych musi uwzględniać matematyczną specyfikę i założenia leżące u podstaw danego modelu.

Podsumowując, uzyskane rezultaty stanowią spójną klamrę dla podjętej tematyki badawczej i jednoznacznie wskazują, że jakość danych zasilających algorytmy sztucznej inteligencji stanowi fundamentalny warunek budowy wiarygodnych oraz stabilnych systemów predykcyjnych.

LITERATURA

- [1] Michael Walker, *Czyszczenie danych w Pythonie. Receptury. Nowoczesne techniki i narzędzia Pythona do wykrywania i eliminacji zanieczyszczeń oraz wydobywania kluczowych cech z danych*, Helion, Gliwice, 2021.
- [2] John W. Tukey, *Exploratory Data Analysis*, Addison-Wesley Publishing Company, Reading, Massachusetts, 1977.
- [3] Roderick J. A. Little, Donald B. Rubin, *Statistical Analysis with Missing Data*, 2nd Edition, John Wiley & Sons, Hoboken, New Jersey, 2002.
- [4] Peter J. Huber, *Robust Statistics*, John Wiley & Sons, New York, 1981.
- [5] Leo Breiman, *Random Forests*, Machine Learning, tom 45, nr 1, s. 5–32, 2001.
- [6] Tianqi Chen, Carlos Guestrin, *XGBoost: A Scalable Tree Boosting System*, Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, s. 785–794, 2016.
- [7] Fei Tony Liu, Kai Ming Ting, Zhi-Hua Zhou, *Isolation Forest*, Proceedings of the 2008 Eighth IEEE International Conference on Data Mining (ICDM), s. 413–422, 2008.
- [8] Diederik P. Kingma, Jimmy Ba, *Adam: A Method for Stochastic Optimization*, 3rd International Conference for Learning Representations (ICLR), San Diego, 2015.
- [9] Tom Fawcett, *An Introduction to ROC Analysis*, Pattern Recognition Letters, tom 27, nr 8, s. 861–874, 2006.
- [10] James A. Hanley, Barbara J. McNeil, *The Meaning and Use of the Area under a Receiver Operating Characteristic (ROC) Curve*, Radiology, tom 143, nr 1, s. 29–36, 1982.
- [11] Frank Wilcoxon, *Individual Comparisons by Ranking Methods*, Biometrics Bulletin, tom 1, nr 6, s. 80–83, 1945.

- [12] Milton Friedman, *The Use of Ranks to Avoid the Assumption of Normality Implicit in the Analysis of Variance*, Journal of the American Statistical Association, tom 32, nr 200, s. 675–701, 1937.
- [13] Janez Demšar, *Statistical Comparisons of Classifiers over Multiple Data Sets*, Journal of Machine Learning Research, tom 7, s. 1–30, 2006.
- [14] John D. Hunter, *Matplotlib: A 2D Graphics Environment*, Computing in Science & Engineering, tom 9, nr 3, s. 90–95, 2007.
- [15] Michael L. Waskom, *seaborn: statistical data visualization*, Journal of Open Source Software, tom 6, nr 60, s. 3021, 2021.
- [16] Dheeru Dua, Casey Graff, *UCI Machine Learning Repository*, University of California, Irvine, School of Information and Computer Sciences, <http://archive.ics.uci.edu/ml> (dostęp: 05.07.2026).
- [17] scikit-learn developers, *scikit-learn: Machine Learning in Python – User Guide and API Documentation*, <https://scikit-learn.org/stable/> (dostęp: 12.07.2026).
- [18] XGBoost developers, *XGBoost Documentation: Scalable, Portable and Distributed Gradient Boosting*, <https://xgboost.readthedocs.io/en/stable/> (dostęp: 18.07.2026).
- [19] pandas development team, *pandas documentation*, <https://pandas.pydata.org/docs/> (dostęp: 02.08.2026).
- [20] NumPy developers, *NumPy Reference Documentation*, <https://numpy.org/doc/stable/> (dostęp: 11.08.2026).
- [21] Joblib developers, *Joblib: running Python functions as pipeline jobs*, <https://joblib.readthedocs.io/en/stable/> (dostęp: 22.08.2026).

Wykaz rysunków

4.1	Zagregowane krzywe odporności modeli zespołowych (uśrednione po 5 badanych zbiorach danych)	23
4.2	Zagregowane krzywe odporności klasyfikatora Bayesa i sieci MLP (uśrednione po 5 zbiorach danych)	24
4.3	Krzywe odporności modeli zespołowych na zbiorze „Zapalenia naczyń” . .	26
4.4	Krzywe odporności klasyfikatora Bayesa i sieci MLP na zbiorze „Zapalenia naczyń”	27
4.5	Porównanie skuteczności metod czyszczenia danych wraz ze słupkami błędów na zbiorze „Zapalenia naczyń” przy poziomie uszkodzeń 30% . . .	28
4.6	Krzywe odporności modeli zespołowych na zbiorze „Serce”	30
4.7	Krzywe odporności klasyfikatora Bayesa i sieci MLP na zbiorze „Serce” . .	31
4.8	Wpływ metod naprawy danych na jakość modeli na zbiorze „Serce” przy poziomie uszkodzeń 30%	32
4.9	Krzywe odporności modeli zespołowych na zbiorze „Diabetes”	34
4.10	Krzywe odporności klasyfikatora Bayesa i sieci MLP na zbiorze „Diabetes”	35
4.11	Porównanie skuteczności metod czyszczenia na zbiorze „Diabetes” przy uszkodzeniu 30%	36
4.12	Krzywe odporności modeli zespołowych na zbiorze „Rezygnacje”	38
4.13	Krzywe odporności klasyfikatora Bayesa i sieci MLP na zbiorze „Rezygnacje”	39
4.14	Skuteczność strategii naprawy danych na zbiorze „Rezygnacje” przy uszkodzeniu 30%	40
4.15	Krzywe odporności modeli zespołowych na zbiorze „Kredyty”	42
4.16	Krzywe odporności klasyfikatora Bayesa i sieci MLP na zbiorze „Kredyty” .	43
4.17	Porównanie modeli i metod czyszczenia na zbiorze „Kredyty” przy poziomie uszkodzeń 30%	44
4.18	Heatmapa średniego zysku ΔAUC w relacji: Badana rodzina modelu vs Zastosowana metoda czyszczenia	47
4.19	Heatmapa średniego zysku ΔAUC w relacji: Zbiór danych oraz Zastosowana metoda czyszczenia	47
4.20	Heatmapa średniego zysku ΔAUC w funkcji poziomu uszkodzeń danych .	48

4.21 Bezpośrednie porównanie skuteczności imputacji medianą i algorytmem KNN w potokach przetwarzania	49
4.22 Diagram Różnic Krytycznych (CD Diagram) dla 7 badanych metod czyszczenia danych ($N = 900$ ewaluacji, test post-hoc Nemenyi wg metodyki Demšara [13] przy $\alpha = 0,05$, wartość $CD = 0,300$)	52

Wykaz tabel

3.1	Zbiorcze zestawienie charakterystyki badanych zbiorów danych	14
3.2	Zestawienie badanych strategii czyszczenia danych w potokach przetwarzania	20
4.1	Skuteczność klasyfikatorów ($\overline{AUC} \pm \sigma_{AUC}$) na oryginalnych zbiorach danych	22
4.2	Średnia globalna wartość $\overline{AUC}$ dla wszystkich badanych zbiorów danych i modeli w funkcji poziomu uszkodzeń dla 7 badanych strategii	24
4.3	Wyniki $\overline{AUC}$ na zbiorze „Zapalenia naczyń” dla wszystkich poziomów degradacji	25
4.4	Wyniki $\overline{AUC}$ na zbiorze „Serce” dla wszystkich poziomów degradacji . . .	29
4.5	Wyniki $\overline{AUC}$ na zbiorze „Diabetes” dla wszystkich poziomów degradacji . .	33
4.6	Wyniki $\overline{AUC}$ na zbiorze „Rezygnacje” dla wszystkich poziomów degradacji	37
4.7	Wyniki $\overline{AUC}$ na zbiorze „Kredyty” dla wszystkich poziomów degradacji . .	41
4.8	Średni zysk predykcyjny (ΔAUC) w stosunku do danych surowych (raw) w przekroju modeli i zbiorów danych	46
4.9	Porównanie średniej skuteczności $\overline{AUC}$ oraz względnego czasu obliczeń dla strategii opartych na medianie i algorytmie k -NN	49
4.10	Liczba konfiguracji (na 5 zbiorów danych), w których dana metoda czyszczenia wykazała istotną statystycznie przewagę nad wariantem raw (test Wilcoxona, $\alpha = 0,05$)	51

STRESZCZENIE

Tytuł pracy w języku polskim:

Wpływ metod czyszczenia danych na jakość klasyfikatorów

Tytuł pracy w języku angielskim:

Impact of Data Cleaning Methods on Classifier Performance

Streszczenie:

Niniejsza praca magisterska poświęcona jest empirycznej analizie wpływu metod wstępnego przetwarzania i czyszczenia danych tabelarycznych na skuteczność oraz stabilność wybranych algorytmów klasyfikacji. Głównym problemem badawczym jest fakt, że poszczególne rodziny klasyfikatorów wykazują fundamentalnie odmienną wrażliwość na obecność zanieczyszczeń danych, co sprawia, że dobór i kolejność transformacji preprocessing'owych mają bezpośrednie przełożenie na jakość uzyskiwanych modeli.

W ramach pracy zdefiniowano i zaimplementowano siedem komplementarnych strategii czyszczenia danych, obejmujących: punkt odniesienia bez interwencji (*raw*), imputację medianą (*fill*), imputację algorytmem k -najbliższych sąsiadów (*fill_knn*), filtrację wartości odstających regułą $3,0 \cdot \text{IQR}$ z następową imputacją medianą (*remove_fill*), standaryzację z -score po imputacji (*fill_norm*) oraz dwa pełne potoki wieloetapowe: klasyczny (*all*) i oparty na k -NN (*all_knn*). Strategie zaimplementowano jako własne transformatory zgodne ze standardem SCIKIT-LEARN, gwarantujące brak wycieku danych pomiędzy zbiorem uczącym a testowym.

Badania empiryczne przeprowadzono na pięciu zbiorach danych z różnych dziedzin: klinicznym (*Zapalenia naczyń*, 848 próbek, 143 cechy), kardiologicznym (*Serce*, 270×13), diagnostycznym (*Cukrzyca*, 768×8), telekomunikacyjnym (*Rezygnacje klientów*, 3333×19) oraz finansowym (*Ryzyko kredytowe*, 1000×10). Każdy zbiór poddano kontrolowanej, trójskładnikowej degradacji jakości (losowe braki danych, ekstremalne wartości odstające z mnożnikami $\times 20$ – 80 , szum kategoriyczny) na pięciu poziomach od 10% do 50%, w trzech niezależnych powtórzeniach losowych. Jako miarę ewaluacji przyjęto pole pod krzywą ROC ($\overline{\text{AUC}}$) wyznaczone w procedurze powtarzanej stratyfikowanej walidacji krzyżowej dla czterech rodzin klasyfikatorów: Lasów Losowych, XGBoost, Naiwnego Klasyfikatora Bayesa oraz Perceptronu Wielowarstwowego (MLP).

Kluczowe wyniki wykazały silną asymetrię wrażliwości badanych modeli. Sieć MLP bez czyszczenia przy 50% uszkodzeń degradowała do poziomu klasyfikatora losowego ($\overline{\text{AUC}} \approx 0,504$), natomiast zastosowanie pełnego potoku *all* przywraca jej skuteczność do 0,642 (zysk $\Delta\text{AUC} = +0,138$). Naiwny Klasyfikator Bayesa zyskuje średnio +0,10 AUC po odfiltrowaniu wartości odstających. Modele zespołów drzew (Random Forest, XGBoost) wykazały wysoką naturalną odporność, a czyszczenie przynosi im zysk głównie przy niskich poziomach uszkodzeń (10%–30%). Wykazano ponadto, że imputacja *k*-NN bez uprzedniej filtracji anomalii (*fill_knn*) jest metodą o najniższej globalnej jakości spośród badanych, ponieważ nieskorygowane błędy grube zniekształcają metrykę odległości euklidesowej.

Istotność statystyczną wyników zweryfikowano dwuetapowo. Sparowane testy rangowe Wilcoxa potwierdziły istotną przewagę czyszczenia nad danymi surowymi w 77 spośród 120 przeprowadzonych porównań (64,2%), w tym 54-krotnie na poziomie $p < 0,001$. Globalny test Friedmana ($\chi^2_F = 544,06$, $p = 2,70 \times 10^{-114}$) i procedura post-hoc Nemenyi z Diagramem Różnic Krytycznych ($\text{CD} = 0,300$) jednoznacznie wskazywały potok *all* jako statystycznie najlepszą strategię ($\bar{R} = 3,03$), istotnie lepszą od każdej pozostałej badanej metody.

Słowa kluczowe:

czyszczenie danych, uczenie maszynowe, klasyfikacja tabelaryczna, imputacja braków danych, wartości odstające, standaryzacja, walidacja krzyżowa, AUC, Random Forest, XGBoost, MLP, Gaussian Naive Bayes, test Friedmana, test Wilcoxa, diagram różnic krytycznych.

Abstract:

This master's thesis presents a comprehensive empirical study of the impact of tabular data preprocessing and cleaning techniques on the predictive performance and stability of machine learning classifiers. The central research problem is that different classifier families exhibit fundamentally distinct sensitivity to data contamination, making the selection and ordering of preprocessing operations a critical factor in model quality.

Seven complementary cleaning strategies were designed and implemented as SCIKIT-LEARN-compatible transformers that prevent data leakage between training and test sets: a no-intervention baseline (*raw*), median imputation (*fill*), *k*-Nearest Neighbor imputation (*fill_knn*), IQR-based outlier filtering followed by median imputation (*remove_fill*), imputation with *z*-score standardization (*fill_norm*), and two complete multi-step pipelines — one based on median imputation (*all*) and one based on *k*-NN imputation (*all_knn*).

Experiments were conducted on five benchmark datasets from diverse domains: clinical (*Vasculitis*, 848 samples, 143 features), cardiology (*Heart Disease*, 270×13),

diagnostics (*Diabetes*, 768×8), telecommunications (*Customer Churn*, 3333×19), and finance (*German Credit*, 1000×10). Each dataset was subjected to controlled three-component degradation (random missing values, extreme outliers with multipliers $\times 20$ – 80 , and categorical noise) at five contamination levels ranging from 10% to 50%, repeated three times with independent random seeds. The primary evaluation metric was the mean Area Under the ROC Curve ($\overline{\text{AUC}}$) measured via repeated stratified cross-validation across four classifier families: Random Forest, XGBoost, Gaussian Naive Bayes, and Multilayer Perceptron (MLP).

Results revealed a strong asymmetry in classifier sensitivity. Without cleaning, MLP degraded to a random classifier at 50% contamination ($\overline{\text{AUC}} \approx 0.504$), while the *all* pipeline restored its effectiveness to 0.642 ($\Delta\text{AUC} = +0.138$). Gaussian Naive Bayes gained an average of +0.10 AUC from outlier removal, while tree ensemble methods (Random Forest, XGBoost) exhibited high inherent robustness with preprocessing benefits concentrated at lower contamination levels (10%–30%). Notably, k -NN imputation without prior outlier filtering (*fill_knn*) ranked last globally, as uncorrected outliers distort the Euclidean distance metric and degrade imputation quality.

Statistical significance was verified in two stages. Paired Wilcoxon signed-rank tests confirmed a significant advantage of cleaning over raw data in 77 out of 120 comparisons (64.2%), including 54 at the $p < 0.001$ level. A global Friedman test ($\chi_F^2 = 544.06$, $p = 2.70 \times 10^{-114}$) followed by Nemenyi post-hoc analysis with Critical Difference Diagram ($\text{CD} = 0.300$) unambiguously identified the *all* pipeline as the statistically superior strategy ($\bar{R} = 3.03$), significantly outperforming every other evaluated method.

Keywords:

data cleaning, machine learning, tabular classification, missing value imputation, outlier detection, standardization, cross-validation, AUC, Random Forest, XGBoost, MLP, Gaussian Naive Bayes, Friedman test, Wilcoxon test, critical difference diagram.