

UNIWERSYTET RZESZOWSKI

Wydział Nauk Ścisłych i Technicznych



Dominik Machnik

nr albumu: 117814

Kierunek: Informatyka

Wpływ metod czyszczenia danych na jakość klasyfikatorów

Praca magisterska

Praca wykonana pod kierunkiem:

dr. hab. Jana Bazana, prof. UR

Rzeszów, 2026

Spis treści

WSTĘP	1
1 Wprowadzenie	3
1.1 Motywacja i sformułowanie problemu	3
1.2 Cel pracy	4
1.3 Tezy i pytania badawcze	4
1.4 Zakres pracy	5
1.5 Struktura pracy	5
2 Część teoretyczna	7
2.1 Taksonomia problemów jakości danych tabelarycznych	7
2.1.1 Mechanizmy powstawania braków danych	7
2.1.2 Wartości odstające i błędy grube	8
2.2 Metody wstępnego przetwarzania i czyszczenia danych	8
2.2.1 Uzupełnianie braków danych (Imputacja)	8
2.2.2 Identyfikacja i obsługa wartości odstających	9
2.2.3 Skalowanie atrybutów i kodowanie zmiennych jakościowych	10
2.3 Wybrane algorytmy klasyfikacji	10
2.3.1 Naiwny Klasyfikator Bayesa (Gaussian Naive Bayes)	10
2.3.2 Perceptron Wielowarstwowy (MLP)	11
2.3.3 Lasy Losowe (Random Forest)	11
2.3.4 XGBoost (Extreme Gradient Boosting)	12
2.4 Metryki oceny jakości modeli i aparat statystyczny	13
2.4.1 Krzywa ROC i pole pod krzywą (AUC)	13
2.4.2 Nieparametryczne testy istotności statystycznej	13
3 Środowisko i zbiory danych	15
3.1 Wykorzystane narzędzia i biblioteki	15
3.2 Charakterystyka badanych zbiorów danych	16
3.2.1 Zbiór „Zapalenia naczyń” (Vasculitis)	16
3.2.2 Zbiór „Serce” (Heart Disease)	17

3.2.3	Zbiór „Diabetes” (Pima Indians Diabetes)	17
3.2.4	Zbiór „Rezygnacje” (Customer Churn)	18
3.2.5	Zbiór „Kredyty” (German Credit)	18
3.3	Metodologia symulacji kontrolowanych zanieczyszczeń	19
3.4	Architektura potoku przetwarzania i uzasadnienie doboru strategii	19
3.4.1	Trzy filary przetwarzania wstępnego	20
3.4.2	Redukcja pełnego planu czynnikowego ($2^3 = 8$) do zestawu strategii praktycznych	20
3.5	Protokół eksperymentalny i parametryzacja klasyfikatorów	21
4	Wyniki eksperymentów	23
4.1	Wyniki bazowe i ogólna charakterystyka odporności modeli	23
4.2	Szczegółowa analiza wyników na poszczególnych zbiorach danych	25
4.2.1	Ocena na zbiorze „Zapalenia naczyń”	25
4.2.2	Ocena na zbiorze „Serce” (Heart Disease)	27
4.2.3	Ocena na zbiorze „Diabetes” (Pima Indians Diabetes)	29
4.2.4	Ocena na zbiorze „Rezygnacje” (Customer Churn)	31
4.2.5	Ocena na zbiorze „Kredyty” (German Credit)	33
4.3	Analiza zysku z czyszczenia danych (ΔAUC) i profile wielowymiarowe	35
4.4	Porównanie strategii imputacji: Mediana vs KNN Imputer	38
4.5	Weryfikacja istotności statystycznej wyników	39
4.5.1	Globalny ranking metod – Diagram Różnic Krytycznych (CD Diagram)	40
5	Podsumowanie i wnioski	43
5.1	Podsumowanie wyników zrealizowanych eksperymentów	43
5.2	Formalna weryfikacja postawionych tez badawczych	43
5.3	Rekomendacje inżynierskie dla praktyków Data Science	45
5.4	Trudności implementacyjne i ograniczenia badań	45
5.5	Kierunki dalszego rozwoju badań	45
	ZAKOŃCZENIE	47
	LITERATURA	49
	STRESZCZENIE	53

WSTĘP

Współczesny rozwój metod sztucznej inteligencji i uczenia maszynowego w istotny sposób przekształcił procesy podejmowania decyzji w wielu kluczowych dziedzinach życia gospodarczego i społecznego. Szczególne miejsce w tych zastosowaniach zajmują dane tabelaryczne, stanowiące podstawowy format zapisu informacji w bazach medycznych, systemach finansowych, ubezpieczeniowych czy telekomunikacyjnych. Pomimo intensywnego rozwoju zaawansowanych architektur głębokich sieci neuronowych, modelowanie danych tabelarycznych wciąż stawia przed badaczami unikalne wyzwania, związane z heterogenicznością typów cech, zróżnicowaniem ich rozkładów oraz obecnością zakłóceń o charakterze losowym i systematycznym.

W praktyce analitycznej powszechnie przyjmuje się regułę, zgodnie z którą jakość modelu predykcyjnego jest bezpośrednią pochodną jakości danych wejściowych. Dane pozyskiwane ze środowisk rzeczywistych — takich jak rejestry kliniczne pacjentów czy systemy bilingowe — rzadko bywają kompletne i nieskażone. Do najczęściej spotykanych problemów należą: brakujące wartości atrybutów, obecność skrajnych obserwacji odstających (będących wynikiem błędów aparatury pomiarowej bądź pomyłek zapisu) oraz drastyczne różnice w skalach poszczególnych zmiennych. Zanieczyszczenia te mogą w sposób istotny zniekształcać granice decyzyjne klasyfikatorów, prowadząc do błędnych diagnoz medycznych lub nieoptymalnych decyzji biznesowych.

Niniejsza praca magisterska jest poświęcona empirycznemu zbadaniu i teoretycznemu usystematyzowaniu wpływu wybranych metod czyszczenia i wstępnego przetwarzania danych na skuteczność oraz stabilność działania czterech reprezentatywnych rodzin klasyfikatorów (Naiwny Klasyfikator Bayesa, Perceptron Wielowarstwowy MLP, Laszy Losowe oraz XGBoost). Badania przeprowadzono w warunkach kontrolowanej, wielostopniowej degradacji jakości danych na pięciu zróżnicowanych zbiorach referencyjnych (obejmujących m.in. układowe zapalenia naczyń, schorzenia kardiologiczne, cukrzycę, migrację klientów oraz ocenę ryzyka kredytowego).

W pracy szczególną uwagę poświęcono metodycie budowy szczelnych potoków przetwarzania (*pipelines*), eliminujących zjawisko wycieku danych pomiędzy podzbiórami uczącymi a testowymi w procedurze walidacji krzyżowej. Dokonano również formalnej

weryfikacji hipotez badawczych za pomocą nieparametrycznych testów istotności statystycznej (testu rangowego Wilcoxona oraz testu Friedmana), co pozwoliło na sformułowanie uniwersalnych zaleceń inżynierskich dla praktyków data science.

Rozdział 1

Wprowadzenie

1.1 Motywacja i sformułowanie problemu

Rzeczywiste zbiory danych rzadko charakteryzują się idealną spójnością i kompletnością. Zjawiska takie jak błędy aparatury pomiarowej, subiektywizm personelu rejestrującego, usterki systemów teleinformatycznych czy naturalna zmienność biologiczna prowadzą do powstawania zanieczyszczeń w postaci brakujących wartości, błędów grubych oraz obserwacji skrajnie odstających.

Jak wskazuje Michael Walker w swojej pracy poświęconej recepturom czyszczenia danych w języku Python [1], etap przygotowania i oczyszczania zbioru pochłania w praktyce inżynierskiej nawet do 80% czasu poświęcanego na cały projekt analityczny. Walker podkreśla, że zanieczyszczenia danych nie mają charakteru jednorodnego — mogą wynikać zarówno ze strukturalnych braków rejestracji, jak i z obecności obserwacji ekstremalnych, zaburzających fundamentalne estymatory statystyczne (takie jak średnia, wariancja czy korelacje międzycechowe). Niewłaściwe lub bezrefleksyjne potraktowanie tych anomalii prowadzi do budowy modeli o zafałszowanych granicach decyzyjnych oraz niskiej zdolności generalizacji.

Co więcej, poszczególne rodziny algorytmów uczenia maszynowego — od metod probabilistycznych (Naiwny Klasyfikator Bayesa), przez sieci neuronowe (Perceptron Wielowarstwowy MLP), po modele zespołowe oparte na drzewach decyzyjnych (Lasy Losowe, XGBoost) — wykazują fundamentalnie różną wrażliwość na zaburzenia rozkładów, brak standaryzacji oraz obecność szumu. Zrozumienie, w jakim stopniu konkretne techniki czyszczenia danych wpływają na jakość i stabilność poszczególnych klasyfikatorów w

warunkach narastającej degradacji danych, stanowi istotne wyzwanie badawcze i praktyczne.

1.2 Cel pracy

Głównym celem niniejszej pracy magisterskiej jest empiryczne zbadanie i ilościowa ocena wpływu wybranych metod czyszczenia danych na jakość predykcyjną oraz stabilność czterech reprezentatywnych algorytmów klasyfikacji tabelarycznej w warunkach kontrolowanego stopnia zanieczyszczenia zbiorów.

Cel główny realizowany jest poprzez następujące cele szczegółowe:

1. Zaprojektowanie i implementacja modułowego potoku przetwarzania danych (ang. *preprocessing pipeline*) w języku Python, opartego na recepturach czyszczenia danych [1] i eliminującego ryzyko wycieku informacji (ang. *data leakage*) pomiędzy zbiorem uczącym a testowym.
2. Opracowanie metodyki kontrolowanej, wielostopniowej symulacji zanieczyszczeń (braków danych, wartości odstających oraz szumu kategorycznego) na zróżnicowanych zbiorach danych tabelarycznych.
3. Porównanie efektywności elementarnych strategii czyszczenia danych (imputacji statystycznej, imputacji sąsiedztwa KNN, filtracji wartości odstających regułą IQR, standaryzacji cech) oraz ich sekwencyjnych złożań.
4. Przeprowadzenie analizy wrażliwości poszczególnych architektur klasyfikatorów (GaussianNB, MLP, Random Forest, XGBoost) na narastający stopień degradacji danych wejściowych.

1.3 Tezy i pytania badawcze

W pracy sformułowano następujące tezy badawcze podlegające weryfikacji eksperymentalnej:

- T1.** Zastosowanie dedykowanych sekwencji czyszczenia danych pozwala na istotne ograniczenie spadku skuteczności klasyfikatorów przy rosnącym stopniu degradacji jakości zbioru wejściowego.
- T2.** Istnieje istotna asymetria wrażliwości pomiędzy badanymi rodzinami modeli: algorytmy oparte na optymalizacji gradientowej (MLP) oraz estymacji parametrów rozkładu (GaussianNB) zyskują na wieloetapowym czyszczeniu danych w stopniu znacznie wyższym niż modele zespołów drzew decyzyjnych (Random Forest, XGBoost).

- T3.** Zgodnie z metodyką proponowaną przez Walkera [1], kluczowe znaczenie dla poprawności statystycznej ma kolejność operacji: wcześniejsza identyfikacja i izolacja wartości odstających (zamiana na braki danych) przed etapem imputacji i standaryzacji zapobiega zniekształceniu wypełnianych wartości i maksymalizuje metrykę AUC.

1.4 Zakres pracy

Zakres zrealizowanych prac obejmuje:

- Przegląd literatury naukowej oraz współczesnych technik czyszczenia danych tabularycznych w języku Python ze szczególnym uwzględnieniem podejścia recepturowego [1].
- Przygotowanie pięciu zróżnicowanych zbiorów danych: zbioru pacjentów z układowym zapaleniem naczyń (*Zapalenia naczyń*), diagnostyki kardiologicznej (*Serce*), predykcji cukrzycy (*Diabetes*), odpływu klientów telekomunikacyjnych (*Rezygnacje*) oraz ryzyka kredytowego (*Kredyty*).
- Implementację autorskich transformatorów zgodnych ze standardem `scikit-learn`: detektora ekstremalnych wartości odstających `OutlierToNaNTransformer` (opartego na rozstępie IQR z mnożnikiem 3.0) oraz filtru rzadkich kategorii `RareCategoryToNaNTransformer`.
- Zbudowanie potoków przetwarzania implementujących 7 strategii czyszczenia danych: *raw*, *norm*, *fill*, *fill_knn*, *remove_fill*, *fill_norm* oraz pełnych potoków *all* i *all_knn*.
- Przeprowadzenie wielokrotnej powtarzanej stratyfikowanej walidacji krzyżowej (*Repeated Stratified K-Fold*) z rejestracją średniej wartości pola pod krzywą ROC ($\overline{AUC}$) oraz odchylenia standardowego (σ_{AUC}).

1.5 Struktura pracy

Układ niniejszej pracy przedstawia się następująco:

- **Rozdział 2 (Część teoretyczna)** prezentuje formalny opis problemów jakości danych w ujęciu Walkera [1], matematyczne podstawy metod czyszczenia, architekturę badanych klasyfikatorów oraz metryki ewaluacji jakości modeli.

- **Rozdział 3 (Środowisko i zbiory danych)** zawiera szczegółowy opis wykorzystanych narzędzi programistycznych, charakterystykę atrybutów badanych 5 zbiorów danych, a także opis procedury symulacji zanieczyszczeń i budowy potoków przetwarzania.
- **Rozdział 4 (Wyniki eksperymentów)** przedstawia zestawienia tabelaryczne, wykresy i analizę porównawczą skuteczności klasyfikatorów na poszczególnych zbiorach danych w zależności od stopnia uszkodzenia i zastosowanej metody czyszczenia.
- **Rozdział 5 (Podsumowanie i wnioski)** stanowi syntezę uzyskanych rezultatów, formalną weryfikację postawionych tez badawczych, odniesienie do wytycznych literaturowych oraz wskazanie perspektyw dalszego rozwoju projektu.

Rozdział 2

Część teoretyczna

2.1 Taksonomia problemów jakości danych tabelarycznych

Współczesna analiza danych tabelarycznych oraz uczenie maszynowe opierają się na założeniu, że zbiór uczący w sposób wierny odzwierciedla rozkład badanego zjawiska w populacji generalnej. W warunkach rzeczywistych dane wejściowe są jednak obarczone licznymi zniekształceniami. Jak wskazuje Walker [1], błędy te można podzielić na trzy fundamentalne kategorie: braki danych, zaburzenia rozkładów wywołane obserwacjami odstającymi oraz niespójności skali i reprezentacji kategoriycznej.

2.1.1 Mechanizmy powstawania braków danych

W teorii statystyki, sformułowanej pierwotnie przez Donalda Rubina [3], wyróżnia się trzy podstawowe mechanizmy generowania braków danych:

1. **MCAR (ang. *Missing Completely at Random*)** – braki całkowicie losowe. Prawdopodobieństwo wystąpienia braku w danej zmiennej nie zależy ani od wartości samej zmiennej, ani od wartości jakichkolwiek innych atrybutów w zbiorze:

$$P(M \mid Y_{\text{obs}}, Y_{\text{mis}}) = P(M), \quad (2.1)$$

gdzie M jest binarną macierzą wskaźnikową braków, Y_{obs} oznacza wartości zaobserwowane, a Y_{mis} wartości brakujące.

2. **MAR (ang. *Missing at Random*)** – braki losowe warunkowo. Prawdopodobieństwo braku zależy od innych zaobserwowanych zmiennych, lecz nie od samej wartości brakującej:

$$P(M \mid Y_{\text{obs}}, Y_{\text{mis}}) = P(M \mid Y_{\text{obs}}). \quad (2.2)$$

Przykładem jest sytuacja, w której częstość braków w wynikach badań laboratoryjnych zależy od wieku pacjenta lub płci.

3. **MNAR (ang. *Missing Not at Random*)** – braki nielosowe. Prawdopodobieństwo wystąpienia braku zależy bezpośrednio od niezaobserwowanej wartości (np. pacjenci z bardzo wysokim poziomem bólu częściej odmawiają udziału w badaniu).

Wybór odpowiedniej procedury imputacji musi uwzględniać powyższy charakter zjawiska, aby nie doprowadzić do zniekształcenia kowariancji cech [3, 1].

2.1.2 Wartości odstające i błędy grube

Wartości odstające (ang. *outliers*) to obserwacje, które w sposób drastyczny odbiegają od wzorca wyznaczonego przez przeważającą część zbioru. Mogą one wynikać z:

- **Błędów grubych aparatury i zapisu:** pomyłki jednostek (np. gramy zamiast miligramów), błędy wprowadzania danych z klawiatury (np. przesunięcie przecinka dziesiętnego), usterki czujników.
- **Naturalnej zmienności ekstremalnej:** rzadkie, lecz rzeczywiste przypadki kliniczne (np. pacjenci z ekstremalnym nasileniem wskaźników stanu zapalnego).

Obecność obserwacji odstających silnie zaburza nieodporne estymatory statystyczne. Przykładowo, średnia arytmetyczna $\hat{\mu}$ oraz wariancja próbkowa $\hat{\sigma}^2$ charakteryzują się zerowym punktem załamania (ang. *breakdown point* $\epsilon^* = 0$, wg teorii statystyki odpornej Hubera [4]), co oznacza, że pojedyncza skrajna wartość może dowolnie zmienić ich oszacowanie. Z kolei estymatory odporne, takie jak mediana czy rozstęp międzykwartylowy, zachowują stabilność przy obecności do 50% zaburzonych obserwacji [4, 1].

2.2 Metody wstępnego przetwarzania i czyszczenia danych

2.2.1 Uzupełnianie braków danych (Imputacja)

W praktyce inżynierii danych wyróżnia się podejścia proste (statystyczne) oraz zaawansowane (uczące się):

1. **Imputacja statystyczna:** zastąpienie braków wartością syntetyczną wyznaczoną globalnie na zbiorze uczącym:
 - dla cech ciągłych: mediana $\text{Med}(X)$ próby (bezpieczniejsza od średniej przy rozkładach skośnych) [1],
 - dla cech kategorycznych: dominanta (moda), czyli najczęściej występująca kategoria.

2. **Imputacja sąsiedztwa (KNNImputer)**: wielowymiarowa metoda estymacji braków bazująca na algorytmie k -najbliższych sąsiadów [24]. Dla dwóch obserwacji x, y , w których część cech może brakować, odległość euklidesowa z maskowaniem wyznaczana jest ze wzoru:

$$d(x, y) = \sqrt{\frac{p}{p_{\text{wspólne}}} \sum_{i \in \text{wspólne}} (x_i - y_i)^2}, \quad (2.3)$$

gdzie p to całkowita liczba cech, a $p_{\text{wspólne}}$ to liczba cech obserwowanych w obu rekordach jednocześnie. Brakująca wartość w rekordzie x jest następnie estymowana jako średnia ważona z k najbardziej podobnych rekordów:

$$\hat{x}_j = \frac{\sum_{m \in N_k(x)} w_m \cdot y_{m,j}}{\sum_{m \in N_k(x)} w_m}, \quad w_m = \frac{1}{d(x, y_m)}. \quad (2.4)$$

2.2.2 Identyfikacja i obsługa wartości odstających

W pracy zaimplementowano regułę rozstępu międzykwartylowego (IQR) zaproponowaną przez Johna Tukeya [2]. Kwartyle Q_1 i Q_3 dzielą uporządkowany ciąg danych na cztery równe części, a rozstęp międzykwartylowy definiowany jest jako:

$$\text{IQR} = Q_3 - Q_1. \quad (2.5)$$

W klasycznym podejściu Tukeya [2] wyróżnia się:

- anomalie umiarkowane: $x \notin [Q_1 - 1,5 \cdot \text{IQR}, Q_3 + 1,5 \cdot \text{IQR}]$,
- anomalie ekstremalne: $x \notin [Q_1 - 3,0 \cdot \text{IQR}, Q_3 + 3,0 \cdot \text{IQR}]$.

Zgodnie z recepturami Walkera [1], w niniejszej pracy zastosowano próg $3,0 \cdot \text{IQR}$, aby odfiltrować wyłącznie bezdyskusyjne błędy grube i anomalie skrajne. Zamiast agresywnego usuwania całych rekordów (co prowadzi do utraty cennych informacji w pozostałych poprawnych kolumnach), zaimplementowany transformator `OutlierToNaNTransformer` zamienia wykryte outliery na wartości NaN, umożliwiając ich późniejszą poprawną rekonstrukcję w module imputacji.

Do metod wielowymiarowej detekcji anomalii należy algorytm **Isolation Forest** [8]. Metoda ta buduje zespół losowych drzew decyzyjnych (*iTrees*). Punkty odstające, jako rzadkie i odizolowane, wymagają znacznie mniejszej liczby podziałów do ich wyodrębnienia. Wskaźnik anomalii dla obserwacji x definiowany jest jako:

$$s(x, n) = 2^{-\frac{\mathbb{E}(h(x))}{c(n)}}, \quad (2.6)$$

gdzie $h(x)$ to długość ścieżki w drzewie, $\mathbb{E}(h(x))$ to średnia długość ścieżki w zespole, a $c(n) = 2 \ln(n-1) + 0,5772 - \frac{2(n-1)}{n}$ jest średnią długością ścieżki nieudanego wyszukiwania w drzewie BST dla n obserwacji. Wartość $s \rightarrow 1$ jednoznacznie identyfikuje anomalię [8].

2.2.3 Skalowanie atrybutów i kodowanie zmiennych jakościowych

1. **Standaryzacja z-score:** przekształca zmienną losową do postaci o zerowej średniej i jednostkowej wariancji:

$$z = \frac{x - \mu}{\sigma}, \quad (2.7)$$

gdzie parametry μ, σ są wyznaczone wyłącznie na próbce uczącej.

2. **Skalowanie min-max:** mapuje wartości do zamkniętego przedziału $[0, 1]$:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}. \quad (2.8)$$

3. **Kodowanie One-Hot (OneHotEncoder):** przekształca cechę kategoriową o C unikalnych poziomach w C binarnych wektorów wskaźnikowych. W celu uniknięcia problemu rzadkich kategorii wprowadzono transformator `RareCategoryToNaNTransformer`, który kategorie o częstości występowania poniżej progu 5% konwertuje do postaci braków danych przed etapem kodowania.

2.3 Wybrane algorytmy klasyfikacji

2.3.1 Naiwny Klasyfikator Bayesa (Gaussian Naive Bayes)

Naiwny Klasyfikator Bayesa opiera się na bezpośrednim zastosowaniu twierdzenia Bayesa przy założeniu warunkowej niezależności cech $x_1, \dots, x_p$ względem zmiennej decyzyjnej $y \in \{0, 1\}$ [5, 25]:

$$P(y = c | x) = \frac{P(y = c) \prod_{j=1}^p P(x_j | y = c)}{P(x)}. \quad (2.9)$$

W wariancie `GaussianNB` zakłada się, że rozkład warunkowy każdej cechy ciągłej jest rozkładem normalnym:

$$P(x_j | y = c) = \frac{1}{\sqrt{2\pi\sigma_{jc}^2}} \exp\left(-\frac{(x_j - \mu_{jc})^2}{2\sigma_{jc}^2}\right). \quad (2.10)$$

Parametry μ_{jc} i σ_{jc}^2 estymowane są za pomocą średniej i wariancji próbkowej. W konsekwencji obecność nieodfiltrowanych wartości odstających drastycznie zniekształca parametry gęstości prawdopodobieństwa, powodując załamanie zdolności predykcyjnej klasyfikatora.

2.3.2 Perceptron Wielowarstwowy (MLP)

MLP (ang. *Multilayer Perceptron*) to sieć neuronowa o architekturze jednokierunkowej, uczona z nadzorem [5, 26]. Dla pojedynczego neuronu w warstwie ukrytej sygnał wyjściowy wyznaczany jest jako:

$$a = f \left(\sum_{j=1}^p w_j x_j + b \right), \quad (2.11)$$

gdzie w_j oznaczają wagi połączeń, b to obciążenie (bias), a $f(\cdot)$ jest nieliniową funkcją aktywacji (np. ReLU: $f(s) = \max(0, s)$).

Proces uczenia polega na minimalizacji funkcji straty (entropii krzyżowej dla klasyfikacji binarnej):

$$\mathcal{L}(w, b) = -\frac{1}{N} \sum_{i=1}^N [y_i \ln \hat{y}_i + (1 - y_i) \ln(1 - \hat{y}_i)] + \frac{\alpha}{2} \|w\|_2^2, \quad (2.12)$$

za pomocą algorytmu optymalizacji opartego na gradientach (Adam [9]). Brak standaryzacji cech wejściowych prowadzi do złego uwarunkowania macierzy drugich pochodnych (hesjanu), co wywołuje zjawisko oscylacji gradientu i uniemożliwia zbieżność procesu uczenia.

2.3.3 Lasy Losowe (Random Forest)

Algorytm Lasów Losowych, opracowany przez Leo Breimana [6], stanowi zespół wielu drzew decyzyjnych uczonych metodą agregacji bootstrapowej (bagging). Każde drzewo T_b budowane jest na niezależnej próbie losowej ze zwracaniem $D_b \subset D$. W każdym węźle drzewa optymalny podział wyznaczany jest wyłącznie spośród losowo wybranego podzbioru $m \approx \sqrt{p}$ cech.

Kryterium oceny jakości podziału węzła stanowi zanieczyszczenie Giniego (ang. *Gini Impurity*):

$$I_G(t) = 1 - \sum_{k=1}^K p_k^2, \quad (2.13)$$

gdzie p_k to frakcja obserwacji klasy k w węźle t . Ponieważ decyzje podziału w drzewach decyzyjnych zależą wyłącznie od porządku relacyjnego wartości atrybutu ($x_j \leq \theta$), Lasy

Losowe są całkowicie niewrażliwe na monotoniczne transformacje i brak standaryzacji cech [6, 5].

2.3.4 XGBoost (Extreme Gradient Boosting)

XGBoost [7] jest algorytmem sekwencyjnego wzmacniania gradientowego. W odróżnieniu od baggingu, każde kolejne drzewo $f_t(x)$ jest dopasowywane do residuów (błędów) popołnionych przez dotychczasowy zespół:

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i). \quad (2.14)$$

Funkcja celu w kroku t przyjmuje postać:

$$\text{Obj}^{(t)} = \sum_{i=1}^N l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t), \quad (2.15)$$

gdzie człon regularyzacyjny drzewa o T liściach i wagach w definiowany jest jako:

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 + \alpha \sum_{j=1}^T |w_j|. \quad (2.16)$$

Stosując rozwinięcie funkcji straty w szereg Taylora drugiego rzędu, otrzymuje się uproszczoną postać celu:

$$\widetilde{\text{Obj}}^{(t)} \approx \sum_{i=1}^N \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t), \quad (2.17)$$

gdzie $g_i = \partial_{\hat{y}^{(t-1)}} l(y_i, \hat{y}^{(t-1)})$ oraz $h_i = \partial_{\hat{y}^{(t-1)}}^2 l(y_i, \hat{y}^{(t-1)})$. Optymalna waga liścia j wynosi:

$$w_j^* = - \frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda}, \quad (2.18)$$

a zysk z podziału węzła na podzbiory I_L i I_R dany jest wzorem:

$$\text{Gain} = \frac{1}{2} \left[\frac{(\sum_{i \in I_L} g_i)^2}{\sum_{i \in I_L} h_i + \lambda} + \frac{(\sum_{i \in I_R} g_i)^2}{\sum_{i \in I_R} h_i + \lambda} - \frac{(\sum_{i \in I} g_i)^2}{\sum_{i \in I} h_i + \lambda} \right] - \gamma. \quad (2.19)$$

2.4 Metryki oceny jakości modeli i aparat statystyczny

2.4.1 Krzywa ROC i pole pod krzywą (AUC)

Krzywa ROC przedstawia zależność pomiędzy czułością (TPR) a odsetkiem fałszywych alarmów (FPR) dla zmiennego progu klasyfikacji $\theta \in [0, 1]$ [10]:

$$\text{TPR}(\theta) = \frac{\text{TP}(\theta)}{\text{TP}(\theta) + \text{FN}(\theta)}, \quad \text{FPR}(\theta) = \frac{\text{FP}(\theta)}{\text{FP}(\theta) + \text{TN}(\theta)}. \quad (2.20)$$

Pole pod krzywą ROC (AUC) posiada jednoznaczną interpretację probabilistyczną: stanowi prawdopodobieństwo, że losowo wybrana obserwacja z klasy pozytywnej otrzyma od modelu wyższą ocenę punktową (score) niż losowo wybrana obserwacja z klasy negatywnej [10, 11]:

$$\text{AUC} = P(\hat{y}(x^+) > \hat{y}(x^-)). \quad (2.21)$$

Wartość AUC jest ściśle równoważna znormalizowanej statystyce Manna-Whitneya U [11]:

$$\text{AUC} = \frac{U}{n^+ \cdot n^-} = \frac{R^+ - \frac{n^+(n^++1)}{2}}{n^+ \cdot n^-}, \quad (2.22)$$

gdzie R^+ oznacza sumę rang przypisanych obserwacjom pozytywnym.

2.4.2 Nieparametryczne testy istotności statystycznej

W celu rzetelnego porównania metod czyszczenia danych zastosowano nieparametryczne testy rangowe:

1. **Test rangowy znaków Wilcoxona** [12]: nieparametryczny odpowiednik testu t -Studenta dla prób zależnych. Dla par wyników (x_i, y_i) oblicza się różnice $d_i = x_i - y_i$, a następnie porządkuje ich wartości bezwzględne, przypisując im rangi R_i . Statystyka testowa wynosi:

$$W = \min(W^+, W^-), \quad W^+ = \sum_{d_i > 0} R_i, \quad W^- = \sum_{d_i < 0} R_i. \quad (2.23)$$

2. **Test Friedmana** [13]: wielogrupowy test rangowy do weryfikacji hipotezy o braku różnic pomiędzy k metodami ewaluowanymi na N zbiorach prób. Statystyka testowa ma postać:

$$\chi_F^2 = \frac{12N}{k(k+1)} \left[\sum_{j=1}^k \bar{R}_j^2 - \frac{k(k+1)^2}{4} \right], \quad (2.24)$$

gdzie $\bar{R}_j$ to średnia ranga j -tej metody.

Rozdział 3

Środowisko i zbiory danych

3.1 Wykorzystane narzędzia i biblioteki

Całość prac badawczo-implementacyjnych zrealizowano w języku programowania **Python** (wersja 3.10+), stanowiącym obecnie dominujący standard w inżynierii danych i uczeniu maszynowym [1]. W projekcie wykorzystano wyspecjalizowany zestaw bibliotek open-source:

- **Pandas** [17] (wersja 2.x) – wykorzystywana do profilowania danych, identyfikacji brakujących pól, konwersji typów zmiennych oraz operacji tabelarycznych,
- **NumPy** [16] – zapewniająca wydajne operacje macierzowe oraz funkcje losowania pseudolosowego z użyciem generatora `default_rng`,
- **scikit-learn** [15] – główny szkielet eksperymentalny; posłużyła do implementacji klasyfikatorów (`GaussianNB`, `MLPClassifier`, `RandomForestClassifier`), procedur podziału stratyfikowanego (`StratifiedKFold`), transformatorów czyszczących (`SimpleImputer`, `KNNImputer`, `StandardScaler`, `OneHotEncoder`) oraz obiektów potokowych (`Pipeline`, `ColumnTransformer`),
- **XGBoost** [7] – wysoce zoptymalizowana implementacja algorytmu Extreme Gradient Boosting zintegrowana ze standardem interfejsu `scikit-learn`,
- **Joblib** – biblioteka służąca do zrównoleglenia powtarzanych procedur walidacji krzyżowej na wielordzeniowych jednostkach obliczeniowych CPU,
- **Matplotlib** [18] oraz **Seaborn** [19] – narzędzia graficzne zastosowane do automatycznego generowania krzywych odporności modeli, macierzy korelacji, wykresów radarowych oraz heatmap zysku ΔAUC .

3.2 Charakterystyka badanych zbiorów danych

W badaniach empirycznych wykorzystano pięć zróżnicowanych zbiorów danych tabelarycznych, reprezentujących odmienne domeny zastosowań (medycyna kliniczna, diagnostyka kardiologiczna, telekomunikacja, bankowość). Taki dobór danych pozwolił na weryfikację zachowania metod czyszczenia zarówno na zbiorach o dominacji cech ciągłych, jak i silnie wymieszanych z atrybutami kategorycznymi, a także przy różnym stopniu zrównoważenia klas decyzyjnych. Zbiorcze zestawienie parametrów zbiorów przedstawiono w tabeli 3.1.

Tabela 3.1: Zbiorcze zestawienie charakterystyki badanych zbiorów danych

Zbiór danych	Liczba prób	Liczba cech	Cechy ciągłe	Cechy kateg.	Balans klas (0 / 1)
Zapalenia naczyń	848	143	15	128	702 / 146 (82,8% / 17,2%)
Serce (Heart)	270	13	5	8	150 / 120 (55,6% / 44,4%)
Cukrzyca (Diabetes)	768	8	8	0	500 / 268 (65,1% / 34,9%)
Rezygnacje (Churn)	3333	19	15	4	2850 / 483 (85,5% / 14,5%)
Kredyty (German)	1000	10	3	7	700 / 300 (70,0% / 30,0%)

3.2.1 Zbiór „Zapalenia naczyń” (Vasculitis)

Zbiór ten obejmuje rzeczywiste dane kliniczne pacjentów diagnozowanych i leczonych z powodu układowych zapaleń naczyń (ang. *systemic vasculitis*). Zadaniem klasyfikacyjnym jest predykcja binarnej zmiennej decyzyjnej Zgon (0 – przeżycie pacjenta, 1 – zgon). Zgodnie z recepturami wstępnego profilowania danych [1], wykluczono techniczny identyfikator pacjenta (Kod). Pozostałe 143 atrybuty wejściowe obejmują:

- **Wskaźniki ciągłe (15 cech):** wiek pacjenta w latach (Wiek), wiek w chwili postawienia diagnozy (Wiek_rozpoznania), czas opóźnienia rozpoznania (Opoznienie_Rozpozna), wskaźnik palenia tytoniu w paczkoletach (Paczkoleta), liczba narządów objętych aktywnym procesem chorobowym (Liczba_Zajetych_Narzadow), liczba zaostrzeń choroby (Liczba_Zaostrzen), czas do wystąpienia pierwszego zaostrzenia (Czas_Pierwsze_Zaostrzenie), stężenie kreatyniny w surowicy (Kreatynina), maksymalne stężenie białka C-reaktywnego (Max_CRP), łączne dawki glikokortykosteroidów (Sterydy_Dawka_g, Sterydy_Dawka_mg), całkowity czas trwania sterydoterapii (Czas_Sterydow) oraz miana przeciwciał i markerów immunologicznych (Anti-PR3_Wartosc, Anti-MPO_Wartosc, Eozynofilia_Krwi_Obwodowej_Wartosc).
- **Wskaźniki jakościowe i binarne (128 cech):** płeć, specyficzne rozpoznania kliniczne (np. GPA, EGPA, MPA, choroba Takayasu, choroba Kawasaki), manifestacje

narządowe (płucne, sercowo-naczyniowe, nerkowe, laryngologiczne, ośrodkowego układu nerwowego), wyniki biopsji tkankowych oraz schematy farmakoterapii (cyklofosfamid, rituximab, mykofenolan mofetylu, azatiopryna, metotreksat).

3.2.2 Zbiór „Serce” (Heart Disease)

Klasyczny zbiór referencyjny pochodzący ze zbiorów UCI Machine Learning Repository [20] (baza Statlog/Cleveland). Zadaniem jest rozpoznanie obecności istotnych zmian miażdżycowych w naczyniach wieńcowych (diagnoza: 0 – brak choroby, 1 – choroba serca). Zbiór zawiera 13 cech diagnostycznych:

- **Cechy ciągłe (5 atrybutów):** wiek pacjenta (`wiek`), spoczynkowe ciśnienie tętnicze krwi (`cisnienie_krwi_spoczynek`), stężenie cholesterolu całkowitego w surowicy (`cholesterol_we_krwi`), maksymalna częstość akcji serca osiągnięta w trakcie próby wysiłkowej (`ilosc_uderzen_serca`) oraz obniżenie odcinka ST wywołane wysiłkiem fizycznym (`max_obnizka_st`).
- **Cechy kateryczne (8 atrybutów):** płeć (`plec`), typ dolegliwości bólowych w klatce piersiowej (`typ_bolu_klatka`), stężenie glukozy na czczo powyżej 120 mg/dl (`cukier_we_krwi`), spoczynkowy wynik elektrokardiogramu (`wynik_ekg_spoczynek`), dławica piersiowa wywołana wysiłkiem (`bol_klatka_wysilek`), nachylenie odcinka ST na szczycie wysiłku (`przebieg_st_szczyt`), liczba głównych naczyń zabarwionych podczas fluoroskopii (zwapnienia miażdżycowe) oraz wynik scyntygrafii perfuzyjnej mięśnia sercowego (`proba_ta`).

3.2.3 Zbiór „Diabetes” (Pima Indians Diabetes)

Zbiór pochodzący z repozytorium UCI [20], służący do prognozowania wystąpienia cukrzycy u kobiet z populacji Indian Pima na podstawie parametrów fizjologicznych i biochemicznych. Zmienna celu (`decision`) przyjmuje wartości binarne (0 – brak cukrzycy, 1 – potwierdzona cukrzyca). Wszystkie 8 atrybutów wejściowych ma charakter ciągły:

- liczba przebytych ciąż (`preg`),
- stężenie glukozy w osoczu krwi po doustnym teście tolerancji glukozy (`plas`),
- rozkurczowe ciśnienie tętnicze krwi (`pres`),
- grubość fałdu skórno-tłuszczowego na mięśniu trójgłowym ramienia (`skin`),
- 2-godzinne stężenie insuliny w surowicy (`insu`),
- wskaźnik masy ciała BMI (`mass`),

- wskaźnik obciążenia genetycznego rodowodem cukrzycy (pedi),
- wiek pacjentki w latach (age).

3.2.4 Zbiór „Rezygnacje” (Customer Churn)

Zbiór danych pochodzący z sektora telekomunikacyjnego, wykorzystywany do detekcji zjawiska migracji klientów (ang. *customer churn*). Zadaniem klasyfikacyjnym jest predykcja binarnej decyzji klienta o rezygnacji z usług operatora (REZYGN: 0 – lojalny klient, 1 – odejście do konkurencji). Po wykluczeniu numeru telefonu klienta (NR_TEL), zestaw zawiera:

- **Cechy ciągłe (15 atrybutów):** czas trwania umowy w miesiącach (CZAS_POSIADANIA), liczba odsłuchanych wiadomości poczty głosowej (L_WIAD_POCZTA_G), łączna liczba minut, liczba połączeń oraz naliczona opłata w strefie dziennej (DZIEN_MIN, DZIEN_L_POL, DZIEN_OPLATA), strefie wieczornej (WIECZOR_MIN, WIECZ_L_POL, WIECZ_OPLATA), strefie nocnej (NOC_MIN, NOC_L_POL, NOC_OPLATA), strefie połączeń międzynarodowych (MIEDZY_MIN, MIEDZY_L_POL, MIEDZY_OPLATA) oraz liczba kontaktów z biurem obsługi klienta (L_POL_BIURO).
- **Cechy katerygoryczne (4 atrybuty):** kod stanu zamieszkania (STAN), numer kierunkowy obszaru (KOD_OBSZARU), aktywność międzynarodowego planu taryfowego (PLAN_MIEDZY) oraz aktywność usługi poczty głosowej (POCZTA_G).

3.2.5 Zbiór „Kredyty” (German Credit)

Klasyczny zbiór oceny ryzyka kredytowego (ang. *credit scoring*) z repozytorium UCI [20] (Statlog German Credit). Zadaniem jest klasyfikacja wiarygodności finansowej klienta wnioskującego o pożyczkę (Kredyt: good → 0 – niski poziom ryzyka, bad → 1 – wysokie ryzyko niewypłacalności). Zbiór charakteryzuje się silną obecnością atrybutów jakościowych:

- **Cechy ciągłe (3 atrybuty):** czas trwania bieżącego rachunku lub wnioskowanej pożyczki w miesiącach (Czas_trwania_konta), całkowita kwota wnioskowanego kredytu (Kwota_kredytu) oraz wiek klienta w latach (Wiek).
- **Cechy katerygoryczne (7 atrybutów):** deklarowany cel pożyczki (Cel_kredytu), staż pracy i czas zatrudnienia (Czas_zatrudnienia), płeć powiązana ze stanem cywilnym (Plec_i_stan_cywilny), czas zamieszkiwania pod obecnym adresem (Czas_od_zamieszkania), liczba spłacanych kredytów w banku (Liczba_kredytow_w_banku), status zawodowy (Praca) oraz liczba osób pozostających na utrzymaniu pożyczkobiorcy (Liczba_osob_na_utrzymaniu).

3.3 Metodologia symulacji kontrolowanych zanieczyszczeń

W celu rzetelnej, ilościowej oceny skuteczności poszczególnych receptur czyszczenia danych, zbiory oryginalne poddano kontrolowanej procedurze sztucznego wprowadzania zaburzeń. W eksperymentach zdefiniowano pięć rosnących poziomów degradacji: $p \in \{10\%, 20\%, 30\%, 40\%, 50\%\}$. Każdy poziom generowano w 3 niezależnych powtórzeniach losowych z wykorzystaniem generatora liczb pseudolosowych `numpy.random.default_rng`.

Zgodnie z systematyką problemów jakości danych opisaną przez Walkera [1], wprowadzono trzy typy zanieczyszczeń:

1. **Braki danych (ang. *missing data*):** losowe usuwanie wartości w kolumnach z prawdopodobieństwem p , zastępując je wartością NaN (symulacja mechanizmu braków całkowicie przypadkowych MCAR).
2. **Ekstremalne wartości odstające (ang. *extreme outliers*):** losowy wybór obserwacji w liczbie proporcjonalnej do poziomowi degradacji i ich modyfikacja poprzez drastyczne mnożniki:

$$x_{\text{dirty}} = x \cdot c, \quad c \in \{20, 40, 80, -20\}. \quad (3.1)$$

Zabieg ten odzwierciedla błędy grube aparatury pomiarowej, pomyłki skali lub błędne jednostki metryczne [1].

3. **Szum w zmiennych kategoriowych:** losowe wstrzykiwanie rzadkiej, nieprawidłowej wartości "9", symulującej błędne kody kategorii lub usterki systemów ankietowych.

3.4 Architektura potoku przetwarzania i uzasadnienie doboru strategii

Wszystkie operacje przetwarzania danych zorganizowano w postaci modularnych obiektów Pipeline oraz ColumnTransformer z biblioteki `scikit-learn`. Podejście to, rekomendowane przez Walkera [1], gwarantuje całkowitą hermetyzację transformacji — parametry czyszczenia (progi IQR, mediany, średnie, parametry skalarów) są wyznaczone wyłącznie w fazie `fit` na podzbiorze uczącym, a następnie aplikowane do podzbioru testowego (`transform`), co eliminuje błąd wycieku danych (*data leakage*).

3.4.1 Trzy filary przetwarzania wstępnego

W badaniach nad jakością klasyfikatorów tabelarycznych wyodrębniono trzy fundamentalne operacje inżynierii danych:

1. O_1 – **Eliminacja i obsługa wartości odstających**: identyfikacja anomalii regułą rozstępu międzykwartylowego ($3 \cdot \text{IQR}$) i ich konwersja do braków danych (NaN) przez autorski transformator `OutlierToNaNTransformer`.
2. O_2 – **Imputacja braków danych**: rekonstrukcja wartości brakujących za pomocą estymatorów statystycznych (mediana/dominanta) lub algorytmu k -najbliższych sąsiadów (`KNNImputer`, $k = 5$).
3. O_3 – **Standaryzacja i kodowanie cech**: przekształcenie z -score ($\mu = 0, \sigma = 1$) za pomocą `StandardScaler` oraz binarne kodowanie cech kategoriowych (`OneHotEncoder`) po uprzedniej filtracji rzadkich poziomów (`RareCategoryToNaNTransformer`).

3.4.2 Redukcja pełnego planu czynnikowego ($2^3 = 8$) do zestawu strategii praktycznych

Początkowy plan badawczy zakładał pełny układ kombinatoryczny $2^3 = 8$ metod:

$$\mathcal{S}_{\text{pełny}} = \{\text{raw}, \text{norm}, \text{fill}, \text{remove}, \text{remove_fill}, \text{remove_norm}, \text{fill_norm}, \text{all}\}. \quad (3.2)$$

W toku analizy metodologicznej zidentyfikowano jednak krytyczne wady wariantów pozostawionych kroku imputacji (fill):

- **Problem sztucznej stałej w metodzie remove**: W operacji `remove` wykryte anomalie zamieniane są na NaN. Brak późniejszego etapu rekonstrukcji wymusza zastąpienie braków techniczną wartością stałą (np. $-999,0$), aby umożliwić działanie klasyfikatorów. Procedura ta de facto tworzy nową, skrajną wartość odstającą, negując sens eliminacji anomalii.
- **Zniekształcenie parametrów rozkładu w metodzie norm**: Standaryzacja cech w obecności nieskorygowanych wartości odstających prowadzi do błędnej estymacji średniej $\hat{\mu}$ oraz drastycznego zawyżenia odchylenia standardowego $\hat{\sigma}$. W rezultacie typowe wartości cech ulegają sztucznej kompresji blisko zera.

Z tego względu przestrzeń badawcza została zoptymalizowana i rozszerzona o bezpośrednie porównanie paradygmatów imputacji (statystyczna vs sąsiedztwa KNN), tworząc zestaw 7 komplementarnych strategii badawczych zestawionych w tabeli 3.2.

Tabela 3.2: Zestawienie badanych strategii czyszczenia danych w potokach przetwarzania

Kod strategii	Składowe potoku (Pipeline)	Uzasadnienie i rola badawcza
raw	Brak operacji (maskowanie –999)	Punkt odniesienia (<i>baseline</i>) – degradacja bez interwencji.
fill	Imputacja medianą i dominantą	Wpływ samej prostej rekonstrukcji braków.
fill_knn	Imputacja k -NN ($k = 5$)	Wpływ wielowymiarowej rekonstrukcji opartej na sąsiedztwie.
remove_fill	Outliery ($3 \cdot \text{IQR}$) → Mediana	Dwuetałowa korekcja: oczyszczenie rozkładu przed imputacją.
fill_norm	Mediana → Standaryzacja z -score	Wpływ skalowania na poprawnie zaimputowanych danych.
all	Outliery → Mediana → Standaryzacja	Pełny klasyczny potok inżynierii danych [1].
all_knn	Outliery → k -NN → Standaryzacja	Zaawansowany potok łączący filtrację z modelowaniem k -NN.

3.5 Protokół eksperymentalny i parametryzacja klasyfikatorów

W celu uzyskania odpornych i statystycznie istotnych wyników zastosowano procedurę powtarzanej stratyfikowanej walidacji krzyżowej (*Repeated Stratified K-Fold*) z podziałem na 4 lub 5 foldów i ewaluacją na 3–5 niezależnych ziarnach losowości.

Dla każdego podziału ewaluowano 4 klasyfikatory o ustalonej parametryzacji:

- **Random Forest (RF):** `n_estimators=220, random_state=seed`.
- **Gaussian Naive Bayes (NB):** model probabilistyczny z domyślną estymacją parametrów rozkładu normalnego.
- **Perceptron Wielowarstwowy (MLP):** sieć o architekturze z jedną warstwą ukrytą (100 neuronów, aktywacja ReLU, optymalizator Adam, wczesne zatrzymanie `early_stopping=True, n_iter_no_change=15`).
- **XGBoost:** `n_estimators=180, max_depth=4, learning_rate=0.07, subsample=0.9, colsample_bytree=0.9`, funkcja straty `logloss`.

Jako główną miarę ewaluacji przyjęto średnią arytmetyczną pola pod krzywą ROC ($\overline{\text{AUC}}$) oraz odchylenie standardowe σ_{AUC} liczone po wszystkich foldach i powtórzeniach walidacji.

Rozdział 4

Wyniki eksperymentów

W niniejszym rozdziale przedstawiono szczegółowe rezultaty przeprowadzonych badań empirycznych, których celem była ocena wpływu 7 strategii czyszczenia danych na jakość i stabilność czterech architektur klasyfikatorów (Random Forest, XGBoost, Gaussian Naive Bayes, MLP). Eksperymenty zrealizowano na 5 zbiorach danych poddanych kontrolowanej degradacji jakości na pięciu poziomach uszkodzeń (10%, 20%, 30%, 40%, 50%) w procedurze wielokrotnej stratyfikowanej walidacji krzyżowej.

Główną miarą oceny jakości predykcji jest pole pod krzywą ROC ($\overline{AUC}$) wraz z odchyleniem standardowym σ_{AUC} , a także zysk predykcyjny definiowany jako różnica względem danych nieoczyszczonych:

$$\Delta AUC = \overline{AUC}_{\text{metoda}} - \overline{AUC}_{\text{raw}}. \quad (4.1)$$

4.1 Wyniki bazowe i ogólna charakterystyka odporności modeli


W tabeli 4.1 zestawiono wyniki bazowe uzyskane na oryginalnych (czystych) zbiorach danych, stanowiące górną granicę skuteczności dla każdego z modeli.

Tabela 4.1: Skuteczność klasyfikatorów ($\overline{AUC} \pm \sigma_{AUC}$) na oryginalnych zbiorach danych

Zbiór danych	Random Forest (RF)	XGBoost	Gaussian NB	MLP (Sieć neuronowa)
Zapalenia naczyń	0,9391 $\pm$ 0,005	0,9363 $\pm$ 0,004	0,8721 $\pm$ 0,003	0,7407 $\pm$ 0,020
Serce (Heart)	0,9075 $\pm$ 0,010	0,8912 $\pm$ 0,010	0,8872 $\pm$ 0,007	0,6132 $\pm$ 0,134
Cukrzyca (Diabetes)	0,8302 $\pm$ 0,001	0,8165 $\pm$ 0,000	0,8149 $\pm$ 0,001	0,6395 $\pm$ 0,040
Rezygnacje (Churn)	0,9143 $\pm$ 0,003	0,9165 $\pm$ 0,004	0,6527 $\pm$ 0,007	0,6874 $\pm$ 0,145
Kredyty (German)	0,6839 $\pm$ 0,003	0,6828 $\pm$ 0,011	0,6316 $\pm$ 0,005	0,4590 $\pm$ 0,013

Najwyższą jakość predykcyjną na czystych danych osiągają modele zespołowe (Random Forest oraz XGBoost), uzyskując na zbiorach medycznych $\overline{AUC} > 0,90$. Naiwny Klasyfikator Bayesa wykazuje stabilne rezultaty rzędu 0,81 – 0,88 na danych medycznych, jednak radzi sobie słabiej w zadaniach o silnych interakcjach nieliniowych (np. zbiór *Rezygnacje*). Z kolei sieć MLP bez zaawansowanego strojenia hiperparametrów osiąga najniższe wartości bazowe oraz charakteryzuje się podwyższoną wariancją wyników (σ_{AUC} do 0,145).

Ogólną dynamikę spadku jakości modeli pod wpływem degradacji danych przedstawiono na rysunku 4.1.



Rysunek 4.1: Zbiorcze krzywe odporności klasyfikatorów: średnia wartość AUC w funkcji poziomu uszkodzeń danych dla 7 badanych strategii czyszczenia

Wykres zbiorczy uwidacznia fundamentalną prawidłowość: brak procedur czyszczących (*raw* – linia pomarańczowa) prowadzi do gwałtownej degradacji jakości predykcyjnej wszystkich modeli. Zastosowanie pełnego potoku czyszczącego (*all* oraz *all_knn*) skutecznie hamuje spadek AUC, zachowując najwyższą użyteczność decyzyjną modeli nawet przy 50% stopniu uszkodzenia atrybutów.

4.2 Szczegółowa analiza wyników na poszczególnych zbiorach danych

4.2.1 Ocena na zbiorze „Zapalenia naczyń”


Zbiór kliniczny pacjentów z zapaleniem naczyń charakteryzuje się dużą liczbą cech (143) oraz obecnością kluczowych markerów stanu zapalnego. Wyniki klasyfikacji w zależności od stopnia uszkodzenia i zastosowanej metody zestawiono w tabeli 4.2.

Tabela 4.2: Wyniki $\overline{AUC}$ na zbiorze „Zapalenia naczyń” dla wybranych poziomów degradacji


Model	Poziom uszkodzeń	raw	fill	fill_knn	remove_fill	fill_norm	all
RF	Uszkodzenie 10%	0,9248	0,9315	0,9289	0,9295	0,9315	0,9318
	Uszkodzenie 30%	0,8845	0,9082	0,9024	0,9065	0,9082	0,9112
	Uszkodzenie 50%	0,8124	0,8641	0,8580	0,8612	0,8641	0,8695
XGBoost	Uszkodzenie 10%	0,9195	0,9280	0,9254	0,9268	0,9280	0,9291
	Uszkodzenie 30%	0,8712	0,9014	0,8965	0,8998	0,9014	0,9045
	Uszkodzenie 50%	0,7986	0,8523	0,8460	0,8501	0,8523	0,8574
NB	Uszkodzenie 10%	0,8315	0,8592	0,8561	0,8580	0,8512	0,8615
	Uszkodzenie 30%	0,7342	0,8125	0,8104	0,8115	0,7980	0,8190
	Uszkodzenie 50%	0,6210	0,7450	0,7412	0,7438	0,7290	0,7562
MLP	Uszkodzenie 10%	0,6812	0,6945	0,6910	0,6930	0,7312	0,7380
	Uszkodzenie 30%	0,5740	0,6120	0,6085	0,6105	0,6895	0,6984
	Uszkodzenie 50%	0,5120	0,5412	0,5380	0,5400	0,6315	0,6420

Na rysunku 4.2 zaprezentowano ciągłe krzywe odporności modeli, natomiast na rysunku 4.3 przedstawiono szczegółowy rozkład słupkowy skuteczności metod naprawy z uwzględnieniem odchyłeń standardowych przy uszkodzeniu 30%. Rysunek 4.4 przedstawia ranking ważności cech (*Feature Importance*).

Krzywe odporności na uszkodzenia danych - Zapalenia



Rysunek 4.2: Krzywe odporności modeli na zbiorze „Zapalenia naczyń” dla poszczególnych strategii czyszczenia



Rysunek 4.3: Porównanie skuteczności metod czyszczenia danych wraz ze słupkami błędów na zbiorze „Zapalenia naczyń” przy poziomie uszkodzeń 30%




Rysunek 4.4: Ranking 15 najważniejszych cech w zbiorze „Zapalenia naczyń” wg modelu Random Forest

Analiza ważności atrybutów jednoznacznie wskazuje, że kluczowymi predyktorami zgonu w układowych zapaleniach naczyń są: maksymalny poziom białka C-reaktywnego (Max_CRP), stężenie kreatyniny, wiek pacjenta oraz dawki i czas trwania sterydoterapii. Zniekształcenie tych kluczowych parametrów przy braku czyszczenia obniża AUC modelu Random Forest z 0,939 do 0,812 przy uszkodzeniu 50%. Zastosowanie potoku *all* pozwala odzyskać ponad 0,057 AUC, utrzymując model na wysokim poziomie 0,869.


4.2.2 Ocena na zbiorze „Serce” (Heart Disease)

Zbiór kardiologiczny stanowi reprezentatywny przykład danych o zrównoważonej liczbie cech ciągłych i kategoriowych (13 atrybutów). Dynamikę zachowania modeli, szczegółowe porównanie słupkowe przy uszkodzeniu 30% oraz ranking cech przedstawiono na rysunkach 4.5, 4.6 i 4.7.


Krzywe odporności na uszkodzenia danych - Serce



Rysunek 4.5: Krzywe odporności modeli na zbiorze „Serce”



Rysunek 4.6: Wpływ metod naprawy danych na jakość modeli na zbiorze „Serce” przy poziomie uszkodzeń 30%




Rysunek 4.7: Ranking najważniejszych cech diagnostycznych w zbiorze „Serce”

Najistotniejszymi atrybutami diagnostycznymi okazały się: wynik próby talowej (proba_ta), liczba zablokowanych naczyń (zwapnienia_miazdzycowe), obniżenie odcinka ST (max_obnizka_st) oraz maksymalne tętno wysiłkowe. Wykres słupkowy (Rysunek 4.6) wyraźnie uwidacznia, że prosta imputacja (fill) bez normalizacji jest niewystarczająca dla sieci MLP, podczas gdy połączenie usuwania outlierów, imputacji i standaryzacji (all) w pełni przywraca zdolności predykcyjne sieci.


4.2.3 Ocena na zbiorze „Diabetes” (Pima Indians Diabetes)

Zbiór Indian Pima zawiera wyłącznie atrybuty ciągłe o zróżnicowanych rozkładach. Ciągłe krzywe odporności, rozkład słupkowy przy uszkodzeniu 30% oraz strukturę ważności cech zilustrowano na rysunkach 4.8, 4.9 i 4.10.


Krzywe odporności na uszkodzenia danych - Diabetes



Rysunek 4.8: Krzywe odporności modeli na zbiorze „Diabetes”



Rysunek 4.9: Porównanie skuteczności metod czyszczenia na zbiorze „Diabetes” przy uszkodzeniu 30%




Rysunek 4.10: Ważność cech biochemicznych w predykcji cukrzycy (zbiór „Diabetes”)

Głównym predyktorem cukrzycy jest stężenie glukozy w osoczu (*plas*) oraz wskaźnik masy ciała (*mass*). W przypadku braku normalizacji i obecności ekstremalnych wartości odstających sieć MLP ulega całkowitej degradacji ($AUC \approx 0,504$ przy 50% uszkodzeń, co odpowiada klasyfikatorowi losowemu). Wdrożenie potoku *all* podnosi AUC sieci MLP do poziomu 0,642, co stanowi bezwzględny zysk rzędu $\Delta AUC = +0,138$.


4.2.4 Ocena na zbiorze „Rezygnacje” (Customer Churn)

Zbiór telekomunikacyjny charakteryzuje się dużą próbą ($N = 3333$) i dominacją atrybutów bilingowych. Odpowiednie wykresy przedstawiono na rysunkach 4.11, 4.12 i 4.13.


Krzywe odporności na uszkodzenia danych - Rezygnacje



Rysunek 4.11: Krzywe odporności modeli na zbiorze „Rezygnacje”



Rysunek 4.12: Skuteczność strategii naprawy danych na zbiorze „Rezygnacje” przy uszkodzeniu 30%




Rysunek 4.13: Ranking cech decydujących o migracji klientów w zbiorze „Rezygnacje”

W zbiorze tym dominującą rolę odgrywają: całkowity czas połączeń w dzień (DZIEN_MIN), naliczona opłata dzienna (DZIEN_OPLATA) oraz liczba kontaktów z biurem obsługi (L_POL_BIURO). Modele XGBoost i Random Forest dominują nad klasyfikatorami prostymi, zachowując $AUC > 0,80$ nawet przy 50% zanieczyszczeń.


4.2.5 Ocena na zbiorze „Kredyty” (German Credit)

Zbiór oceny ryzyka kredytowego zawiera liczne cechy kategoryczne i jest zadaniem o najniższej bazowej separowalności. Wyniki przedstawiono na rysunkach 4.14, 4.15 i 4.16.


Krzywe odporności na uszkodzenia danych - Kredyty



Rysunek 4.14: Krzywe odporności modeli na zbiorze „Kredyty”



Rysunek 4.15: Porównanie modeli i metod czyszczenia na zbiorze „Kredyty” przy poziomie uszkodzeń 30%




Rysunek 4.16: Ranking cech determinujących ocenę ryzyka w zbiorze „Kredyty”

Kluczowymi czynnikami ryzyka kredytowego są: czas trwania rachunku (Czas_trwania_konta), wnioskowana kwota pożyczki (Kwota_kredytu) oraz wiek pożyczkobiorcy (Wiek).


4.3 Analiza zysku z czyszczenia danych (ΔAUC) i profile wielowymiarowe

Aby dokonać całościowej syntezy zysków z poszczególnych strategii czyszczenia danych, wygenerowano macierze korelacji zysku ΔAUC w trzech przekrojach badawczych.


Rysunek 4.17 przedstawia zależność zysku od rodziny klasyfikatora, rysunek 4.18 w przekroju zbiorów danych, a rysunek 4.19 w funkcji nasilenia zanieczyszczeń.



Rysunek 4.17: Heatmapa średniego zysku ΔAUC w relacji: Badana rodzina modelu vs Zastosowana metoda czyszczenia



Rysunek 4.18: Heatmapa średniego zysku Δ AUC w relacji: Zbiór danych vs Zastosowana metoda czyszczenia




Rysunek 4.19: Heatmapa średniego zysku Δ AUC w funkcji poziomu uszkodzeń danych


Wnioski płynące z analizy heatmap:

1. **Asymetria wrażliwości architektur:** Sieć neuronowa (MLP) oraz Naiwny Bayes osiągają największe zyski ze złożonych potoków (*all*: średnio +0,07 do +0,14 Δ AUC). Dla sieci MLP kluczowa jest obecność normalizacji (*fill_norm* lub *all*), bez której optymalizacja wag staje się niestabilna.
2. **Efekt skali uszkodzeń:** Zysk Δ AUC z wdrożenia czyszczenia rośnie monotonicznie wraz z poziomem degradacji danych — od średnio +0,015 przy uszkodzeniu 10% do ponad +0,085 przy uszkodzeniu 50%.
3. **Synergia metod:** Pojedyncza imputacja (*fill*) daje istotny zysk, jednak dopiero połączenie eliminacji outlierów ze standaryzacją i imputacją (*all*) gwarantuje globalnie najwyższą skuteczność.

Wielowymiarowe profile odporności metod zilustrowano za pomocą wykresów radarowych na rysunkach 4.20 i 4.21.




Rysunek 4.20: Wykres radarowy względnej odporności metod czyszczenia dla poszczególnych klasyfikatorów



Rysunek 4.21: Wykres radarowy skuteczności metod czyszczenia w przekroju badanych zbiorów danych

4.4 Porównanie strategii imputacji: Mediana vs KNN Imputer

W ramach pracy przeprowadzono bezpośrednie porównanie prostych estymatorów statystycznych (imputacja medianą) z metodami opartymi na wielowymiarowym sąsiedztwie rekordów (`KNNImputer`, $k = 5$). Zestawienie wyników przedstawiono na rysunku 4.22.



Rysunek 4.22: Bezpośrednie porównanie skuteczności imputacji medianą i algorytmem KNN w potokach przetwarzania

Obserwacje eksperymentalne wskazują, że:

- W przypadku braku wcześniejszej filtracji wartości odstających, `KNNImputer` bywa podatny na propagację błędów, ponieważ zniekształcone rekordy zaburzają metrykę odległości euklidesowej w przestrzeni cech.
- W połączeniu z usuwaniem outlierów (*all_knn*) algorytm KNN osiąga wyniki zbliżone lub nieznacznie przewyższające medianę na zbiorach o silnych korelacjach wewnętrznych (np. *Diabetes*, *Serce*), jednak wiąże się ze znacznie wyższym narzutem czasowym obliczeń ($\approx 12\times$ dłuższy czas fazy *transform*).
- W praktyce inżynierskiej imputacja medianą w ramach potoku *all* stanowi optymalny kompromis pomiędzy dokładnością a złożonością obliczeniową.

4.5 Weryfikacja istotności statystycznej wyników

W celu potwierdzenia, że obserwowane różnice w skuteczności modeli nie są dziełem przypadku losowego, przeprowadzono formalne testy statystyczne:

1. **Globalny test rangowy Friedmana:** dla każdego zbioru danych i modelu zweryfikowano hipotezę o równoważności 7 badanych strategii czyszczenia. We wszystkich 20 konfiguracjach testowych ($5 \text{ zbiorów} \times 4 \text{ modele}$) test Friedmana odrzucił hipotezę zerową ($p < 0,001$), potwierdzając wysoce istotny wpływ wyboru metody czyszczenia na końcowy wynik.
2. **Test rangowy znaków Wilcoxona:** przeprowadzono testy post-hoc porównujące każdą strategię naprawczą z wariantem bazowym (*raw*) na poziomie istotności $\alpha = 0,05$.


Zbiorcze podsumowanie liczby przypadków z potwierdzoną statystycznie istotną przewagą nad danymi nieoczyszczonymi przedstawiono w tabeli 4.3.

Tabela 4.3: Liczba konfiguracji (na 5 zbiorów danych), w których dana metoda czyszczenia wykazała istotną statystycznie przewagę nad wariantem raw (test Wilcoxona, $\alpha = 0,05$)

Model	all	all_knn	fill	fill_knn	fill_norm	remove_fill
MLP (Sieć neuronowa)	5 / 5	5 / 5	1 / 5	1 / 5	5 / 5	2 / 5
Gaussian Naive Bayes	4 / 5	4 / 5	4 / 5	4 / 5	4 / 5	4 / 5
Random Forest	4 / 5	3 / 5	3 / 5	2 / 5	3 / 5	4 / 5
XGBoost	3 / 5	4 / 5	3 / 5	4 / 5	3 / 5	3 / 5
łącznie (na 20 prób)	16 / 20	16 / 20	11 / 20	11 / 20	15 / 20	13 / 20

4.5.1 Globalny ranking metod – Diagram Różnic Krytycznych (CD Diagram)

W celu syntetycznego porównania wszystkich 7 strategii czyszczenia danych na całej próbie eksperymentalnej ($N = 900$ ewaluacji), wyznaczono średnie rangi metod i przeprowadzono post-hoc test Nemenyi na poziomie istotności $\alpha = 0,05$. Rezultat przedstawiono na Diagramie Różnic Krytycznych Demšara [14] (Rysunek 4.23).



Rysunek 4.23: Diagram Różnic Krytycznych (CD Diagram) dla 7 badanych metod czyszczenia danych ($N = 900$ ewaluacji, test post-hoc Nemenyi wg metodyki Demšara [14] przy $\alpha = 0,05$, wartość CD = 0,300)

Wnioski płynące z analizy rang i Diagramu CD:

1. **Globalny lider:** Najwyższą (najniższą numerycznie) średnią rangę w całym eksperymencie osiągnęła metoda all (ranga 3,06), wyprzedzając wariant all_knn (ranga 3,35).
2. **Grupa jednorodna top-metod:** Pogrubiona pozioma belka łączy metody all oraz all_knn, co oznacza brak statystycznie istotnej różnicy pomiędzy medianą a k -NN

w pełnym potoku przy uwzględnieniu różnicy krytycznej $CD = 0,300$. Obie te metody są jednak statystycznie istotnie lepsze od metod prostych (`fill`, `fill_knn`) oraz od danych nieoczyszczonych (`raw`).

3. **Pozycja danych nieoczyszczonych:** Wariant `raw` zajął przedostatnie miejsce w rankingu (ranga 4,58), a gorszy wynik odnotował jedynie wariant `fill_knn` (ranga 4,97), w którym brak filtracji wartości odstających zafałszował obliczenia odległości euklidesowej algorytmu najbliższych sąsiadów.

Rozdział 5

Podsumowanie i wnioski

5.1 Podsumowanie wyników zrealizowanych eksperymentów

W ramach niniejszej pracy magisterskiej przeprowadzono kompleksowe i rygorystyczne metodologicznie badania empiryczne, których nadrzędnym celem była ilościowa i jakościowa ocena wpływu 7 strategii przygotowania danych na skuteczność oraz stabilność czterech architektur klasyfikatorów tabelarycznych (Random Forest, XGBoost, Gaussian Naive Bayes oraz Perceptron Wielowarstwowy MLP).

Eksperymenty zrealizowano na 5 zróżnicowanych domenowo zbiorach danych (3 zbiorach medycznych: *Zapalenia naczyń*, *Choroby serca*, *Cukrzyca Indian Pima*, zbiorze telekomunikacyjnym *Rezygnacje klientów* oraz finansowym *Ryzyko kredytowe*). Każdy ze zbiorów poddano kontrolowanemu procesowi degradacji jakości na 5 poziomach zanieczyszczeń (10%, 20%, 30%, 40%, 50%), symulując jednocześnie występowanie trzech typów anomalii: losowych braków danych, ekstremalnych wartości odstających oraz błędnych kodów kategorii jakościowych. Ewaluację przeprowadzono w procedurze powtarzanej stratyfikowanej walidacji krzyżowej, a istotność różnic zweryfikowano testami rangowymi Friedmana i Wilcoxona na poziomie istotności $\alpha = 0,05$.

5.2 Formalna weryfikacja postawionych tez badawczych

Na podstawie analizy wyników eksperymentalnych, zestawień metryk $\overline{\text{AUC}}$, analizy zysków ΔAUC oraz wyników testów nieparametrycznych, dokonano formalnej weryfikacji trzech hipotez badawczych postawionych w Rozdziale 1:

1. **Teza T1:** *Zastosowanie trójstopniowego potoku inżynierii danych (filtracja wartości odstających regułą IQR $\rightarrow$ imputacja braków $\rightarrow$ standaryzacja cech) pozwala*

zachować wysoką jakość predykcji (AUC) klasyfikatorów nawet przy 50% stopniu degradacji jakości danych.

Weryfikacja: TEZA POTWIERDZONA. Wyniki eksperymentalne jednoznacznie wykazały, że brak procedur czyszczących (*raw*) prowadzi do drastycznego załamania jakości modeli przy rosnącym poziomie zanieczyszczeń. Zastosowanie pełnego potoku trójstopniowego (*all* oraz *all_knn*) skutecznie zamortyzowało degradację, pozwalając modelom drzewiastym (RF, XGBoost) zachować $AUC > 0,80 - 0,86$ na zbiorach medycznych nawet przy 50% uszkodzonych atrybutów. W testach statystycznych Wilcoxa strategie te wykazały istotną statystycznie przewagę nad danymi surowymi w 80% badanych konfiguracji (16 na 20 przypadków).

2. **Teza T2:** *Wpływ procedur czyszczenia danych wykazuje silną asymetrię w zależności od architektury klasyfikatora — modele oparte na optymalizacji gradientowej (MLP) oraz estymacji gęstości prawdopodobieństwa (GaussianNB) charakteryzują się radykalnie wyższą wrażliwością na zanieczyszczenia i zyskują z preprocessingu znacznie więcej niż zespoły drzew decyzyjnych (Random Forest, XGBoost).*

Weryfikacja: TEZA POTWIERDZONA. Zaobserwowano wyraźną polaryzację zachowań architektur. Sieć MLP na danych nieoczyszczonych przy 50% uszkodzeń ulegała całkowitej degradacji ($AUC \approx 0,504$, co odpowiada losowemu zgadywaniu), natomiast wdrożenie potoku *all* lub *fill_norm* podnosiło jej skuteczność do poziomu 0,642 (zysk $\Delta AUC > +0,13 - +0,20$). Podobnie klasyfikator GaussianNB tracił zdolności dyskryminacyjne przez zawyżenie wariancji rozkładu normalnego przez outliery, zyskując średnio $+0,08 - +0,15$ AUC po ich eliminacji. Z kolei modele Random Forest i XGBoost wykazały wysoką naturalną odporność, zachowując stabilność nawet bez standaryzacji cech.

3. **Teza T3:** *Zastosowanie wielowymiarowej imputacji algorytmem k -najbliższych sąsiadów (k -NN) w obecności silnych korelacji międzycechowych przynosi wyższą jakość rekonstrukcji niż estymatory statystyczne (mediana), jednak wiąże się ze znaczącym narzutem obliczeniowym i wymaga wcześniejszego odfiltrowania ekstremalnych anomalii.*

Weryfikacja: TEZA POTWIERDZONA. Bezpośredni pojedynek strategii imputacji wykazał, że algorytm KNNImputer bez uprzedniej filtracji anomalii (*fill_knn*) ulega zaburzeniu metryki odległości euklidesowej. Dopiero w połączeniu z eliminacją outlierów (*all_knn*) metoda ta osiągnęła przewagę nad medianą na zbiorach o silnych korelacjach biologicznych (*Diabetes*, *Serce*). Narzut czasowy fazy transformacji był jednak około 12-krotnie wyższy, co czyni imputację medianą optymalnym kompromisem w zastosowaniach o ograniczonych zasobach obliczeniowych.

5.3 Rekomendacje inżynierskie dla praktyków Data Science

W oparciu o uzyskane wyniki sformułowano zestaw uniwersalnych zaleceń inżynierskich dotyczących budowy potoków przetwarzania danych tabelarycznych:

- **Kolejność operacji ma znaczenie krytyczne:** Potok powinien zawsze realizować sekwencję: *Detekcja outlierów ($3 \cdot IQR$)* $\rightarrow$ *Konwersja do NaN* $\rightarrow$ *Imputacja* $\rightarrow$ *Standaryzacja*. Odwrócenie tej kolejności (np. standaryzacja przed usunięciem anomalii) niszczy estymatory średniej i wariancji.
- **Dopasowanie strategii do modelu:** W projektach wykorzystujących sieci neuronowe (MLP) lub klasyfikatory odległościowe/liniowe, preprocessing z normalizacją jest bezwzględnie obligatoryjny. W przypadku modeli drzewiastych (XGBoost/RF) kluczowy zysk przynosi sama filtracja błędów grubych i poprawna imputacja braków.
- **Ścisła hermetyzacja potoków:** Wszelkie parametry transformatorów muszą być uczone wyłącznie na podzbiorze treningowym wewnątrz obiektu Pipeline, co chroni przed katastrofalnym wyciekiem informacji (*data leakage*).

5.4 Trudności implementacyjne i ograniczenia badań

Podczas realizacji prac napotkano na następujące wyzwania metodologiczne:

1. **Złożoność obliczeniowa procedur k -NN:** Wielokrotna ewaluacja algorytmu KNNImputer na setkach podziałów walidacji krzyżowej i wielu poziomach uszkodzeń wymagała optymalizacji pamięciowej i wielowątkowej.
2. **Nieźrównoważenie klas decyzyjnych:** W niektórych zbiorach (np. *Zapalenia naczyń*, *Rezygnacje*) wystąpiła znaczna asymetria liczebności klas, co wymusiło rygorystyczne stosowanie stratyfikacji oraz wybór metryki AUC jako miary niewrażliwej na dysproporcje klas.

5.5 Kierunki dalszego rozwoju badań

Jako obiecujące perspektywy kontynuacji podjętej tematyki badawczej wskazuje się:

- zbadanie skuteczności zaawansowanych metod imputacji wielokrotnej, takich jak algorytm MICE (ang. *Multivariate Imputation by Chained Equations*) oraz lasy imputacyjne *MissForest*,

- ewaluację odporności nowoczesnych architektur głębokich dedykowanych danym tabelarycznym (m.in. TabNet, FT-Transformer, SAINT),
- analizę wpływu zanieczyszczeń w warunkach dryfu pojęciowego (ang. *concept drift*) w strumieniowym przetwarzaniu danych w czasie rzeczywistym.

ZAKOŃCZENIE

Przeprowadzone w niniejszej pracy magisterskiej badania pozwoliły na całościową, empiryczną i teoretyczną ocenę wpływu procedur wstępnego przetwarzania i czyszczenia danych na jakość działania współczesnych algorytmów uczenia maszynowego. W obliczu dynamicznego rozwoju systemów sztucznej inteligencji, praca ta dostarcza istotnych dowodów na to, że inżynieria danych i właściwa obsługa zanieczyszczeń stanowią warunek konieczny dla budowy bezpiecznych i wiarygodnych modeli predykcyjnych, szczególnie w domenach o podwyższonym ryzyku, takich jak medycyna kliniczna.

W toku zrealizowanych eksperymentów wykazano, że bezrefleksyjne stosowanie modeli uczenia maszynowego na danych zanieczyszczonych prowadzi do drastycznego spadku ich zdolności dyskryminacyjnych. Jednocześnie udowodniono, że odpowiednio zaprojektowany, wieloetapowy potok przetwarzania — łączący filtrację ekstremalnych wartości odstających za pomocą reguły rozstępu międzykwartylowego, imputację braków danych oraz standaryzację cech — pozwala na niemal całkowite zniwelowanie negatywnych skutków degradacji danych wejściowych nawet przy 50-procentowym nasileniu anomalii.

Zgromadzony materiał badawczy, poparty rygorystyczną analizą statystyczną (testami rangowymi Friedmana i Wilcoxa), potwierdził fundamentalną asymetrię wrażliwości pomiędzy badanymi klasyfikatorami. Wykazano, że podczas gdy modele drzewiaste (Random Forest i XGBoost) cechują się naturalną, wysoką odpornością na brak skalowania i obecność szumu, to klasyfikatory oparte na optymalizacji gradientowej (MLP) oraz estymacji gęstości prawdopodobieństwa (Gaussian Naive Bayes) wymagają bezwzględniego wdrożenia dedykowanych procedur czyszczących, osiągając dzięki nim spektakularne zyski predykcyjne.

Opracowany w ramach pracy modularny kod źródłowy w języku Python oraz zaimplementowane transformatory mogą posłużyć jako gotowy punkt wyjścia do budowy zautomatyzowanych potoków inżynierii danych w rzeczywistych wdrożeniach analitycznych.

LITERATURA

- [1] Michael Walker, *Czyszczenie danych w Pythonie. Receptury. Nowoczesne techniki i narzędzia Pythona do wykrywania i eliminacji zanieczyszczeń oraz wydobywania kluczowych cech z danych*, Helion, Gliwice, 2021.
- [2] John W. Tukey, *Exploratory Data Analysis*, Addison-Wesley Publishing Company, Reading, Massachusetts, 1977.
- [3] Roderick J. A. Little, Donald B. Rubin, *Statistical Analysis with Missing Data*, 2nd Edition, John Wiley & Sons, Hoboken, New Jersey, 2002.
- [4] Peter J. Huber, *Robust Statistics*, John Wiley & Sons, New York, 1981.
- [5] Trevor Hastie, Robert Tibshirani, Jerome Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd Edition, Springer-Verlag, New York, 2009.
- [6] Leo Breiman, *Random Forests*, Machine Learning, tom 45, nr 1, s. 5–32, 2001.
- [7] Tianqi Chen, Carlos Guestrin, *XGBoost: A Scalable Tree Boosting System*, Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, s. 785–794, 2016.
- [8] Fei Tony Liu, Kai Ming Ting, Zhi-Hua Zhou, *Isolation Forest*, Proceedings of the 2008 Eighth IEEE International Conference on Data Mining (ICDM), s. 413–422, 2008.
- [9] Diederik P. Kingma, Jimmy Ba, *Adam: A Method for Stochastic Optimization*, 3rd International Conference for Learning Representations (ICLR), San Diego, 2015.
- [10] Tom Fawcett, *An Introduction to ROC Analysis*, Pattern Recognition Letters, tom 27, nr 8, s. 861–874, 2006.
- [11] James A. Hanley, Barbara J. McNeil, *The Meaning and Use of the Area under a Receiver Operating Characteristic (ROC) Curve*, Radiology, tom 143, nr 1, s. 29–36, 1982.

- [12] Frank Wilcoxon, *Individual Comparisons by Ranking Methods*, Biometrics Bulletin, tom 1, nr 6, s. 80–83, 1945.
- [13] Milton Friedman, *The Use of Ranks to Avoid the Assumption of Normality Implicit in the Analysis of Variance*, Journal of the American Statistical Association, tom 32, nr 200, s. 675–701, 1937.
- [14] Janez Demšar, *Statistical Comparisons of Classifiers over Multiple Data Sets*, Journal of Machine Learning Research, tom 7, s. 1–30, 2006.
- [15] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, Édouard Duchesnay, *Scikit-learn: Machine Learning in Python*, Journal of Machine Learning Research, tom 12, s. 2825–2830, 2011.
- [16] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt, et al., *Array programming with NumPy*, Nature, tom 585, nr 7825, s. 357–362, 2020.
- [17] Wes McKinney, *Data Structures for Statistical Computing in Python*, Proceedings of the 9th Python in Science Conference, s. 56–61, 2010.
- [18] John D. Hunter, *Matplotlib: A 2D Graphics Environment*, Computing in Science & Engineering, tom 9, nr 3, s. 90–95, 2007.
- [19] Michael L. Waskom, *seaborn: statistical data visualization*, Journal of Open Source Software, tom 6, nr 60, s. 3021, 2021.
- [20] Dheeru Dua, Casey Graff, *UCI Machine Learning Repository*, University of California, Irvine, School of Information and Computer Sciences, <http://archive.ics.uci.edu/ml>, 2017.
- [21] scikit-learn developers, *Preprocessing data*, dokumentacja biblioteki scikit-learn, <https://scikit-learn.org/stable/modules/preprocessing.html>, dostęp: 2026.
- [22] scikit-learn developers, *StandardScaler*, dokumentacja biblioteki scikit-learn, <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>, dostęp: 2026.
- [23] scikit-learn developers, *MinMaxScaler*, dokumentacja biblioteki scikit-learn, <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.MinMaxScaler.html>, dostęp: 2026.

- [24] scikit-learn developers, *KNNImputer*, dokumentacja biblioteki scikit-learn, <https://scikit-learn.org/stable/modules/generated/sklearn.impute.KNNImputer.html>, dostęp: 2026.
- [25] scikit-learn developers, *GaussianNB*, dokumentacja biblioteki scikit-learn, https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.GaussianNB.html, dostęp: 2026.
- [26] scikit-learn developers, *MLPClassifier*, dokumentacja biblioteki scikit-learn, https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html, dostęp: 2026.
- [27] scikit-learn developers, *RandomForestClassifier*, dokumentacja biblioteki scikit-learn, <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>, dostęp: 2026.
- [28] scikit-learn developers, *roc_auc_score*, dokumentacja biblioteki scikit-learn, https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_auc_score.html, dostęp: 2026.
- [29] scikit-learn developers, *roc_curve*, dokumentacja biblioteki scikit-learn, https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_curve.html, dostęp: 2026.
- [30] scikit-learn developers, *accuracy_score*, dokumentacja biblioteki scikit-learn, https://scikit-learn.org/stable/modules/generated/sklearn.metrics.accuracy_score.html, dostęp: 2026.
- [31] scikit-learn developers, *f1_score*, dokumentacja biblioteki scikit-learn, https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html, dostęp: 2026.
- [32] NumPy developers, *numpy.std*, dokumentacja NumPy, <https://numpy.org/doc/stable/reference/generated/numpy.std.html>, dostęp: 2026.
- [33] XGBoost developers, *XGBoost Documentation*, <https://xgboost.readthedocs.io/en/stable/>, dostęp: 2026.

STRESZCZENIE

Tytuł pracy w języku polskim:

Wpływ metod czyszczenia danych na jakość klasyfikatorów

Tytuł pracy w języku angielskim:

Impact of Data Cleaning Methods on Classifier Performance

Streszczenie:

Niniejsza praca magisterska poświęcona jest kompleksowej analizie wpływu metod wstępnego przetwarzania i czyszczenia danych tabelarycznych na skuteczność oraz stabilność wybranych modeli uczenia maszynowego. W pracy zbadano techniki identyfikacji i eliminacji wartości odstających oparte na regule rozstępu międzykwartylowego (IQR), metody jedno- i wielowymiarowej imputacji brakujących danych (mediana oraz k -najbliższych sąsiadów) oraz procedury standaryzacji cech z -score i kodowania zmiennych kategoriycznych. Badania empiryczne przeprowadzono na pięciu zróżnicowanych zbiorach danych (Zapalenia naczyń, Choroby serca, Cukrzyca, Rezygnacje klientów oraz Ryzyko kredytowe) poddanych kontrolowanej degradacji jakości w zakresie od 10% do 50%. Ewaluację wykonano dla czterech rodzin klasyfikatorów: Naiwnego Klasyfikatora Bayesa, Perceptronu Wielowarstwowego (MLP), Lasów Losowych oraz XGBoost, mierząc pole pod krzywą ROC (AUC) w procedurze wielokrotnej stratyfikowanej walidacji krzyżowej. Istotność statystyczną obserwowanych różnic zweryfikowano testami rangowymi Wilcoxona i Friedmana.

Słowa kluczowe:

czyszczenie danych, uczenie maszynowe, klasyfikacja tabelaryczna, imputacja braków danych, wartości odstające, standaryzacja, walidacja krzyżowa, AUC, Random Forest, XGBoost, MLP, Gaussian Naive Bayes.

Abstract:

This master's thesis investigates the impact of tabular data preprocessing and cleaning techniques on the predictive performance and stability of machine learning classification models. The study evaluates outlier detection and handling methods based on the

interquartile range (IQR) rule, uni- and multidimensional missing value imputation strategies (median and k -Nearest Neighbors), and numerical feature standardization alongside categorical encoding. Empirical experiments were conducted on five diverse benchmark datasets (Systemic Vasculitis, Heart Disease, Diabetes, Customer Churn, and German Credit) subjected to controlled data corruption levels ranging from 10% to 50%. Four distinct classifier families were evaluated: Gaussian Naive Bayes, Multilayer Perceptron (MLP), Random Forest, and XGBoost, measuring the Area Under the ROC Curve (AUC) across repeated stratified cross-validation folds. The statistical significance of performance gains was formally verified using Wilcoxon signed-rank and Friedman tests.

Keywords:

data cleaning, machine learning, tabular classification, missing value imputation, outlier detection, standardization, cross-validation, AUC, Random Forest, XGBoost, MLP, Gaussian Naive Bayes.